Universidad Tecnológica de Pereira

SUSTENTACIÓN DE TESIS DE MAESTRÍA

Modelo de Optimización para la Planificación de Coproductos con Metaheurísticas en la Industria Avícola

Daniel Andrés Castañeda Rodríguez

Directora: PhD. Eliana Mirledy Ocampo Toro

Maestría en Investigación de Operaciones y Estadística — Universidad Tecnológica de Pereira · 2026

Agenda

1. Contexto de la industria avícola
2. Problema e hipótesis
3. Justificación
4. Objetivos
5. Marco teórico
6. Estado del arte
7. Modelo matemático
8. Diseño experimental y metaheurísticas
9. Resultados: campaña diagnóstica (v1) y confirmatoria (v2)
10. Conclusiones y trabajo futuro

> Idea clave: cuatro actos — el problema, el modelo, la evidencia en dos campañas y lo que significa para la industria.

El problema

«Cada pollo produce un mix fijo; el mercado no compra ese mix».

1. Una industria de 1.7M t/año planifica sobre un mix que no elige

1.7M
t/año de producción de pollo en Colombia (FENAVI 2023)

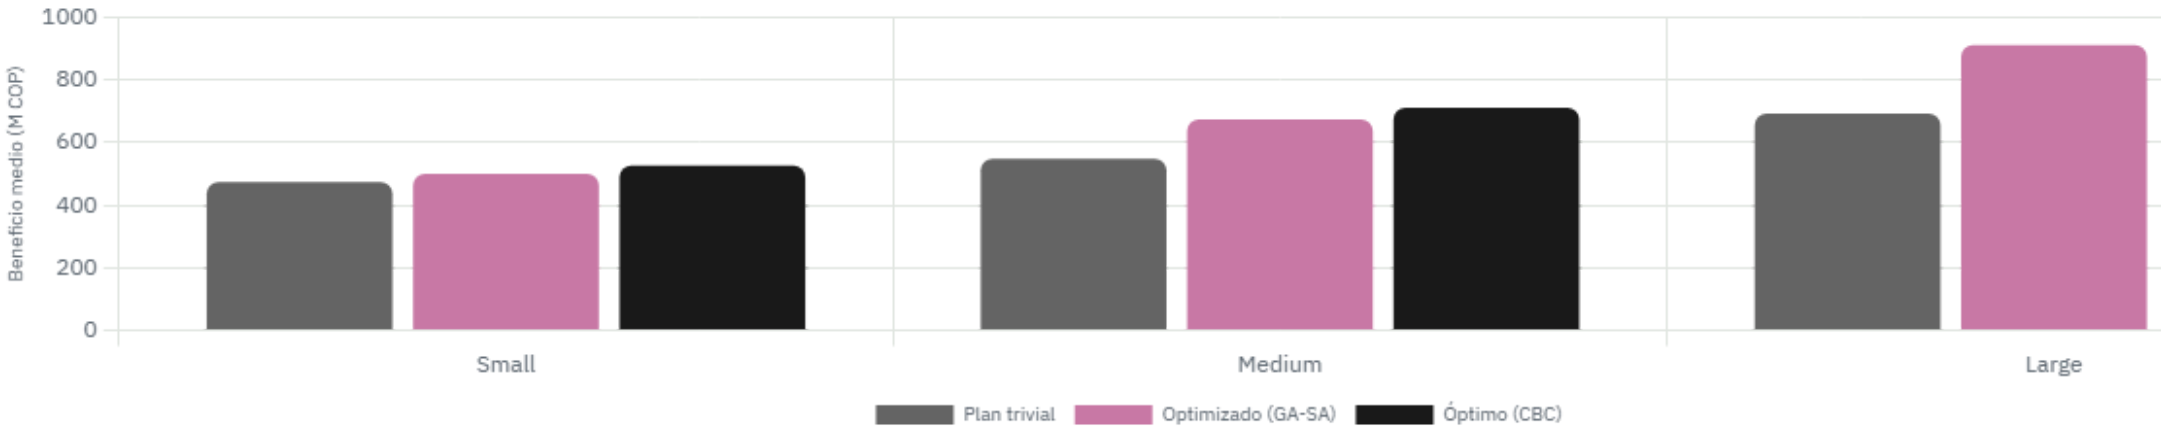
~30%
de la canal es pechuga: el resto debe venderse igual

20%
beneficio adicional demostrado (campaña confirmatoria)

Por qué es un problema difícil

- **8 coproductos por carcasa** (pechuga, muslo, ala, etc.) en proporciones fijas α_p.
- **CLSP estocástico NP-hard:** setup, perecibilidad y coproducción simultáneos.
- Demanda heterogénea y estacional por corte.

Baseline vs GA-SA vs CBC exacto



Beneficio medio (M COP) por tamaño — campaña confirmatoria (v2). El plan trivial deja 10–29% sobre la mesa.

Idea clave: a esta escala, cada punto porcentual de eficiencia en el mix vale miles de millones de COP al año.

2. La anatomía fija la oferta; el mercado exige otro mix

Push (Oferta)

- Oferta **rígida** por anatomía de la carcasa.
- Proporciones fijas de coproductos (α_p).
- No se puede producir solo pechuga.

Pull (Demanda)

- Demanda **estacional** y heterogénea por corte.
- Pechuga alta demanda, ala baja rotación.
- Perecibilidad: vida útil $L_p \in [3,7]$ periodos.

Consecuencias del desbalance

Consecuencia	Descripción	Impacto
Inventario excesivo	Productos de baja rotación se acumulan	Costos de almacenamiento
Pérdida por perecibilidad	Producto vencido = pérdida total	Reducción de margen
Demanda insatisfecha	Cortes de alta demanda agotados	Pérdida de ventas

Idea clave: no se puede producir solo pechuga → todo plan de producción administra el mix completo o paga el desbalance.

3. El desbalance cuesta margen, inventario y desperdicio

Relevancia Económica

Consecuencia	Impacto estimado	Fuente
Costos de inventario excesivo	+15–25% del costo total	Sel et al. 2015
Pérdidas por ventas de liquidación	−20–40% del margen	Amorim et al. 2014
Desperdicio de producto perecedero	5–10% de la producción	Claassen 2016
Penalización por demanda insatisfecha	Variable por contrato	Solano-Blanco 2022

Alineación ODS

- **ODS 9** (Industria, Innovación e Infraestructura): Aplicación de técnicas avanzadas de optimización a la industria colombiana.
- **ODS 12** (Producción y Consumo Responsables): Reducción del desperdicio alimentario mediante planificación óptima.

Relevancia Metodológica

- Primer framework que combina **lot-sizing estocástico + coproductos + perecibilidad + metaheurísticas** en la industria avícola.
- Benchmark reproducible con instancias calibradas con FENAVI/DANE.

Idea clave: inventario excesivo, liquidaciones y desperdicio son costos evitables con mejor planificación — y alinean el estudio con los ODS 9 y 12.

4. Tres hipótesis falsables sobre el valor de optimizar

¿Cómo optimizar la planificación de producción de coproductos avícolas bajo demanda estocástica, minimizando costos de inventario y maximizando el beneficio?

H1: La mejor metaheurística mejora Z en ≥ 5% vs baseline **v1: No (0.6%–1.1%)** **v2: Soportada (20%–21%, $p<10^{-4}$)**

H2: GA-SA alcanza gap ≤ 2% vs mejor metaheurística individual **v1: Sí (-0.02%)** **v2: Sí (+0.54%)**

H3: Reducción de inventario ≥ 15% (endpoint primario: inventario promedio) **v1: No (12%–17%)** **v2: Soportada (28%–31%, $p<10^{-4}$)**

Hallazgo central: el valor de la optimización depende del régimen económico. Régimen v1 (demanda > capacidad, setup marginal): una regla trivial es casi óptima. Régimen operativo v2 (setup costoso, holgura, demanda volátil): las mejoras hipotetizadas se confirman con potencia 1.000.

Lectura metodológica

- **Baseline:** comparador de impacto operativo/negocio.
- **CBC exacto:** comparador técnico de calidad (gap).
- Objetivo: escalar con buena calidad, no superar al exacto.

Idea clave: las mismas tres hipótesis se contrastan en dos regímenes económicos — y el veredicto cambia con el régimen.

5. Objetivos: formular, resolver, calibrar y validar en dos campañas

Objetivo General

Desarrollar un modelo de optimización para la planificación de coproductos en la industria avícola colombiana, resuelto mediante metaheurísticas.

OE1. Formular un modelo MILP multi-periodo con lot-sizing estocástico.

OE2. Implementar GA, SA, DE y el híbrido GA-SA.

OE3. Calibrar hiperparámetros con Optuna (TPE).

OE4. Comparar rendimiento en dos campañas: 9 instancias × 30 semillas (v1) y 30 instancias × 6 semillas con presupuesto igualado (v2).

OE5. Validar con datos FENAVI/DANE y análisis de sensibilidad.

Idea clave: del modelo formal (OE1) a la validación estadística (OE5), un pipeline completo y reproducible.

6. Coproducción + perecibilidad + estocasticidad: un CLSP NP-hard

Producción Conjunta

- Despiece genera **P coproductos** en **proporciones fijas** α_p.
- Decisión sobre un corte implica producción de todos los demás.
- Clasificación OR: *mezcla multi-producto con restricciones de co-producción* (Gicquel & Miègeville, 2017).

CLSP Estocástico + Perecibilidad

- **NP-hard** demostrado formalmente (Florian et al. 1980; Bitran & Yanasse 1982).
- Extensión estocástica preserva NP-hardness (Rahmani et al. 2025).
- Variables: setup binario y_t, lote continuo q_t, inventario $I_{pt\omega}$.
- **Perecibilidad:** vida útil L_p con política FIFO (Entrup et al. 2005).

Prog. Estocástica 2 Etapas

- **1ª etapa** (*here-and-now*): setup y_t y producción q_t.
- **2ª etapa** (*wait-and-see*): ventas $v_{pt\omega}$, inventario $I_{pt\omega}$ por escenario $\omega \in \Omega$.
- F.O.: maximizar **beneficio esperado** sobre todos los escenarios (Birge & Louveaux, 2011).

Metaheurísticas (Clasificación)

- **Trayectoria** (SA): intensificación local, aceptación probabilística de Boltzmann.
- **Población** (GA, DE): diversificación global, operadores evolutivos.
- **Híbridos meméticos** (GA-SA): exploración GA + explotación SA cada *k* generaciones.

Justificación del enfoque

Lote mínimo + setup + perecibilidad + estocasticidad: el problema es formalmente **NP-hard** (Mahdieh et al. 2018). En los tamaños estudiados (hasta ≈58,000 variables) CBC certifica el óptimo en segundos (small/medium) y hasta ~3 min (large); el valor de las metaheurísticas está en su comportamiento *anytime* (99% del óptimo en segundos), su escalabilidad al tamaño industrial real (52 periodos × 500 escenarios) y su flexibilidad para extensiones no lineales o multi-objetivo.

Idea clave: el valor de las metaheurísticas no es vencer a CBC, sino su comportamiento anytime y su escalabilidad al tamaño industrial.

7. Ningún trabajo previo integra las cuatro dimensiones con coproductos

Búsqueda sistemática Scopus (feb. 2026): 8 queries temáticas → 478 resultados → **13 papers** en la intersección directa.

Q7 (reviews multi-product lot-sizing estocástico) = 0 resultados.

Queries Scopus y Resultados

Q	Tema	#
Q1	Lot-sizing estocástico + NP-hard	9
Q2	MH + Setup estocástico	11
Q3	Perecibilidad + Lot-sizing	20
Q4	Optimización avícola/cárnica	186
Q5	Prog. estocástica + MH	218
Q6	CLSP + Complejidad	30
Q7	Reviews multi-product estocástico	**0**
Q8	Lote mínimo + Prog. entera	4
	Total	**478**

Autor	Año	Enfoque	Vacío
Solano-Blanco et al.	2022	MILP estocástico avícola	Sin MH
Akbari-Aghghaleh et al.	2025	GA-SA SC avícola	Determinista
Tahraoui et al.	2025	MILP CPLEX avícola	Sin MH
Rahmani et al.	2025	Híbrido CLSP estoc.	No avícola
Claassen	2016	Lot-sizing + decay FPI	Determinista
Slama et al.	2021	GA + Monte Carlo CLSP	Sin coprod.

Brecha central

Solo **2.7% de 478 papers** (13) tocan simultáneamente lot-sizing estocástico + perecibilidad + MH + avícola. **Ninguno** combina las 4 dimensiones con coproductos.

Idea clave: 13 de 478 papers rozan la intersección; la combinación completa con coproductos es la brecha que llena esta tesis.

II

Modelo y algoritmos

«Un MILP estocástico y cuatro metaheurísticas sobre el mismo decodificador».

8. Un MILP estocástico de dos etapas maximiza el beneficio esperado

Función Objetivo: Maximizar beneficio esperado

$$\max Z = \frac{1}{|\Omega|} \sum_{\omega} \left[\sum_{p,t} r_p \cdot v_{pt\omega} - \sum_{t} (c_{prod} \cdot q_t + c_{setup} \cdot y_t) - \sum_{p,t} c_{inv} \cdot I_{pt\omega} \right]$$

Restricciones clave

- Coproducción: $x_{pt} = \alpha_p \cdot q_t$
- Setup: $q_t \leq Q^{max} \cdot y_t$
- Lote mínimo: $q_t \geq Q^{min} \cdot y_t$
- Balance: $I_{pt\omega} = I_{p,t-1,\omega} + x_{pt} - v_{pt\omega}$
- Perecibilidad: FIFO con vida útil L_p

Dimensiones

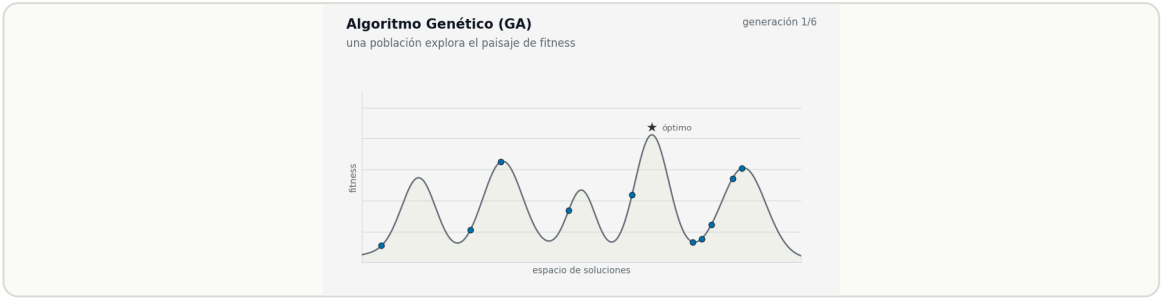
Tamaño	T (v1 / v2)	Formas	|Ω|
Small	6 / 12	6	10 / 20
Medium	12 / 18	6	50 / 50
Large	30 / 24	8	100 / 100

≈1,100–58,000 variables (medido en CBC); v2 añade parvada mixta y setup 50M

Idea clave: setup y lote se deciden antes de conocer la demanda; el modelo optimiza su valor esperado sobre los escenarios.

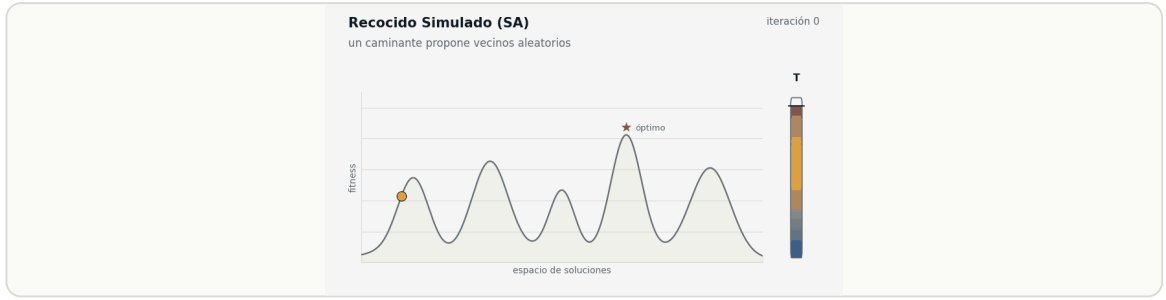
9. Cuatro estrategias de búsqueda: población, trayectoria e hibridación

GA



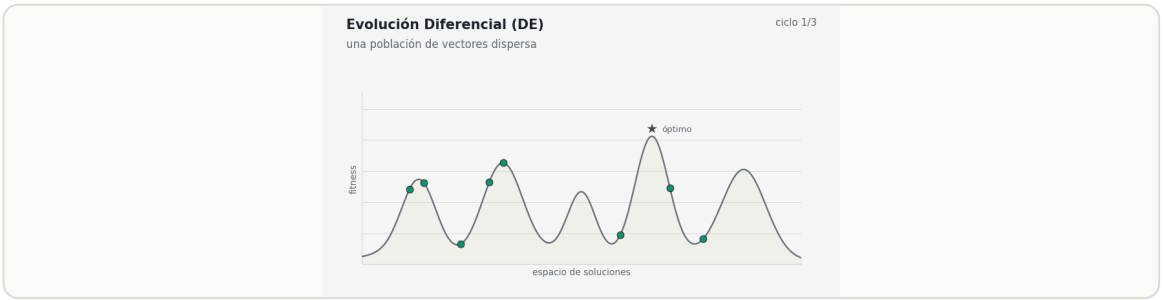
Población → selección → cruce → mutación.

SA



Trayectoria con enfriamiento: $T_0 \rightarrow T_{min}$.

DE



Mutación: $v = x_{r1} + F \cdot (x_{r2} - x_{r3})$.

GA-SA (Híbrido)



GA global + SA local cada *k* generaciones.

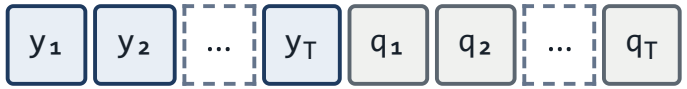
Idea clave: cuatro mecanismos de búsqueda distintos compiten sobre el mismo problema y en igualdad de condiciones.

10. Un cromosoma y un decodificador comunes hacen justa la comparación

Aplicación Universal: Este esquema y decodificador es utilizado de manera idéntica por GA, SA, DE y GA-SA.

1. Estructura del Cromosoma (Genotipo)

Vector unificado de **2T genes** (dos puntos de decisión por cada uno de los T periodos). Combina variables de setup binarias (y_t) y tamaño de lote continuas (q_t):



Restricciones físicas mapeadas a cotas: $q_t \in [Q^{min}, Q^{max}]$.

2. Decodificador Greedy (Fenotipo)

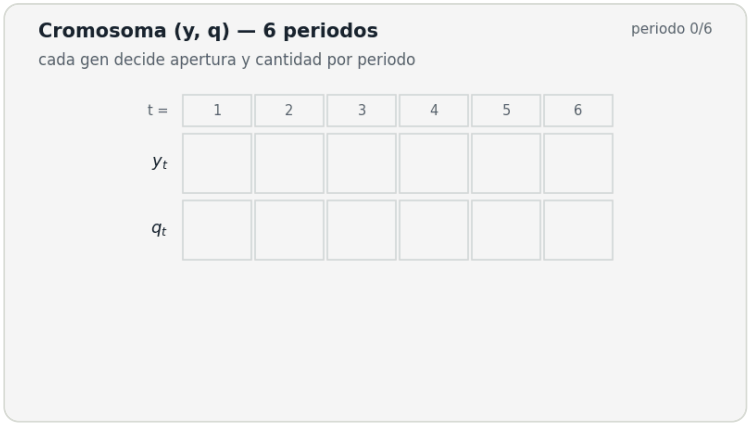
1. **Reparación factibilidad:** Forzar $y_t = 1$ si la demanda supera stock disponible.
2. **Balance de Masas:** Calcular coproductos $x_{pt} = \alpha_p \cdot q_t$ para cada parte.
3. **Simulación Estocástica:** Computar inventario FIFO a través de los $|\Omega|$ escenarios de demanda de la instancia (10–100).
4. **Perecibilidad:** Descartar producto excediendo vida útil L_p (Desecho).
5. **Fitness:** Esperanza matemática E[Z] de la utilidad neta.

Fuentes empíricas: Adaptado de la representación clásica de Lot-Sizing en agroindustrias.

Idea clave: al compartir representación y decodificador, la comparación mide algoritmos de búsqueda, no diferencias de implementación.

11. Vecindades que equilibran exploración y explotación en un espacio de 10^{35}

Cromosoma s = (y, q)



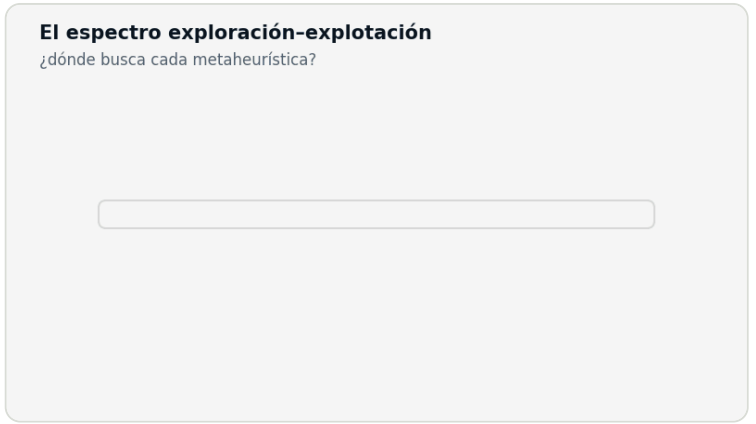
Codifica solo las decisiones de 1ª etapa: setup $y_t \in \{0, 1\}$ y lote $q_t \in [Q^{min}, Q^{max}]$. Espacio de búsqueda ≈ 8.7×10^{35} (T=12): la enumeración exhaustiva es imposible.

Operadores de vecindad



N_{toggle} invierte bits de setup (saltos estructurales); $N_{quantity}$ perturba cantidades (ajuste fino). N_{mixta} los combina probabilísticamente — usado por **SA** y **GA-SA**.

Exploración–Explotación



GA/DE diversifican vía población; SA intensifica con enfriamiento (Metropolis $P = e^{\Delta / T}$). **GA-SA** combina exploración global del GA con explotación periódica del SA sobre los top-k.

Idea clave: con ≈ 8.7×10^{35} soluciones posibles, el diseño de la vecindad importa tanto como el algoritmo que la recorre.

III

La evidencia

«Dos campañas: una diagnóstica que falló con honestidad y una confirmatoria que respondió».

12. Diseño experimental: 1,878 corridas en dos campañas

Factores y niveles

Factor	Niveles
Algoritmo	6 (GA, SA, DE, GA-SA, Baseline, CBC)
Tamaño	3 (Small, Medium, Large)
Semilla	30 réplicas independientes
Total v1	**1,098 ejecuciones** (+780 de la campaña v2 → 1,878)

Calibración (Optuna TPE)

- 30 trials por algoritmo sobre 5 instancias de calibración.
- Función objetivo: maximizar Z promedio (3 small + 2 medium).
- Timeout por trial: 900 s, con registro completo de trazabilidad.

Pruebas estadísticas

- ANOVA + Tukey HSD (vista por corridas)
- Friedman + Wilcoxon-Holm (bloques por instancia)
- Contrastes one-sided contra umbral para H1/H2/H3
- $\alpha = 0.05$

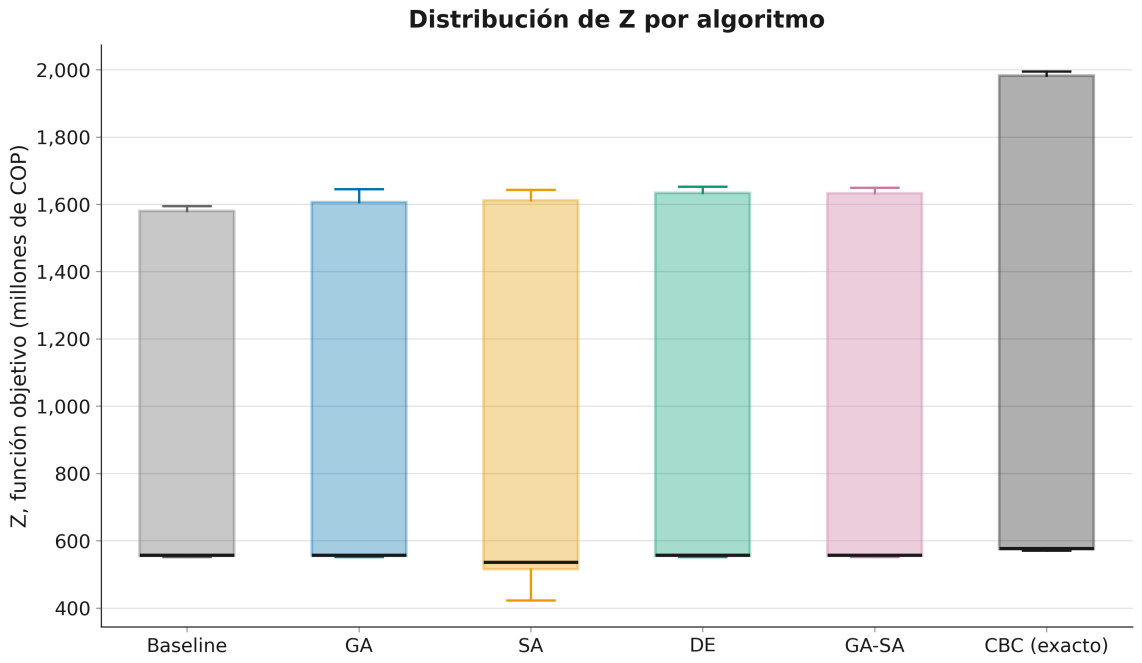
Idea clave: calibración con Optuna, réplicas independientes y pruebas no paramétricas sostienen cada afirmación que sigue.

13. Campaña diagnóstica (v1): la instancia pesa más que el algoritmo

Distribución Empírica (Z Global)

- **Varianza inter-instancia:** El valor objetivo Z es altamente heterocedástico, dependiendo críticamente de la demanda pico y el tamaño de la instancia.
- **Dispersión entre semillas:** GA/GA-SA/DE muestran baja variación en small/medium; SA mantiene mayor dispersión en las 9 instancias.
- **Ranking práctico:** GA-SA y DE lideran en media, con diferencias prácticas pequeñas entre ambos.

Dato analítico: frente a CBC exacto, el gap medio de GA-SA/DE/GA es ~8.1–8.5% (mediana 3.43%); en H2, GA-SA vs mejor MH es -0.02%.



Idea clave: la varianza entre instancias domina (~10×) sobre la diferencia entre algoritmos: el ranking exige bloquear por instancia.

14. Campaña diagnóstica (v1): el baseline trivial empata — y eso es un hallazgo

Algoritmo	$\bar{Z}$ (COP)	Std Z	Rank	N
GA-SA	**916,865,520**	512,578,412	**1**	270
DE	916,484,283	512,072,980	2	270
GA	908,817,120	501,216,075	3	270
SA	883,217,511	522,140,338	4	270

Lectura estadística: ANOVA por corridas p=0.855 (no significativo), pero **Friedman bloqueado por instancia p=0.0011** (significativo). Comparaciones Wilcoxon-Holm: SA vs {DE, GA-SA} significativas ($p < 0.024$). GA-SA ≈ DE en magnitud de efecto ($\Delta \approx 0.024\%$).

Ranking práctico: GA-SA ≈ DE > GA > SA. La varianza inter-instancia domina (~10×) frente a la varianza inter-algoritmo.

Idea clave: el empate con el baseline no es un fracaso — delimita el régimen donde optimizar no paga y motiva la campaña confirmatoria.

15. Contrastación formal (v1): H2 se sostiene; H1 y H3 no alcanzan el umbral

Pruebas Globales

Dócima	Estadístico	P-valor	Significancia (α=0.05)
ANOVA 1-way (corridas)	F = 0.259	**0.8550**	No significativo
Friedman (instancia)	χ^2 = 16.07	**0.0011**	Significativo
Wilcoxon-Holm (pares)	SA vs DE / GA-SA	**< 0.024**	Significativo
Shapiro-Wilk	varía	< 0.05 (varios casos)	No normalidad global

Nota: la vista por corridas queda dominada por heterogeneidad entre instancias; la vista bloqueada por instancia mejora la inferencia para ranking.

H1: EFECTIVIDAD VS BASELINE

No soportada en v1: mejora por instancia de 0.59%–1.10% (p=1.0 frente al umbral 5%). El baseline de capacidad máxima es casi óptimo en este régimen (potencia del diseño ≈ 0). **Soportada en v2** (siguiente lámina).

H2: SINERGIA COMPUTACIONAL DE GA-SA

Soportada (calidad): gap medio = -0.02% (p=0.002 por instancia). El componente de tiempo (≤50% de CBC) no se cumple: la razón media por instancia es 4.7× (52.5× en v1), dominada por las small donde CBC resuelve en ~2 s; en tiempo total agregado GA-SA es comparable a CBC (≈1×).

H3: INVENTARIO (PRIMARIO + SECUNDARIO)

No soportada en v1 (primario): no se alcanza 15%; baja rotación queda exploratorio por n informativo bajo. **Soportada en v2** (28%–31%).

Idea clave: hay significancia estadística entre algoritmos, pero sin relevancia práctica frente al baseline en este régimen.

16. Campaña confirmatoria (v2): 20% más beneficio y −30% inventario donde el setup importa

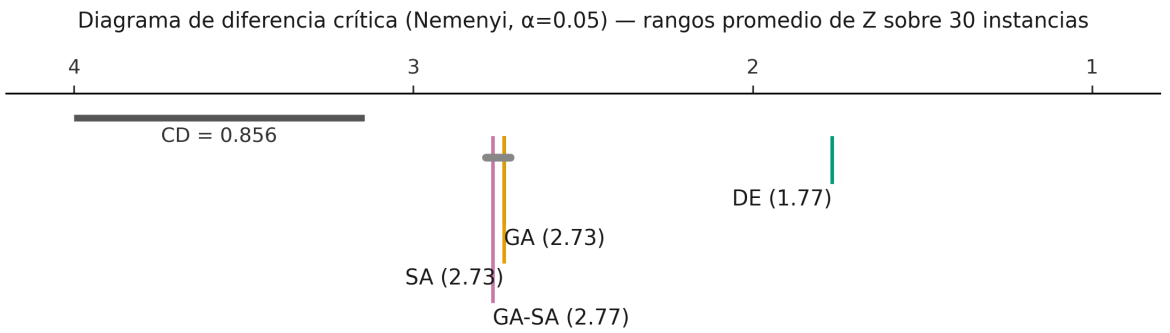
Diseño v2 (780 corridas)

- **30 instancias** (10 por tamaño) × 6 réplicas — unidad estadística: la instancia (n=30 vs n=9).
- **Economía operativa:** setup 50M COP/día, capacidad con holgura, demanda volátil → el óptimo apaga la línea 1–5 días.
- **Parvada mixta:** 30% liviano / 50% estándar / 20% pesado (α por perfil).
- **Presupuesto igualado:** 20,000 evaluaciones para las 4 MH (SA con reinicios).
- **Gap certificado:** CBC probó optimalidad en las 30 instancias (best bound).

Gap vs óptimo certificado

Tamaño	Baseline	GA	SA	DE	GA-SA
Small	9.88%	4.84%	**4.73%**	4.98%	4.76%
Medium	23.02%	5.02%	5.19%	**4.57%**	5.16%
Large	28.55%	5.59%	5.80%	**5.05%**	5.91%

El baseline se degrada con el horizonte (9.9%→28.6%); las 4 MH re-calibradas convergen a 4.6–5.9%. Friedman $p \le 0.03$ por estrato; Nemenyi: DE 1.77 (leve ventaja), GA/SA/GA-SA empatados 2.73–2.77 (CD=0.856).



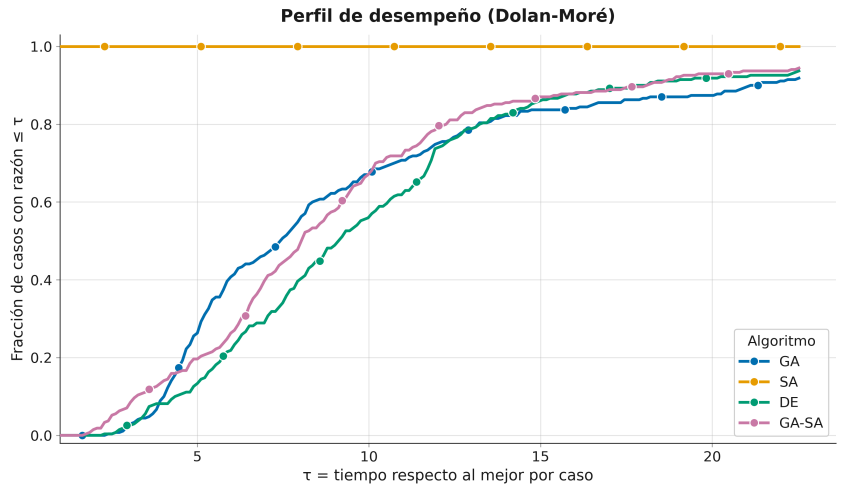
VEREDICTOS V2 (N=30, POTENCIA 1.000)

H1 SOPORTADA: mejora 20.2%–20.8% vs baseline ($p<10^{-4}$) · **H3 SOPORTADA:** inventario −28% a −31% · **H2:** GA-SA +0.54% vs mejor MH (≤2%). Con las 4 MH re-calibradas la paridad es el resultado: **elegir el algoritmo importa menos que calibrarlo para el régimen**. Anytime: DE alcanza el 99% del óptimo en 1.6/4.0/17.4 s (mediana; en large solo el 47% de corridas lo logra) — con CBC certificando el óptimo en 2/25/159 s.

Idea clave: donde el setup cuesta y hay holgura, optimizar rinde +20% de beneficio y −30% de inventario con potencia 1.000.

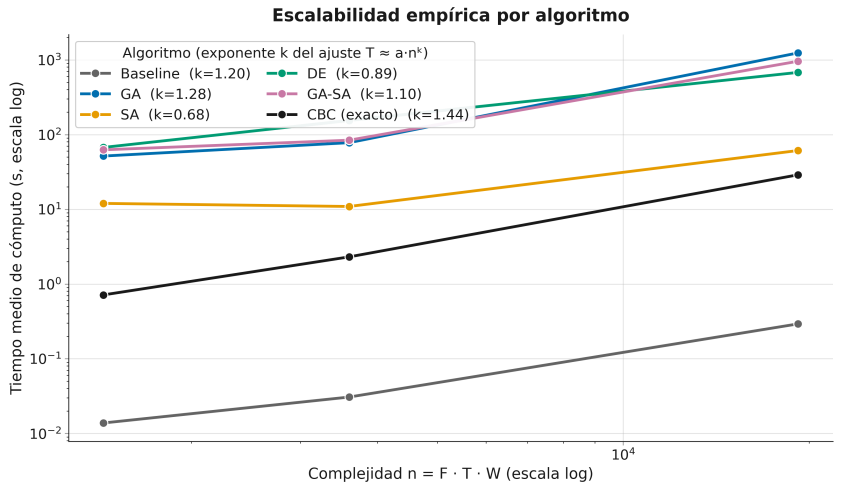
17. Escalabilidad (campaña diagnóstica, v1): rapidez y calidad no coinciden en un único algoritmo

Dolan-Moré: Performance Profile (Eficiencia/Tiempo)



El perfil de desempeño muestra dominancia de SA en tiempo puro y mejor calidad de GA-SA/DE. La lectura es multi-criterio: rapidez y calidad no coinciden en un único algoritmo.

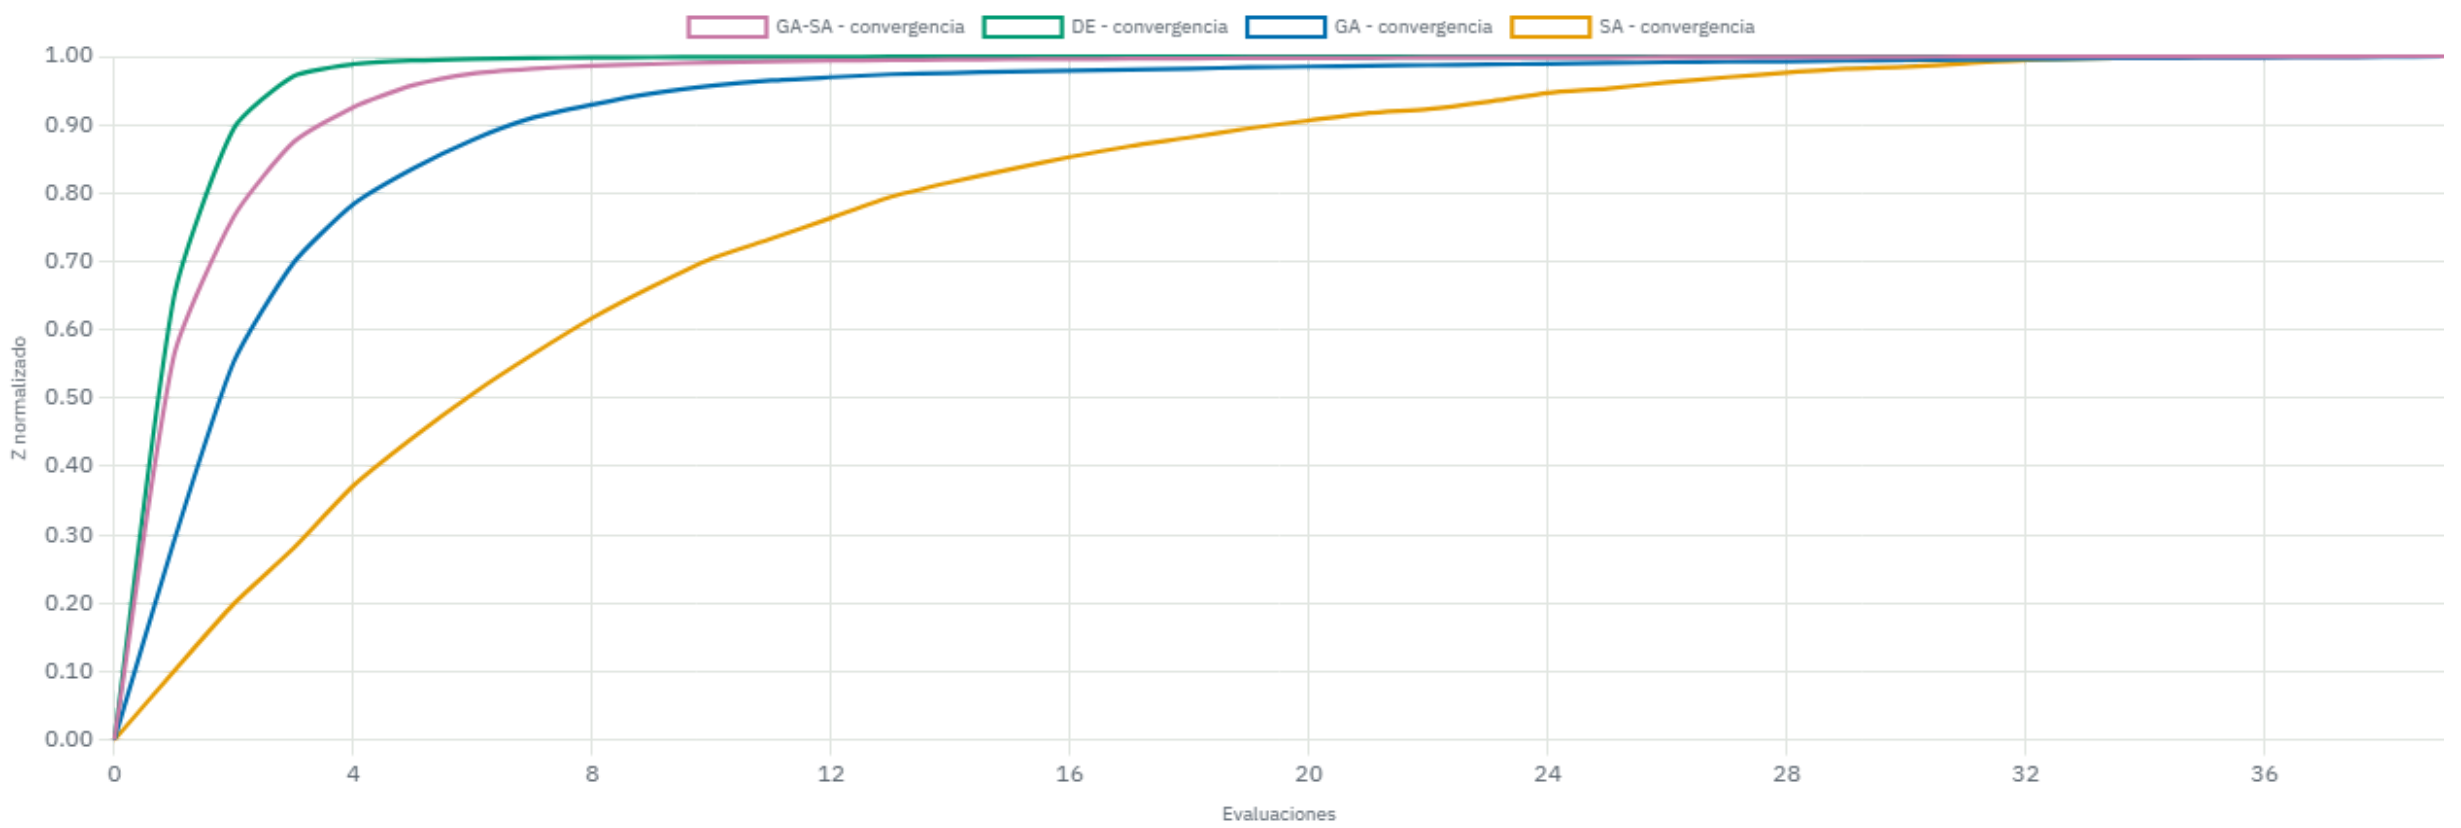
Cota Log-Log: Tiempo vs. Dimensión



Ajustes log-log por algoritmo: exponente empírico $k \in [0.68, 1.28]$. Con solo 3 tamaños, es evidencia indicativa de escalamiento sub-cuadrático, no una ley definitiva.

Idea clave: SA domina en tiempo puro y GA-SA/DE en calidad — la elección depende del presupuesto de cómputo disponible.

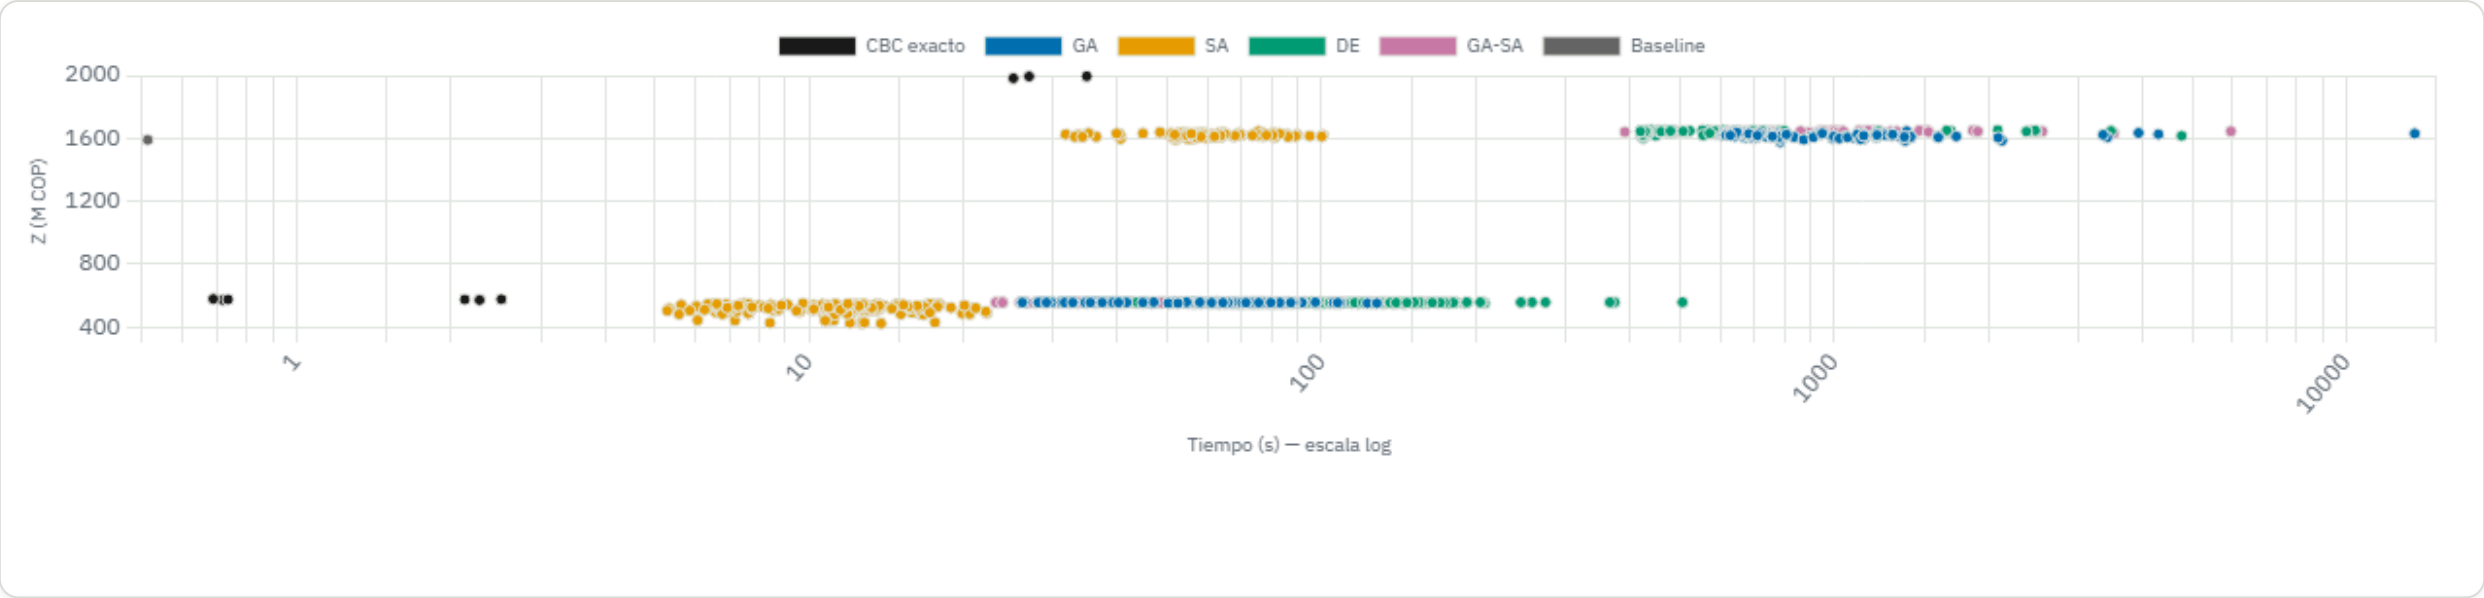
18. Convergencia (v1): la ganancia llega en las primeras evaluaciones



Trazas de convergencia reales — campaña diagnóstica (v1), 1,098 corridas.

Idea clave: el grueso de la mejora se obtiene en las primeras evaluaciones — comportamiento anytime útil para decidir en segundos.

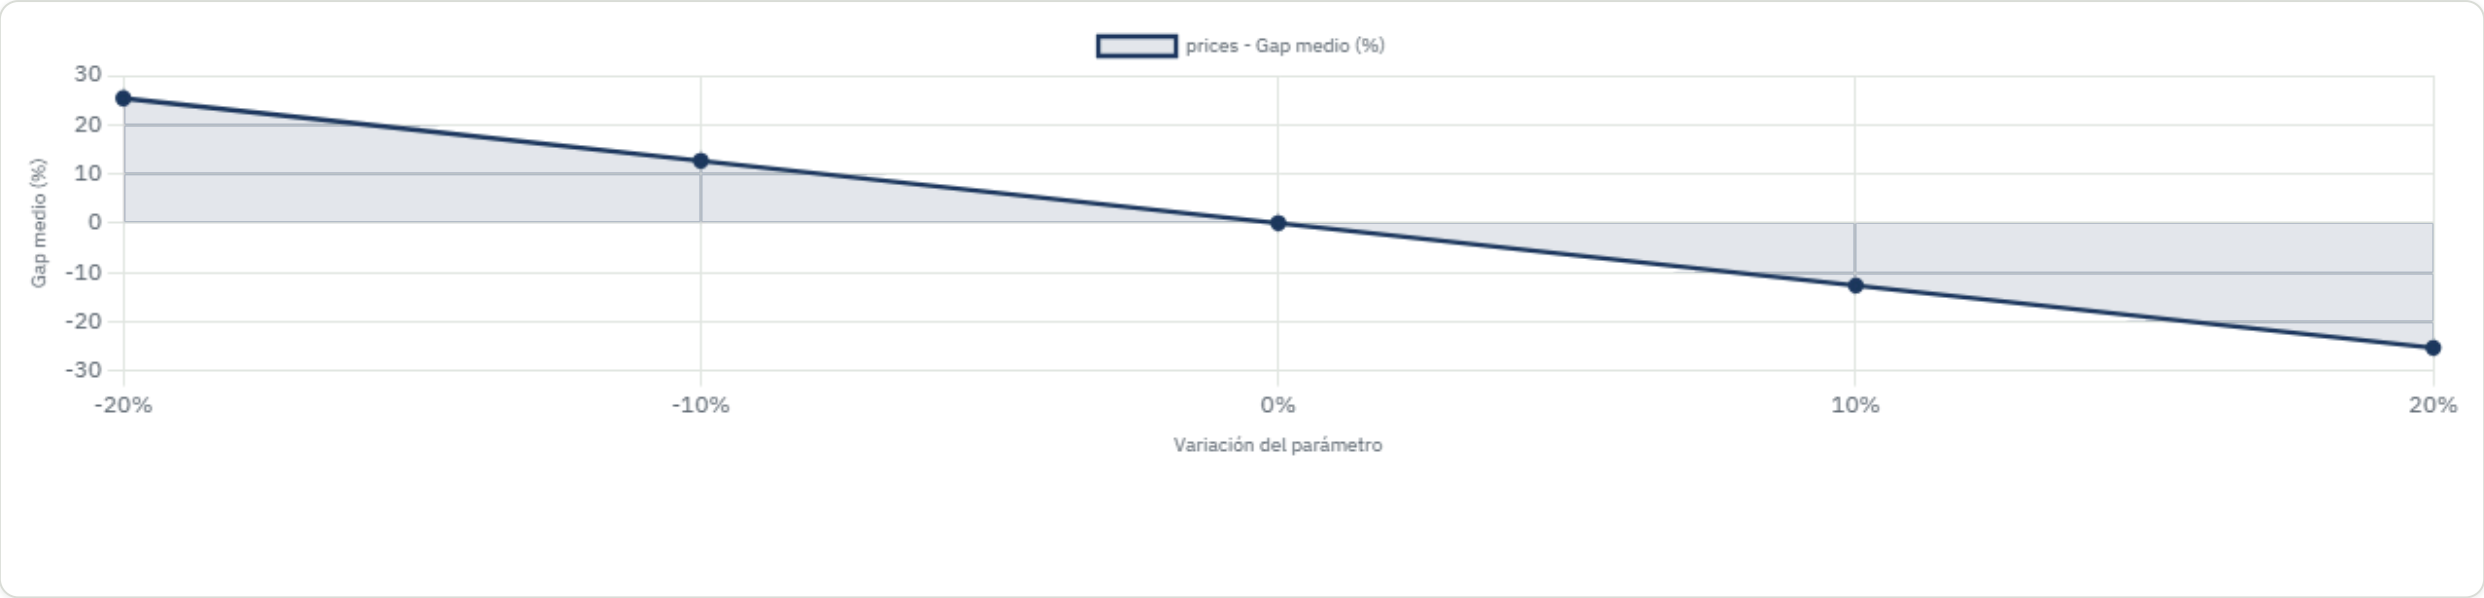
19. Frontera de Pareto (v1): ninguna corrida domina calidad y tiempo a la vez



Cada punto representa una corrida; filtros en vivo por tamaño y algoritmo.

Idea clave: la frontera calidad-cómputo es el mapa para elegir algoritmo según el tiempo disponible en operación.

20. Sensibilidad (v1): 100% de factibilidad bajo estrés de parámetros



Factibilidad 100% en sensibilidad y respuesta consistente ante variaciones.

Idea clave: los precios mueven el resultado (±12.7%) más que la variabilidad de la demanda (±0.35%) — y la factibilidad nunca se pierde.

IV

Qué significa

«El valor depende del régimen; la calibración pesa más que el algoritmo».

21. Limitaciones: qué afirma este estudio y qué no

Limitaciones Metodológicas

1. **Datos sintéticos:** Instancias calibradas con FENAVI/DANE, pero no son datos operativos reales de planta. La correlación temporal sin desfase es baja ($|\rho| \approx 0.19$); con lags mejora a $|\rho_{lag}| \approx 0.65$.
2. **Baseline fuerte:** Producir a Q^{max} resulta ser casi óptimo cuando demanda > capacidad, reduciendo el margen de mejora de MH.
3. **Proporciones fijas:** Se asume α_p constante; no se modela variabilidad inter-lote en rendimiento de carcasa.

Limitaciones Técnicas

4. **Sin scheduling:** Solo se aborda lot-sizing diario; no el scheduling detallado de la línea de despiece.
5. **Perecibilidad simplificada:** Vida útil discreta (FIFO) sin deterioro gradual de calidad.

Implicación: Estas limitaciones no invalidan los hallazgos, pero definen el alcance de generalidad. La validación con datos operativos reales de planta sigue siendo necesaria.

Idea clave: los hallazgos son válidos dentro de su alcance declarado; la validación con datos de planta sigue pendiente.

22. El valor de la optimización depende del régimen

OE1 (Formular): Modelo MILP multi-periodo validado con CBC (óptimo certificado en todos los tamaños; ≈1,100–58,000 variables).

OE2 (Implementar): GA, SA, DE, GA-SA con reparación de factibilidad y convergencia.

OE3 (Calibrar): 30 trials Optuna por algoritmo, evaluados en 5 instancias de calibración.

OE4 (Comparar): dos campañas (1,098 + 780 ejecuciones, la segunda con las 4 MH re-calibradas y presupuesto igualado). En la confirmatoria las 4 convergen a 4.6–5.9% de gap (Nemenyi: DE 1.77 con leve ventaja; GA/SA/GA-SA empatados).

OE5 (Validar): Sensibilidad estable (precios ±12.67%, demanda ±0.35% en gap) y validación externa FENAVI útil: correlación mensual baja sin desfase, pero mejora al considerar lags temporales.

Hallazgo principal: el valor de la optimización depende del régimen económico. Con setup marginal y demanda > capacidad, producir a Q^{max} es casi óptimo; en el régimen operativo (setup costoso, holgura, volatilidad), las metaheurísticas mejoran el beneficio ~20% y reducen inventario 28–31% ($p<10^{-4}$); re-calibradas, las cuatro convergen a ~5% de gap — calibrar para el régimen importa más que elegir el algoritmo — y alcanzan el 99% del óptimo antes de que CBC certifique.

Idea clave: la pregunta correcta no es «¿qué algoritmo gana?» sino «¿en qué régimen opera la planta y cómo calibrar para él?».

23. Contribuciones: un benchmark reproducible y una regla de decisión

Contribuciones

1. Modelo MILP original para coproductos avícolas con perecibilidad.
2. Framework comparativo con 4 metaheurísticas y baseline riguroso.
3. Evidencia empírica sobre metaheurísticas híbridas: bajo calibración justa por régimen, las cuatro estrategias alcanzan paridad (leve ventaja de DE) — la superioridad del híbrido reportada por Akbari-Aghghaleh et al. (2025) resulta dependiente de la calibración.
4. Conjunto de 39 instancias calibradas (FENAVI/DANE) en dos regímenes económicos, con perfiles de pollo mezclables en parvada.
5. Caracterización del régimen de valor: cuándo basta una regla trivial y cuándo la optimización aporta ~20% de beneficio (hasta 219M COP por horizonte en instancias grandes).
6. Código abierto Python reproducible con tests y pipeline Pandoc→PDF.

Trabajo Futuro

- **Híbrido DE-SA:** Evaluar combinación DE + SA local (Akbari-Aghghaleh 2025).
- **Multi-objetivo:** NSGA-II/MOEA-D (costo vs nivel de servicio).
- **Datos reales:** Validación con datos operativos de planta procesadora.
- **Scheduling integrado:** Lot-sizing + programación detallada (Claassen 2016).
- **Aprendizaje por refuerzo:** Deep RL para ajuste dinámico de hiperparámetros (Tan et al. 2026; Wang et al. 2026).
- **Rolling horizon:** Planificación semanal + integración ERP/MRP.

Idea clave: 39 instancias calibradas, dos regímenes caracterizados y código abierto dejan un benchmark listo para extenderse.

GRACIAS POR SU ATENCIÓN

¿Preguntas?

Daniel Andrés Castañeda Rodríguez

Directora: PhD. Eliana Mirledy Ocampo Toro

Universidad Tecnológica de Pereira

Material de respaldo

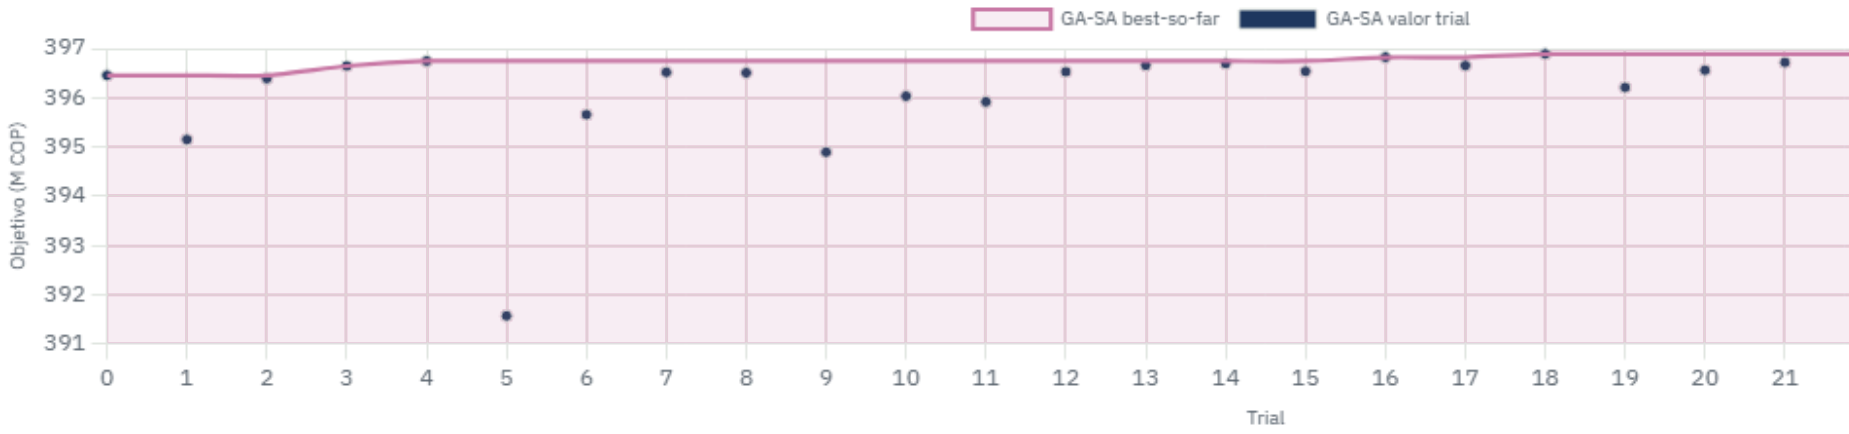
«para preguntas del jurado»

Respaldo: Trazabilidad de hiperparámetros — calibración diagnóstica (v1), re-calibrada en la confirmatoria (v2)

Hiperparámetros Óptimos (Tabla 5 tesis)

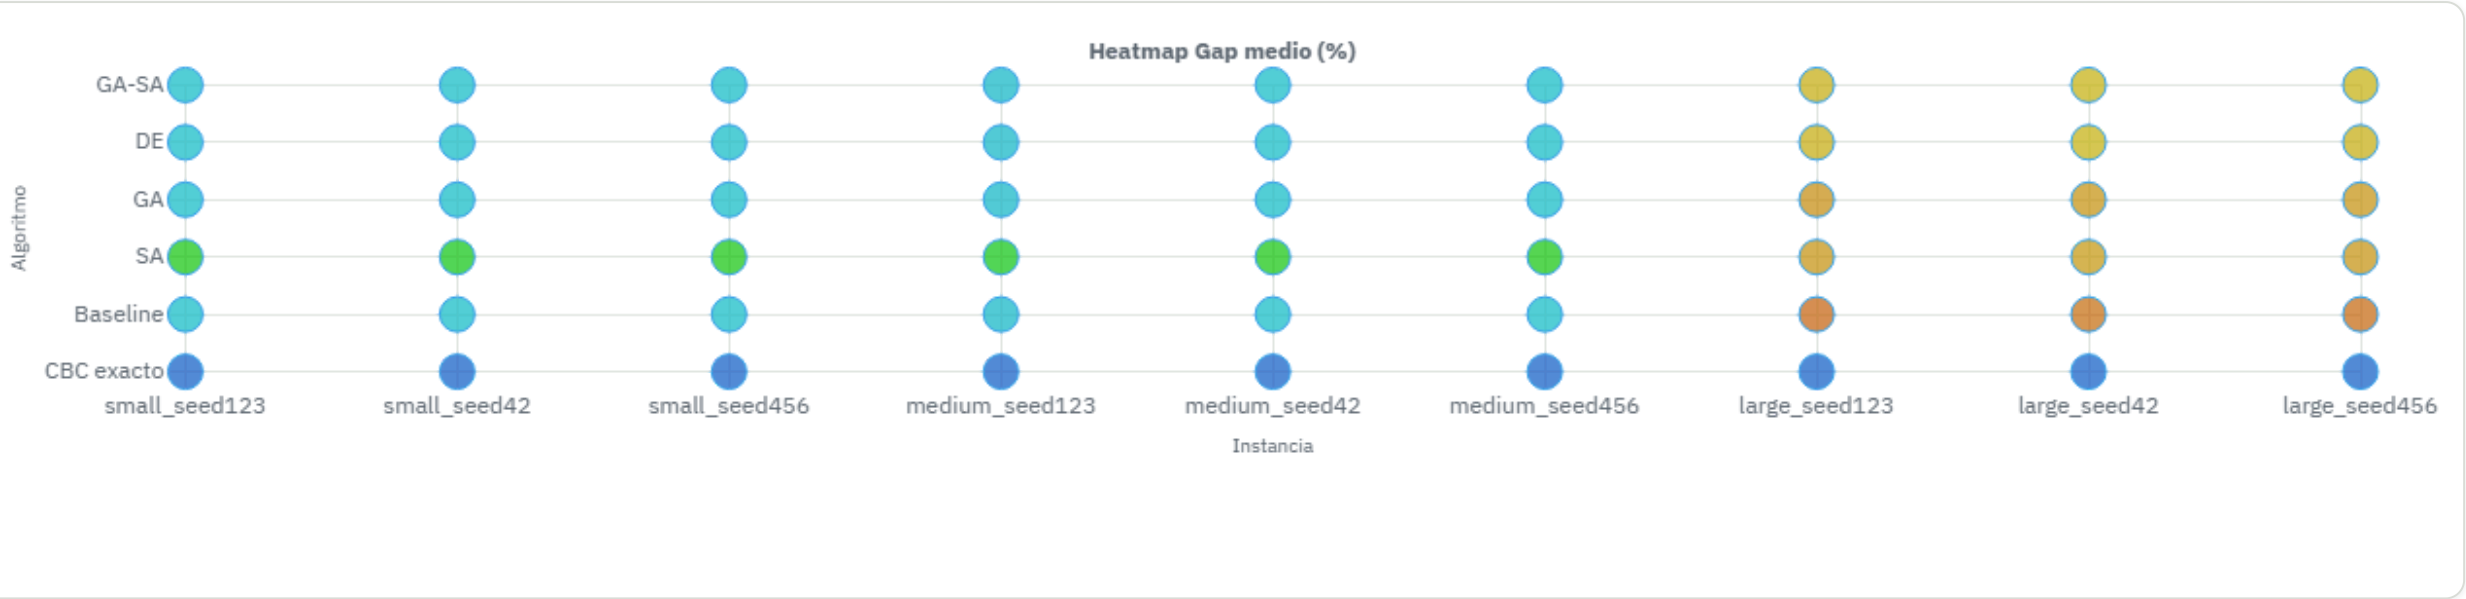
Parámetro	GA	SA	DE	GA-SA
pop_size	80	—	51	39
crossover_rate	0.744	—	—	0.859
mutation_rate	0.089	—	—	0.051
T_0 / cooling	—	203,952 / 0.782	—	—
F (scale) / CR	—	—	0.317 / 0.511	—
LS freq / top_k	—	—	—	9 / 10
stagnation_limit	50	54	50	50

30 trials × 5 instancias calibración × timeout 900 s/trial. Tabla completa en anexo de la tesis.



Idea clave: cada hiperparámetro final es trazable a sus 30 trials de Optuna — la calibración es auditable, no una caja negra.

Respaldo: Superficie analítica de desempeño (heatmap, campaña diagnóstica v1)



Vista matricial interactiva por combinación algoritmo-instancia (promedios de corridas).

Idea clave: la vista matricial localiza en qué instancias concretas se concentran los gaps y los tiempos altos.

Respaldo: Dinámica del inventario de baja rotación (campaña diagnóstica v1)



Caja intercuartil (Q25-Q75), mediana y bigotes P10-P90 por algoritmo.

Idea clave: el inventario de baja rotación concentra el riesgo de perecibilidad; su distribución distingue a los algoritmos.

Respaldo: Robustez operativa de la arquitectura (campaña diagnóstica v1)

Checklist técnico

- Reparación de factibilidad (y,q) en GA, SA, DE y GA-SA.
- Registro de convergencia en todos los algoritmos.
- Control por estancamiento en GA, DE y GA-SA.
- Factibilidad empírica: 100% en comparación y sensibilidad.

Alertas de validez

Indicadores operativos

