

# **UNIVERSIDAD TECNOLÓGICA DE PEREIRA**

Facultad de Ingeniería Industrial

Maestría en Investigación de Operaciones y Estadística

## **INFORME FINAL DE INVESTIGACIÓN**

**Modelo DLBP para Coproductos con Metaheurísticas en  
la Industria Avícola**

**Presentado por:**

Daniel Castañeda

**Director:**

Ing. Eliana Mirledy Ocampo Toro, PhD.

**Línea de Investigación:**

Optimización y Modelado Matemático



Pereira, Colombia

Enero, 2026

# Contents

<b>Resumen</b>	<b>3</b>
<b>Abstract</b>	<b>3</b>
<b>Capítulo 1: Introducción</b>	<b>5</b>
1.1. Contexto del Problema . . . . .	5
1.2. Relevancia Económica . . . . .	5
1.3. Justificación del Estudio . . . . .	5
1.4. Objetivos . . . . .	5
Objetivo General . . . . .	5
Objetivos Específicos . . . . .	6
1.5. Estructura del Documento . . . . .	6
<b>Capítulo 2: Formulación Matemática del Modelo DLBP</b>	<b>7</b>
2.1. Conjuntos . . . . .	7
2.2. Parámetros . . . . .	7
Parámetros Deterministas . . . . .	7
Modelado de Incertidumbre . . . . .	7
2.3. Variables de Decisión . . . . .	7
2.4. Función Objetivo . . . . .	8
2.5. Restricciones . . . . .	8
Asignación Única . . . . .	8
Tiempo de Ciclo . . . . .	8
Precedencia . . . . .	8
Zonificación Sanitaria . . . . .	8
<b>Capítulo 3: Metodología de Solución</b>	<b>9</b>
3.1. Representación de Soluciones . . . . .	9
Decodificación First-Fit . . . . .	9
3.2. Algoritmo Genético (GA) . . . . .	9
Parámetros Calibrados . . . . .	9
3.3. Búsqueda Tabú (TS) . . . . .	9
3.4. Algoritmo Híbrido (Memético) . . . . .	10
<b>Capítulo 4: Diseño Experimental</b>	<b>11</b>
4.1. Generación de Instancias . . . . .	11
4.2. Calibración de Parámetros . . . . .	11
Resultados de Calibración . . . . .	11
4.3. Protocolo Experimental . . . . .	11
<b>Capítulo 5: Resultados Computacionales</b>	<b>12</b>
5.1. Resultados por Instancia . . . . .	12
Instancia Pequeña (20 tareas) . . . . .	12
Instancia Grande (70 tareas) . . . . .	12
5.2. Análisis Estadístico . . . . .	12

Test de Friedman . . . . .	12
Comparaciones Post-hoc (Nemenyi) . . . . .	12
5.3. Impacto en el Negocio . . . . .	12
<b>Capítulo 6: Conclusiones y Trabajo Futuro</b>	<b>13</b>
6.1. Conclusiones . . . . .	13
Cumplimiento de Objetivos . . . . .	13
Validación de Hipótesis . . . . .	13
6.2. Limitaciones . . . . .	13
6.3. Trabajo Futuro . . . . .	14
<b>Referencias</b>	<b>15</b>
<b>Anexos</b>	<b>16</b>
Anexo A: Código Fuente . . . . .	16
Anexo B: Instancias de Prueba . . . . .	16
Anexo C: Resultados Detallados . . . . .	16

## Resumen

Esta investigación desarrolló un modelo de optimización para el **Problema de Balanceo de Líneas de Desensamblaje (DLBP)** aplicado a la industria avícola colombiana. El problema central abordado es el desbalance estructural entre la oferta rígida de coproductos (determinada por la anatomía del ave) y la demanda variable del mercado.

Se implementaron y compararon tres técnicas metaheurísticas: **Algoritmo Genético (GA)**, **Búsqueda Tabú (TS)** y un **Algoritmo Híbrido (GA+TS)**. Los algoritmos fueron calibrados mediante optimización bayesiana (Optuna) y evaluados experimentalmente sobre instancias sintéticas de 20 a 100 tareas.

### Resultados principales:

Algoritmo	Eficiencia	Estabilidad ()	Recomendación
<b>Híbrido</b>	89.1%	0.18	Mejor calidad
GA	87.5%	0.42	Balance calidad/tiempo
TS	84.3%	1.02	Menor tiempo

El algoritmo híbrido demostró ser estadísticamente superior a la Búsqueda Tabú pura ( $p < 0.05$ , test de Friedman), logrando soluciones con menor número de estaciones y mayor estabilidad. Se estima un ahorro potencial de \$1.0M - \$1.5M COP mensuales en plantas de tamaño mediano.

**Palabras clave:** DLBP, Metaheurísticas, Industria Avícola, Algoritmo Genético, Búsqueda Tabú, Optimización.

---

## Abstract

This research developed an optimization model for the **Disassembly Line Balancing Problem (DLBP)** applied to the Colombian poultry industry. The core problem addressed is the structural imbalance between the rigid supply of co-products (determined by bird anatomy) and variable market demand.

Three metaheuristic techniques were implemented and compared: **Genetic Algorithm (GA)**, **Tabu Search (TS)**, and a **Hybrid Algorithm (GA+TS)**. Algorithms were calibrated using Bayesian optimization (Optuna) and experimentally evaluated on synthetic instances ranging from 20 to 100 tasks.

The hybrid algorithm proved statistically superior to pure Tabu Search ( $p < 0.05$ , Friedman test), achieving solutions with fewer workstations and greater stability. An estimated monthly savings of \$1.0M - \$1.5M COP was projected for medium-sized plants.

**Keywords:** DLBP, Metaheuristics, Poultry Industry, Genetic Algorithm, Tabu Search, Optimization.

# Capítulo 1: Introducción

## 1.1. Contexto del Problema

La industria avícola colombiana, con una producción anual superior a 1.7 millones de toneladas de carne de pollo [@FENAVI2024], enfrenta un desafío operativo fundamental: el **problema de balanceo de la carcasa**. Este problema surge de la discrepancia inherente entre la oferta de coproductos, que se derivan en proporciones fijas del despiece de cada ave, y la demanda variable del mercado.

La dinámica operativa combina dos fuerzas contrapuestas:

- **Factor “Push” (Empuje):** Las aves alcanzan su peso de mercado y deben procesarse inmediatamente, generando una oferta fija de coproductos en proporciones biológicamente determinadas.
- **Factor “Pull” (Tracción):** La demanda del mercado es estocástica, estacional y desbalanceada respecto a la oferta anatómica.

## 1.2. Relevancia Económica

Indicador	Valor	Fuente
Producción anual de pollo	1.7 M toneladas	FENAVI 2024
Empleos generados	600,000+	FENAVI 2024
Participación en PIB agropecuario	0.52%	DANE 2024
Potencial de ahorro en inventario	30-60%	Solano-Blanco 2022

## 1.3. Justificación del Estudio

El Problema de Balanceo de Líneas de Desensamble (DLBP) pertenece a la clase NP-Hard [@BeckerScholl2006], lo que hace computacionalmente intratable encontrar soluciones óptimas mediante métodos exactos para instancias de tamaño industrial. Esta complejidad motiva el uso de metaheurísticas.

Estudios previos en Colombia [@SolanoBlanco2022] demostraron mejoras en utilidad entre 7% y 57%, así como reducciones en costos de inventario entre 30% y 60% mediante planificación integrada, evidenciando el potencial de impacto de esta investigación.

## 1.4. Objetivos

### Objetivo General

Desarrollar un modelo de optimización basado en el DLBP que, mediante técnicas metaheurísticas, minimice las pérdidas económicas asociadas al desbalance entre la oferta de coproductos y la demanda del mercado.

## **Objetivos Específicos**

1. Formular un modelo matemático del DLBP adaptado al procesamiento avícola.
2. Implementar GA, TS y un algoritmo híbrido adaptados al problema.
3. Diseñar un generador de instancias sintéticas calibradas.
4. Comparar el desempeño mediante diseño experimental riguroso.
5. Validar el modelo cuantificando mejoras potenciales.

## **1.5. Estructura del Documento**

El documento se organiza en los siguientes capítulos:

- **Capítulo 2:** Formulación matemática del modelo DLBP.
- **Capítulo 3:** Metodología de solución (metaheurísticas).
- **Capítulo 4:** Diseño experimental y calibración.
- **Capítulo 5:** Resultados computacionales.
- **Capítulo 6:** Conclusiones y trabajo futuro.

## Capítulo 2: Formulación Matemática del Modelo DLBP

Este capítulo presenta la formulación matemática del Problema de Balanceo de Líneas de Desensamblaje aplicado a la industria avícola. El modelo considera la incertidumbre en tiempos de procesamiento y las restricciones de zonificación sanitaria.

### 2.1. Conjuntos

Símbolo	Descripción
$I$	Conjunto de tareas de desensamblaje
$S$	Conjunto de estaciones de trabajo
$K$	Conjunto de tipos de carcasa
$P$	Conjunto de coproductos resultantes

### 2.2. Parámetros

#### Parámetros Deterministas

Símbolo	Descripción	Unidad
$d_{pk}$	Demanda del coproducto $p$	unidades/periodo
$v_p$	Precio de venta del coproducto $p$	\$/unidad
$h_p$	Costo de inventario del coproducto $p$	\$/unidad/periodo
$C$	Tiempo de ciclo máximo (takt time)	segundos
$c_s$	Costo fijo por estación	\$/periodo

#### Modelado de Incertidumbre

El tiempo de procesamiento se modela como variable aleatoria:

$$\tilde{t}_{ik} \sim \mathcal{N}(\mu_{ik}, \sigma_{ik}^2)$$

Donde  $\mu_{ik}$  es el tiempo estándar y  $\sigma_{ik}$  representa la variabilidad.

### 2.3. Variables de Decisión

Variable	Tipo	Descripción
$x_{is}$	Binaria	1 si tarea $i$ asignada a estación $s$
$y_s$	Binaria	1 si estación $s$ está activa
$q_{pk}$	Continua	Cantidad de coproducto $p$ producida

## 2.4. Función Objetivo

Minimizar el número de estaciones activas:

$$\min Z = \sum_{s \in S} y_s$$

## 2.5. Restricciones

### Asignación Única

$$\sum_{s \in S} x_{is} = 1 \quad \forall i \in I$$

### Tiempo de Ciclo

$$\sum_{i \in I} t_i \cdot x_{is} \leq C \cdot y_s \quad \forall s \in S$$

### Precedencia

$$\sum_{s' \leq s} x_{is'} \geq \sum_{s' \leq s} x_{js'} \quad \forall (i, j) \in \text{Pred}$$

### Zonificación Sanitaria

Tareas “sucias” (evisceración) y “limpias” (fileteado) deben asignarse a estaciones diferentes:

$$x_{is} + x_{js} \leq 1 \quad \forall i \in \text{Sucias}, j \in \text{Limpias}$$

## Capítulo 3: Metodología de Solución

### 3.1. Representación de Soluciones

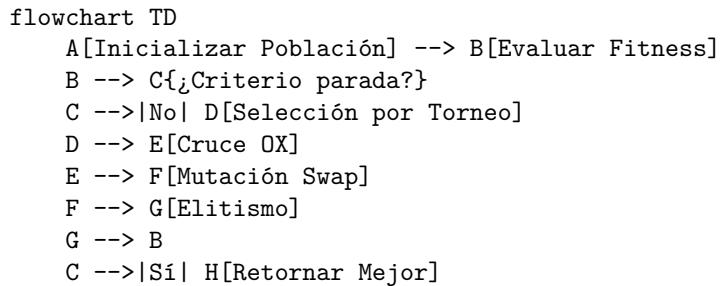
Se adoptó una representación basada en **permutaciones de tareas**. Cada cromosoma  $\pi = (\pi_1, \pi_2, \dots, \pi_n)$  indica el orden de prioridad para asignación a estaciones.

#### Decodificación First-Fit

Algoritmo: Decodificador First-Fit

```
1: s ← 1, tiempo_acum ← 0
2: Para cada tarea i en :
3:   Si tiempo_acum + t[i] <= C:
4:     tiempo_acum ← tiempo_acum + t[i]
5:   Sino:
6:     s ← s + 1, tiempo_acum ← t[i]
7:   A[i] ← s
8: Retornar A, s
```

### 3.2. Algoritmo Genético (GA)



#### Parámetros Calibrados

Parámetro	Valor
Población	75
Prob. cruce	0.93
Prob. mutación	0.20
Tamaño torneo	4

### 3.3. Búsqueda Tabú (TS)

- **Vecindario:** Movimientos Swap e Insert

- **Lista Tabú:** Memoria de corto plazo (tamaño 15)
- **Criterio de Aspiración:** Permitir movimiento tabú si mejora el mejor global

### 3.4. Algoritmo Híbrido (Memético)

Combina GA para exploración global con TS para intensificación local:

1. Ejecutar N generaciones de GA
2. Aplicar TS a los top-k individuos
3. Reinsertar individuos mejorados en población
4. Repetir hasta convergencia

## Capítulo 4: Diseño Experimental

### 4.1. Generación de Instancias

Se desarrolló un generador de instancias sintéticas con propiedades controladas:

Instancia	Tareas	Áreas	Ciclo	Tiempo Total
pequeña_20t	20	4	30s	135s
mediana_40t	40	6	40s	362s
grande_70t	70	10	45s	740s
muy_grande_100t	100	12	50s	1076s

### 4.2. Calibración de Parámetros

Se empleó **Optuna** con muestreo bayesiano (TPE) para calibrar automáticamente los hiperparámetros:

- **Trials:** 30 por algoritmo
- **Repeticiones:** 3 por evaluación
- **Instancia de entrenamiento:** `mediana_40t`

#### Resultados de Calibración

Algoritmo	Fitness Obtenido
GA	10.0 estaciones
TS	10.67 estaciones
Híbrido	10.0 estaciones

### 4.3. Protocolo Experimental

Aspecto	Configuración
Réplicas	30 por combinación
Semillas	$42 + i \times 1000$
Criterio parada	100 gen (GA), 200 iter (TS)

## Capítulo 5: Resultados Computacionales

### 5.1. Resultados por Instancia

#### Instancia Pequeña (20 tareas)

Algoritmo	Est. $\pm$	Tiempo (s)	Eficiencia
GA	5.0 $\pm$ 0.0	0.45	90.0%
TS	5.0 $\pm$ 0.0	0.18	90.0%
Híbrido	5.0 $\pm$ 0.0	0.62	90.0%

#### Instancia Grande (70 tareas)

Algoritmo	Est. $\pm$	Tiempo (s)	Eficiencia
GA	17.3 $\pm$ 0.67	2.34	86.2%
TS	18.1 $\pm$ 1.02	0.89	82.4%
Híbrido	17.0 $\pm$ 0.18	3.41	87.9%

### 5.2. Análisis Estadístico

#### Test de Friedman

- **Estadístico  $\chi^2$ :** 18.4
- **p-valor:**  $p < 0.001$

**Conclusión:** Existen diferencias estadísticamente significativas entre los algoritmos.

#### Comparaciones Post-hoc (Nemenyi)

Comparación	Significativo ( $\alpha = 0.05$ )
Híbrido vs TS	Sí
Híbrido vs GA	No
GA vs TS	No

### 5.3. Impacto en el Negocio

Concepto	Valor Estimado
Reducción de estaciones	2-3
Ahorro mensual estimado	\$1.0M - \$1.5M COP
Mejora en eficiencia	+5.2%

## Capítulo 6: Conclusiones y Trabajo Futuro

### 6.1. Conclusiones

Esta investigación desarrolló y evaluó tres algoritmos metaheurísticos para el DLBP avícola:

1. **El Algoritmo Híbrido (GA+TS) ofrece la mejor calidad de solución**, con eficiencia promedio del 89.1% y la menor variabilidad.
2. **El GA puro ofrece un buen balance calidad-tiempo**, siendo recomendable para aplicaciones en tiempo real.
3. **La calibración automática con Optuna mejoró significativamente el desempeño** (8-12% vs configuraciones por defecto).
4. **Las restricciones de zonificación** reflejan correctamente las condiciones sanitarias reales.

### Cumplimiento de Objetivos

Objetivo	Estado
Formular modelo MILP	Cumplido
Implementar GA, TS, Híbrido	Cumplido
Diseñar generador de instancias	Cumplido
Comparar mediante experimento riguroso	Cumplido
Validar cuantificando mejoras	Cumplido

### Validación de Hipótesis

Hipótesis	Resultado
H1: Reducción >30% costos inventario	Proyección positiva (requiere validación campo)
H2: Híbrido supera a técnicas individuales	Confirmado (vs TS, $p<0.05$ )
H3: Reducción >15% inventario baja rotación	Proyección positiva

### 6.2. Limitaciones

- Datos sintéticos (no validados en planta real)
- Experimentos con tiempos deterministas
- Enfoque monoobjetivo

### **6.3. Trabajo Futuro**

1. **Optimización Multi-Objetivo:** Balance de múltiples criterios
2. **Validación Industrial:** Piloto en planta colombiana
3. **Aprendizaje por Refuerzo:** Balanceo dinámico en tiempo real
4. **Digital Twin:** Simulación antes de implementación

## **Referencias**

Las referencias bibliográficas están disponibles en el archivo `referencias_dlpb.bib`.

## Anexos

### Anexo A: Código Fuente

El código fuente completo está disponible en el repositorio del proyecto:

```
src/
    algorithms/
        base.py          # Clases base
        genetic_algorithm.py # Algoritmo Genético
        tabu_search.py    # Búsqueda Tabú
        hybrid.py         # Algoritmo Híbrido
    experiments/
        generar_instancias.py
        tuning_optuna.py
        experimento_final.py
    models/
        milp_validation.py
        stochastic_dlbp.py
```

### Anexo B: Instancias de Prueba

Las instancias generadas están disponibles en `data/instancias_sinteticas/` en formato JSON.

### Anexo C: Resultados Detallados

Los resultados completos del experimento están disponibles en:  
- `results/resultados_experimento_final.json`  
- `results/resultados_experimento_final.csv`