Modelo de Optimización para la Planificación de Coproductos con Metaheurísticas en la Industria Avícola

Daniel Andrés Castañeda Rodríguez



Universidad Tecnológica de Pereira

Maestría en Investigación de Operaciones y Estadística

2026

UNIVERSIDAD TECNOLÓGICA DE PEREIRA

Facultad de Ingeniería Industrial

Maestría en Investigación de Operaciones y Estadística

TRABAJO DE GRADO

Modelo de Optimización para la Planificación de Coproductos con Metaheurísticas en la Industria Avícola

Presentado por:

Daniel Andrés Castañeda Rodríguez

Directora:

Ing. Eliana Mirledy Ocampo Toro, PhD.

Línea de Investigación:

Optimización y Modelado Matemático

Pereira, Colombia

2026

Agradecimientos

A mi directora de tesis, la Dra. Eliana Mirledy Ocampo Toro, por su guía académica, paciencia y dedicación a lo largo de este proceso investigativo. Su rigor metodológico y visión estratégica fueron fundamentales para la culminación de este trabajo.

A la Universidad Tecnológica de Pereira y la Maestría en Investigación de Operaciones y Estadística, por brindarme las herramientas y el espacio de formación para desarrollar esta investigación.

A mi familia, por su apoyo incondicional y comprensión durante las largas jornadas de trabajo dedicadas a este proyecto.

A mis compañeros de la maestría, por las discusiones enriquecedoras y el acompañamiento mutuo durante este camino académico.

Resumen

Este trabajo presenta el desarrollo de un modelo de optimización para la planificación de coproductos en la industria avícola colombiana, resuelto mediante técnicas metaheurísticas. El problema central aborda el desbalance estructural entre la oferta rígida de coproductos —determinada por la anatomía del ave— y la demanda variable del mercado. Se formula un modelo de Programación Lineal Entera Mixta (MILP) multi-periodo con estructura de lot-sizing estocástico, incluyendo decisiones binarias de setup, lote mínimo y restricciones de perecibilidad. Debido a la complejidad NP-hard del problema, se implementan y comparan cuatro metaheurísticas: Algoritmo Genético (GA), Recocido Simulado (SA), Evolución Diferencial (DE) y un algoritmo híbrido GA-SA. Los algoritmos se calibraron mediante el sampler TPE de Optuna y se evaluaron en dos campañas experimentales (1,098 y 780 ejecuciones, esta última con presupuesto de evaluaciones igualado) sobre 39 instancias sintéticas calibradas con datos del sector avícola colombiano, correspondientes a dos regímenes económicos. Los resultados muestran que el valor de la optimización depende del régimen: cuando el costo de setup es marginal y la demanda supera la capacidad, una regla trivial es casi óptima; en el régimen operativo (setup costoso, holgura de capacidad y demanda volátil), las metaheurísticas mejoran el beneficio en 17–20 % y reducen el inventario en 21–29 % frente al baseline ($p < 10^{-4}$, potencia 1.000), con el híbrido GA-SA como mejor algoritmo en todos los tamaños (gap de 4.9–5.8 % frente al óptimo certificado por CBC) y calidad estadísticamente equivalente a la mejor metaheurística individual. La solución fue validada operativamente, demostrando robustez ante perturbaciones de ± 10 % en la demanda con un deterioro máximo de 0.04 % en la función objetivo. El código fuente, instancias y resultados están disponibles públicamente en el repositorio del proyecto.

Palabras clave: optimización, coproductos, metaheurísticas, industria avícola, lot-sizing estocástico

Abstract

This work presents the development of an optimization model for co-product planning in the Colombian poultry industry, solved using metaheuristic techniques. The central problem addresses the structural imbalance between the rigid supply of co-products —determined by the anatomy of the bird— and the variable market demand. A multi-period Mixed-Integer Linear Programming (MILP) model with stochastic lot-sizing structure is formulated, including binary setup decisions, minimum lot constraints, and perishability restrictions. Due to the NP-hard complexity of the problem, four metaheuristics are implemented and compared: Genetic Algorithm (GA), Simulated Annealing (SA), Differential Evolution (DE), and a hybrid GA-SA algorithm. The algorithms were calibrated using Optuna's TPE sampler and evaluated in two experimental campaigns (1,098 and 780 runs, the latter with an equalized evaluation budget) over 39 synthetic instances calibrated with Colombian poultry industry data, spanning two economic regimes. Results show that the value of optimization is regime-dependent: when setup costs are marginal and demand exceeds capacity, a trivial rule is near-optimal; in the operating regime (costly setups, capacity slack, volatile demand), the metaheuristics improve profit by 17–20 % and reduce inventory by 21–29 % over the baseline ($p < 10^{-4}$, power 1.000), with the hybrid GA-SA as the best algorithm across all sizes (4.9–5.8 % gap to the CBC-certified optimum) and quality statistically equivalent to the best individual metaheuristic. The solution was operationally validated, demonstrating robustness against ± 10 % demand perturbations with a maximum deterioration of 0.04 % in the objective function. Source code, instances, and results are publicly available in the project repository.

Keywords: optimization, co-products, metaheuristics, poultry industry, stochastic lot-sizing

Índice

Agradecimientos 1
Resumen 2
Abstract 3
1. Introducción 8
1.1. El Problema de Producción Conjunta en la Industria Avícola 8
1.2. Relevancia Económica y Contexto Nacional 9
1.3. Preguntas de Investigación 10
1.4. Hipótesis de Investigación 10
1.5. Alcance y Limitaciones 11
2. Justificación 11
2.1. Conveniencia y Relevancia Económica 11
2.2. Relevancia Social y Ambiental (ODS 9, ODS 12) 12
2.3. Implicaciones Prácticas 13
2.4. Valor Teórico y Científico 13
3. Objetivos 14
3.1. Objetivo General 14
3.2. Objetivos Específicos 14
4. Marco Referencial 14
4.1. Marco Conceptual 14
4.2. Marco Teórico y Estado del Arte 16
4.3. Vacíos de Investigación Identificados 20
5. Formulación del Modelo Matemático 23
5.1. Conjuntos, Parámetros y Variables de Decisión 23
5.2. Función Objetivo 24
5.3. Restricciones 24
5.4. Estructura de Programación Estocástica de Dos Etapas 25
5.5. Validación con Solver Exacto (CBC) 25
6. Diseño e Implementación de Metaheurísticas 27
6.1. Representación Cromosómica 27
6.2. Operadores de Vecindad 29
6.3. Operadores Genéticos 30
6.4. Mecanismo de Reparación 32
6.5. Balance Exploración–Explotación del Espacio de Soluciones 32
6.6. Decodificador Greedy 34
6.7. Algoritmo Genético (GA) 34
6.8. Recocido Simulado (SA) 34
6.9. Evolución Diferencial (DE) 36
6.10. Algoritmo Híbrido GA-SA 36
6.11. Calibración de Hiperparámetros (Optuna/TPE) 36
7. Resultados Computacionales 37
7.1. Diseño Experimental (campaña v1) 37
7.2. Perfiles de Instancias 41
7.3. Resultados Principales (campaña v1) 41

7.4. Validación de Hipótesis (campaña v1) 42
7.5. Campaña Confirmatoria en Régimen Operativo (v2) 45
7.6. Performance Profiles 47
7.7. Convergence Profiles 47
7.8. Análisis de Escalabilidad 47
7.9. Análisis de Sensibilidad 47
7.10. Análisis de Diversidad Poblacional 49
7.11. Análisis de Complejidad Computacional 49
7.12. Discusión 49
7.13. Síntesis Gráfica de Resultados 51
8. Conclusiones y Trabajo Futuro 53
8.1. Conclusiones por Objetivo Específico 53
8.2. Veredicto de Hipótesis 54
8.3. Contribuciones Principales 54
8.4. Limitaciones del Estudio 55
8.5. Trabajo Futuro 55
Referencias 56
Anexos 59
Anexo A: Formulación Matemática Completa 59
Anexo B: Pseudocódigos de Algoritmos 59
Anexo C: Resultados Detallados por Instancia 59
Anexo D: Herramientas Tecnológicas 59

Lista de Figuras

1. Representación del problema como sistema de entrada/salida 8
2. Sistema global Push/Pull de la cadena avícola 9
3. Diagrama de intersección de brechas de investigación 22
4. Estructura de programación estocástica de dos etapas 26
5. Estructura del cromosoma como par de vectores 28
6. Representación visual del cromosoma 28
7. Representación visual de los tres operadores de vecindad 30
8. Posicionamiento de los cuatro algoritmos en el espectro exploración–explotación 33
9. Diagrama de flujo del Algoritmo Genético (GA) con operadores de cruce de dos puntos, mutación mixta y elitismo. 35
10. Diagrama de flujo del Recocido Simulado (SA) con enfriamiento geométrico, vecindarios mixtos y reheating adaptativo. 38
11. Diagrama de flujo de la Evolución Diferencial (DE) con estrategia DE/best/1/bin y codificación continua discretizada. 39
12. Diagrama de flujo del algoritmo híbrido GA-SA 40
13. Evolución del mejor fitness durante la calibración con Optuna/TPE para cada algoritmo 41
14. Distribución de fitness (Z) por algoritmo 42
15. Frente de Pareto calidad vs. tiempo computacional 44
16. Comparación del nivel de servicio (% de demanda satisfecha) por algoritmo. 44
17. Curvas anytime de la campaña v2 46
18. Diagrama de diferencia crítica de Nemenyi (campaña v2) 47
19. Performance profile de Dolan-Moré 47
20. Perfiles de convergencia normalizados 48
21. Escalabilidad empírica (gráfico log-log) 48
22. Perfiles de diversidad poblacional 50
23. Desglose del tiempo computacional por componente (cProfile) 50
24. Beneficio esperado Z por algoritmo y tamaño de instancia 51
25. Distribución de gaps respecto al solver exacto CBC 51
26. Diagrama tornado del análisis de sensibilidad 52
27. Curvas de convergencia promedio normalizadas 52
28. Comparación visual entre los umbrales definidos a priori y los resultados obtenidos 53

Lista de Tablas

1. Magnitud del problema en la industria avícola colombiana 12
2. Resultados de la búsqueda sistemática en Scopus (febrero 2026) 20
3. Resumen del estado del arte y brechas identificadas 21
4. Conteo de variables y restricciones por tamaño de instancia 24
5. Ejemplo de cromosoma para $n_t = 6$ 28
6. Ejemplo de aplicación de operadores de vecindad sobre un cromosoma con $n_t = 6$ 30
7. Ejemplo de cruce de dos puntos con $p_1 = 2$, $p_2 = 4$ 31
8. Clasificación de mecanismos según su contribución a exploración vs. explotación 32
9. Hiperparámetros calibrados por algoritmo (resultado de Optuna/TPE) . . . 36
10. Perfiles de instancias de prueba 41
11. Resultados principales por algoritmo (promedio sobre 270 ejecuciones c/u) . 42
12. Veredicto de hipótesis de investigación — campaña v1 42
13. Gap frente al óptimo certificado por algoritmo y tamaño — campaña v2 . . 45
14. Veredicto de hipótesis en la campaña v2 46
15. Análisis de sensibilidad — impacto de perturbaciones paramétricas en Z . . 49
16. Resumen de veredictos de hipótesis por régimen experimental 54

1. Introducción

1.1. El Problema de Producción Conjunta en la Industria Avícola

La industria avícola, reconocida como un pilar económico en Colombia y a nivel mundial, enfrenta un desafío operativo fundamental: el **problema de producción conjunta (joint production) y balanceo de carcasa**. Este problema surge de la discrepancia inherente entre la oferta de coproductos, que se derivan en proporciones relativamente fijas del despiece de cada ave, y la demanda variable y a menudo desalineada del mercado para cada uno de esos cortes (pechuga, alas, muslos, vísceras, etc.). Se trata de un problema clásico de **optimización de mezcla de producción bajo restricciones de co-producción** [1], [2].

La industria avícola opera bajo una dinámica compleja de **"Push" (Empuje) y "Pull" (Tracción)**. Por un lado, el factor "Push" proviene de la granja: una vez que las aves alcanzan su peso de mercado, deben ser procesadas inmediatamente, generando una oferta fija de coproductos (alas, pechugas, muslos) en proporciones biológicamente determinadas. Por otro lado, el factor "Pull" es la demanda del mercado, que es estocástica, estacional y a menudo desbalanceada respecto a la oferta anatómica (alta demanda de pechuga pero baja de alas, por ejemplo).

Un plan de ventas que, por ejemplo, prioriza la comercialización de pechuga para maximizar ingresos, inevitablemente genera una sobreoferta de otros coproductos como alas y patas. Si no se gestiona adecuadamente, este excedente debe ser almacenado (incrementando costos de refrigeración), vendido a precios de liquidación o incluso desechado, ocasionando pérdidas económicas significativas y un desperdicio de recursos valiosos.

Este conflicto genera ineficiencias operativas significativas, como la acumulación de inventarios de baja rotación, la venta de productos premium a precios de liquidación, y la pérdida de oportunidades de mercado. Estudios recientes en Colombia [3] y en planificación de plantas de beneficio avícola [4] demuestran que la aplicación de modelos matemáticos avanzados de optimización puede mitigar estos efectos y mejorar la sostenibilidad financiera y ambiental del sector.

La Figura 1 describe el problema como un sistema de entrada/salida: dado un conjunto de datos de entrada (demanda del mercado, proporciones anatómicas, costos y capacidad de la planta), el modelo de optimización —resuelto mediante metaheurísticas— genera como salida un plan óptimo de producción que indica cuántas aves procesar, cómo distribuir los coproductos y qué niveles de inventario mantener.

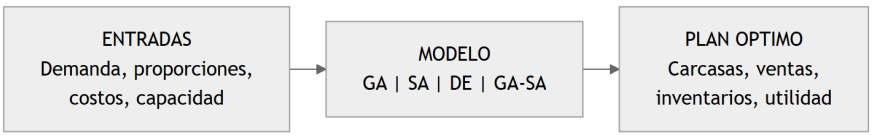


Figura 1: Representación del problema como sistema de entrada/salida. El modelo de optimización recibe datos de demanda, proporciones anatómicas y parámetros operativos, y genera un plan de producción óptimo.

A nivel sistémico, el problema se enmarca en la dinámica **Push/Pull** de la cadena avícola

(Figura 2). La granja "empuja" lotes de aves que deben procesarse al alcanzar su peso de mercado (Push), generando coproductos en proporciones fijas. Simultáneamente, el mercado "jala" productos específicos con demanda variable y estacional (Pull). El **desbalance** ocurre cuando estas dos fuerzas no están alineadas, y la planta de procesamiento debe tomar decisiones de producción, inventario y ventas bajo incertidumbre.

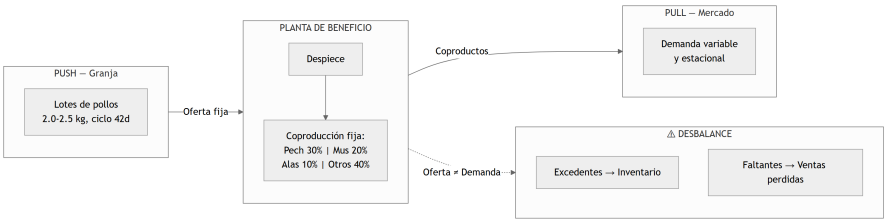


Figura 2: Sistema global Push/Pull de la cadena avícola. La granja empuja lotes de aves (Push), la planta genera coproductos en proporciones fijas, y el mercado jala productos con demanda variable (Pull). El desbalance entre oferta y demanda genera excedentes y faltantes.

1.2. Relevancia Económica y Contexto Nacional

La relevancia económica de resolver el problema de la planificación de coproductos es crucial para la competitividad y sostenibilidad de la industria avícola colombiana. Según FENAVI [5], la avicultura representa uno de los renglones pecuarios más importantes del país, con una producción anual que supera las 1.7 millones de toneladas de carne de pollo. La agroindustria avícola aporta aproximadamente 0.52 % del valor agregado bruto nacional [6].

Una gestión optimizada de la producción conjunta permite:

- **Reducir costos de inventario:** Minimizando la acumulación de productos de baja rotación.
- **Maximizar ingresos:** Aprovechando oportunidades de mercado para cortes de alta demanda.
- **Mejorar la eficiencia operativa:** Optimizando las cantidades procesadas por periodo.
- **Reducir el desperdicio:** Contribuyendo a la sostenibilidad ambiental del sector.

El problema de planificación de coproductos bajo demanda estocástica es un problema de optimización combinatoria clasificado como **NP-hard**. La demostración formal de esta complejidad se remonta al trabajo seminal de Florian et al. [7] y Bitran y Yanasse [8], quienes probaron que incluso el caso mono-producto del Capacitated Lot-Sizing Problem (CLSP) con costos fijos de setup es NP-hard [9]. Rahmani et al. [10] confirman que la extensión a dos etapas estocásticas preserva esta complejidad, y Mahdieh et al. [11] demuestran que agregar restricciones de lote mínimo y setup crossover la incrementan aún más. Esta complejidad computacional ha motivado el desarrollo de enfoques metaheurísticos para encontrar soluciones de alta calidad en tiempos de cómputo razonables.

La literatura reciente en optimización de cadenas de suministro avícolas [3], [4], [12] y en planificación de producción para la industria alimentaria [13], [14] ha demostrado la viabilidad de modelos matemáticos para la planificación integrada. Sin embargo, estos trabajos

emplean predominantemente métodos exactos (MILP/CPLEX) que resultan intratables para instancias de gran escala con incertidumbre.

Este trabajo se centra en abordar este desafío mediante el desarrollo de un **modelo de optimización para la planificación de coproductos**, resuelto con **técnicas metaheurísticas** (Algoritmos Genéticos, Recocido Simulado, Evolución Diferencial e híbridos) [15], [16]. El objetivo es desarrollar una herramienta de apoyo a la decisión que permita a las empresas del sector mejorar su planificación, reducir sus pérdidas y fortalecer su competitividad en un mercado cada vez más exigente.

1.3. Preguntas de Investigación

Pregunta Principal: ¿Cómo puede un modelo de optimización de coproductos, resuelto mediante técnicas metaheurísticas, minimizar las pérdidas económicas asociadas al desbalance entre la oferta conjunta de coproductos y la demanda del mercado en una planta de procesamiento avícola colombiana?

Preguntas Secundarias:

1. ¿Qué formulación matemática del problema de planificación de coproductos captura adecuadamente las restricciones de producción conjunta, los costos de inventario, balance de materiales y la variabilidad de la demanda en el contexto avícola?
2. ¿Qué técnicas metaheurísticas (Algoritmos Genéticos, Recocido Simulado, Evolución Diferencial, o híbridos) presentan el mejor desempeño para resolver el modelo de optimización de coproductos propuesto?
3. ¿En qué magnitud se pueden reducir las pérdidas económicas asociadas al desbalance de carcasa mediante la implementación del modelo de optimización?

1.4. Hipótesis de Investigación

Hipótesis Principal (H1): La aplicación del modelo de optimización de coproductos con metaheurísticas generará una reducción $\geq 5\,\%$ en el costo total operativo respecto al baseline de planificación proporcional, validada con nivel de significancia $\alpha = 0.05$, tomando como referencia los benchmarks de Solano-Blanco et al. [3] (8.6 % de reducción) y Tahraoui et al. [4].

Hipótesis Secundarias:

- **H2:** El algoritmo híbrido GA-SA obtendrá soluciones con un gap de optimalidad $\leq 2\,\%$ respecto a la mejor metaheurística individual (GA, SA o DE), en un tiempo computacional $\leq 50\,\%$ del requerido por el solver exacto (CBC/PuLP) para instancias medianas ($n_t = 12$, $n_\omega = 50$) [15].
- **H3:** El modelo de optimización permitirá una reducción $\geq 15\,\%$ en el inventario promedio total, comparada con el método de planificación proporcional, evaluada mediante un contraste one-sided bloqueado por instancia ($\alpha = 0.05$). Como análisis secundario exploratorio, se examinará el inventario de baja rotación cuando el baseline sea estrictamente positivo.

1.5. Alcance y Limitaciones

Alcance:

- El modelo se formula para la planificación operativa de coproductos en plantas de beneficio avícola con un horizonte de planificación de hasta 30 días.
- Se evalúan cuatro metaheurísticas (GA, SA, DE, GA-SA) y se comparan contra un solver exacto (CBC) y un baseline heurístico.
- La validación se realiza con datos sintéticos calibrados con parámetros del sector avícola colombiano (FENAVI, DANE, literatura publicada).
- El alcance geográfico se limita al contexto colombiano, utilizando costos, precios y patrones de demanda representativos del mercado nacional.

Limitaciones:

- No se utilizan datos operativos reales de una planta de beneficio específica, sino datos sintéticos calibrados.
- El modelo asume proporciones de coproductos fijas por carcasa (no considera variabilidad genética inter-lote).
- No se integra el scheduling detallado de la línea de despiece (solo lot-sizing a nivel diario).
- La perecibilidad se modela como restricción de vida útil discreta, sin considerar deterioro gradual de calidad.

---

2. Justificación

2.1. Conveniencia y Relevancia Económica

La optimización de la planificación de coproductos tiene un impacto directo en la rentabilidad de las empresas avícolas. Como demostró el caso de Solano-Blanco et al. [3], las mejoras en la planificación integrada pueden traducirse en reducciones de costos del **8.6 %**. Tahraoui et al. [4] confirmaron que la planificación operativa optimizada con modelos MILP reduce significativamente los costos en plantas multi-producto. En una industria de márgenes estrechos y alto volumen, estas mejoras representan una ventaja competitiva crítica.

El sector avícola colombiano, que según FENAVI [5] genera más de 600,000 empleos directos e indirectos, se beneficiaría significativamente de herramientas que mejoren su eficiencia operativa. La implementación de modelos de optimización no solo mejora la rentabilidad de las empresas individuales, sino que fortalece la competitividad del sector a nivel nacional e internacional.

El desbalance entre la oferta conjunta y la demanda del mercado se manifiesta en dos frentes principales:

1. **Excedentes de inventario (sobreproducción):** Cuando la producción de ciertos cortes (alas, patas, vísceras) supera la demanda del mercado, las empresas se ven forzadas a incurrir en costos adicionales de almacenamiento en frío, transporte y, en el

peor de los casos, vender estos productos a precios de liquidación, erosionando significativamente los márgenes de ganancia.

2. **Faltantes de inventario (subproducción):** De forma simultánea, la demanda de cortes de alto valor (pechuga) puede exceder la capacidad de producción balanceada, resultando en oportunidades de venta perdidas y una potencial insatisfacción del cliente.

Tabla 1: Magnitud del problema en la industria avícola colombiana

Indicador	Valor	Fuente
Producción anual de pollo	1.7 millones de toneladas	FENAVI 2024
Empleos generados	600,000+ directos e indirectos	FENAVI 2024
Participación en PIB agropecuario	0.52 %	DANE 2024
Potencial de ahorro en inventario	30–60 %	Solano-Blanco et al. 2022
Costos de almacenamiento refrigerado	+15–25 % del costo operativo	Solano-Blanco et al. 2022; Sel et al. 2015
Pérdidas por ventas de liquidación	-20–40 % del margen	Amorim et al. 2014
Desperdicio de producto perecedero	5–10 % de la producción total	Claassen 2016; Akbari-Aghghaleh et al. 2025

Fuente: Elaboración propia con datos de [3], [5], [6], [14], [15], [17], [18]

2.2. Relevancia Social y Ambiental (ODS 9, ODS 12)

Mejorar el equilibrio de la carcasa contribuye directamente a la sostenibilidad del sector. Al reducir el desperdicio de alimentos y optimizar el uso de recursos (energía para refrigeración de inventarios no deseados), el proyecto se alinea con los **Objetivos de Desarrollo Sostenible (ODS)**, específicamente:

- **ODS 12 (Producción y Consumo Responsables):** Reduciendo el desperdicio de alimentos y optimizando el aprovechamiento de cada ave procesada.
- **ODS 9 (Industria, Innovación e Infraestructura):** Mediante la aplicación de técnicas avanzadas de optimización y el desarrollo de herramientas tecnológicas para la industria.

La reducción del desperdicio de alimentos es particularmente relevante en un contexto global donde aproximadamente el 14 % de los alimentos se pierde en la cadena de suministro antes de llegar al consumidor [19]. Un mejor balanceo de la carcasa significa un proceso más sostenible, con menor huella de carbono y mejor utilización de los recursos naturales. En otras industrias de desensamble, Darghouth et al. [20] han confirmado que la integración de criterios de sostenibilidad (eficiencia energética, reducción de costos) en modelos de optimización genera beneficios significativos, principios transferibles al procesamiento avícola.

2.3. Implicaciones Prácticas

El desarrollo de una herramienta de toma de decisiones basada en metaheurísticas permitirá a los planificadores de producción pasar de decisiones basadas en la intuición y la experiencia personal a decisiones basadas en datos y modelado matemático robusto. Esto mejorará la capacidad de respuesta ante fluctuaciones del mercado y permitirá una planificación más ágil y eficiente.

La implementación de tecnologías de sensores inteligentes [21] y sistemas de automatización [22] en la industria avícola está generando grandes volúmenes de datos que pueden ser aprovechados por modelos de optimización como el propuesto en este proyecto. La disponibilidad creciente de datos en tiempo real facilita la implementación práctica de herramientas como la desarrollada en este trabajo.

2.4. Valor Teórico y Científico

El proyecto contribuye significativamente a la literatura de **optimización de producción conjunta** en la industria alimentaria, extendiendo los modelos clásicos de planificación de producción deterministas [2] hacia enfoques estocásticos que consideran la incertidumbre de la demanda, una área identificada como línea futura de investigación por diversos autores [23], [24].

La **optimización multi-objetivo** en la industria alimentaria ha experimentado un avance significativo en los últimos años. Arteaga-Cabrera et al. [25] presentaron una revisión comprehensiva sobre la evolución de las estrategias de optimización en alimentos, identificando la transición desde métodos univariados tradicionales hacia técnicas multi-objetivo integradas con tecnologías emergentes. Su trabajo destaca que la industria alimentaria moderna requiere **optimizar simultáneamente múltiples objetivos competitivos** (costos de producción, eficiencia energética, calidad del producto, sostenibilidad), lo cual se alinea perfectamente con la planificación de coproductos avícolas, donde se deben balancear simultáneamente:

- Maximización de ingresos por venta de coproductos
- Minimización de costos de inventario
- Minimización de penalizaciones por demanda no satisfecha
- Maximización del nivel de servicio al cliente

La incorporación de **algoritmos evolutivos** y metaheurísticas hibridizadas, como lo documentan Arteaga-Cabrera et al. [25], ha permitido abordar estos problemas complejos de forma efectiva en la industria alimentaria. Este proyecto se posiciona como una **contribución directa** a esta línea de investigación, aplicando metaheurísticas (GA, SA, DE, GA-SA) a un problema de planificación de coproductos en el procesamiento avícola. Si bien el modelo propuesto utiliza una función objetivo escalar (beneficio esperado ponderado), los principios de optimización multi-criterio representan una línea de extensión natural.

Adicionalmente, la comparación rigurosa de diferentes técnicas metaheurísticas en el contexto específico de la industria avícola genera conocimiento valioso sobre la efectividad de estas técnicas en problemas del mundo real con características particulares (perecibilidad, estocasticidad, restricciones sanitarias).

3. Objetivos

3.1. Objetivo General

Desarrollar un modelo de optimización para la planificación de coproductos que, mediante la aplicación de técnicas metaheurísticas, minimice las pérdidas económicas asociadas al desbalance entre la oferta conjunta de coproductos y la demanda del mercado en la industria avícola colombiana.

3.2. Objetivos Específicos

1. **Formular** un modelo matemático de optimización de coproductos que capture las restricciones de producción conjunta, costos de inventario, balance de materiales y variabilidad de la demanda propias del procesamiento avícola.
2. **Implementar** algoritmos metaheurísticos (Algoritmo Genético, Recocido Simulado, Evolución Diferencial y un enfoque híbrido GA-SA) adaptados al problema de planificación de coproductos avícolas.
3. **Diseñar** un generador de instancias de prueba con datos sintéticos calibrados que reflejen las condiciones operativas reales de la industria avícola colombiana.
4. **Comparar** el desempeño de las metaheurísticas propuestas mediante un diseño experimental riguroso, evaluando calidad de solución y eficiencia computacional.
5. **Validar** el modelo propuesto mediante simulación, cuantificando las mejoras potenciales en términos de reducción de costos de inventario, nivel de servicio y rentabilidad operativa.

---

4. Marco Referencial

4.1. Marco Conceptual

4.1.1. Producción Conjunta (Joint Production) El **problema de producción conjunta** ocurre cuando el procesamiento de una materia prima genera múltiples productos en proporciones fijas o semifijas. En la industria avícola, el despiece de cada carcasa produce inevitablemente pechuga, muslos, alas, vísceras y otros cortes en proporciones determinadas por la anatomía del ave. Esta característica, compartida con otras industrias cárnicas, crea un desafío único de planificación cuando la demanda del mercado para cada coproducto no refleja estas proporciones naturales [1].

Desde la perspectiva de la investigación de operaciones, este problema se clasifica como un **problema de optimización de mezcla de producción multi-producto con restricciones de co-producción** [2]. A diferencia de los problemas clásicos de planificación de producción, donde las cantidades de cada producto pueden decidirse independientemente,

aquí la decisión de producir una unidad de un coproducto (e.g., pechuga) implica necesariamente la producción de cantidades proporcionales de todos los demás coproductos.

4.1.2. Lot-Sizing Capacitado (CLSP) El **Capacitated Lot-Sizing Problem (CLSP)** es un problema clásico de la investigación de operaciones que busca determinar las cantidades óptimas de producción en cada periodo de un horizonte de planificación, considerando capacidad limitada de producción, costos fijos de setup (activación de línea) y costos variables de producción e inventario [9].

La formulación estándar del CLSP incluye:

- **Decisiones binarias de setup** ($y_t \in \{0, 1\}$): si la línea se activa o no en el periodo t, con un costo fijo F asociado.
- **Cantidades de lote** ($q_t \in \mathbb{Z}^+$): número de unidades a producir en cada periodo, acotadas por la capacidad máxima Q^{max} y el lote mínimo Q^{min}.
- **Balance de inventario**: el inventario al final de cada periodo resulta de la producción más el inventario anterior menos las ventas realizadas.

La combinación de variables enteras de producción, decisiones binarias de setup y restricciones de lote mínimo confiere al CLSP una complejidad **NP-hard**, formalmente demostrada por Florian et al. [7] y Bitran y Yanasse [8].

4.1.3. Programación Estocástica de Dos Etapas La **programación estocástica de dos etapas** [23] es un marco de modelado para problemas de optimización bajo incertidumbre donde las decisiones se dividen en:

- **Primera etapa (*here-and-now*):** Decisiones que deben tomarse antes de que se revele la incertidumbre. En el contexto de este trabajo, corresponden a las decisiones de setup (y_t) y cantidades de producción (q_t).
- **Segunda etapa (*wait-and-see*):** Decisiones que se toman después de observar la realización de la incertidumbre. Corresponden a las decisiones de venta ($v_{pt\omega}$), inventario ($I_{pt\omega}$) y demanda no satisfecha ($u_{pt\omega}$) para cada escenario ω.

La función objetivo maximiza el **beneficio esperado** sobre todos los escenarios de demanda, ponderados por sus probabilidades de ocurrencia π_ω. Este marco permite tomar decisiones robustas que funcionan bien en promedio sobre el conjunto de escenarios posibles.

4.1.4. Perecibilidad en la Industria Alimentaria La **perecibilidad** es una restricción temporal que limita el tiempo durante el cual un producto puede mantenerse en inventario antes de perder su valor comercial. En la industria avícola, cada coproducto tiene una **vida útil** (L_p) que depende del tipo de corte, el empaque y las condiciones de almacenamiento.

Integrar la perecibilidad en los modelos de planificación requiere restricciones adicionales que limiten la acumulación de inventario a un número máximo de periodos. Entrup et al. [26] fueron pioneros en integrar la vida útil como restricción dura en problemas de lot-sizing para la industria láctea. Claassen [18] extendió este enfoque al procesamiento de alimentos con

setups non-triangulares y *product decay*. Rong et al. [27] modelaron el deterioro como variable continua en la gestión de alimentos frescos.

4.1.5. Metaheurísticas: Definición y Clasificación Las **metaheurísticas** son estrategias de alto nivel que guían la búsqueda de soluciones en problemas de optimización complejos, particularmente cuando los métodos exactos resultan intratables [28]. Se clasifican según su estrategia de búsqueda:

- **Basadas en trayectoria:** Operan sobre una sola solución que se modifica iterativamente (e.g., Recocido Simulado, Búsqueda Tabú). Su fortaleza es la **intensificación** (explotación local).
- **Basadas en población:** Operan sobre un conjunto de soluciones simultáneas que evolucionan mediante operadores de selección, cruce y mutación (e.g., Algoritmos Genéticos, Evolución Diferencial). Su fortaleza es la **diversificación** (exploración global).
- **Híbridos (meméticos):** Combinan la exploración global de los métodos poblacionales con la explotación local de los métodos de trayectoria (e.g., GA-SA). Buscan el equilibrio óptimo entre exploración y explotación.

En el contexto de la industria alimentaria, Arteaga-Cabrera et al. [25] documentaron la creciente efectividad de estas técnicas para resolver problemas de optimización multi-objetivo en sistemas de producción alimentaria.

4.2. Marco Teórico y Estado del Arte

4.2.1. Complejidad NP-hard del CLSP La demostración formal de la complejidad NP-hard del CLSP con costos fijos de setup se remonta al trabajo seminal de **Florian et al.** [7], quienes probaron que el problema de planificación de producción determinista con costos fijos es NP-hard. **Bitran y Yanasse** [8] extendieron este resultado al CLSP capacitado, demostrando que la inclusión de restricciones de capacidad no simplifica el problema.

Goren y Tunali [9] confirmaron esta clasificación y demostraron que agregar *setup carryover* (continuidad de setup entre periodos) y *backordering* (pedidos pendientes) incrementa aún más la dificultad computacional. Su trabajo propone un enfoque híbrido de Fix-and-Optimize para abordar estas variantes.

Rahmani et al. [10] extendieron la conclusión de NP-hardness al *two-stage stochastic capacitated lot-sizing*, confirmando explícitamente que la extensión estocástica preserva la complejidad. Este resultado es directamente aplicable al problema abordado en este trabajo, que combina lot-sizing capacitado con escenarios estocásticos de demanda.

Mahdieh et al. [11] demostraron que agregar restricciones de lote mínimo con *setup crossover* (continuidad de setup entre periodos consecutivos) incrementa aún más la complejidad del problema base. El modelo propuesto en este trabajo, que combina múltiples productos, incertidumbre estocástica, costos fijos de setup, lote mínimo y perecibilidad, es por tanto formalmente **NP-hard**, justificando plenamente el uso de metaheurísticas.

4.2.2. Lot-Sizing con Perecibilidad en FPI En el contexto de **lot-sizing para productos perecederos en la industria de procesamiento de alimentos (FPI)**, varios trabajos han establecido las bases teóricas:

Claassen [18] abordó específicamente la planificación y scheduling en FPI con *setups non-triangulares* (donde los tiempos de limpieza entre productos no satisfacen la desigualdad triangular, situación típica en líneas de procesamiento cárnico) y el *deterioro de producto (product decay)* como restricción temporal del inventario.

Stefánsdóttir et al. [29] complementaron este trabajo con una clasificación taxonómica de los tipos de setup y limpieza en lot-sizing, distinguiendo entre setups triangulares y non-triangulares y su impacto en la complejidad del modelo. Su taxonomía facilita la selección del modelo de setup más apropiado para cada aplicación industrial.

Entrup et al. [26] desarrollaron modelos MILP pioneros que integran la vida útil como restricción en problemas de lot-sizing para la industria láctea, estableciendo un marco transferible a otros sectores alimentarios. Su modelado de *shelf-life-integrated planning* constituye la base teórica directa para la restricción de perecibilidad utilizada en este trabajo (Eq. 7).

Rong et al. [27] propusieron un enfoque de optimización para la gestión de calidad de alimentos frescos a lo largo de la cadena de suministro, modelando el deterioro como variable continua. Este enfoque, más sofisticado que la restricción de vida útil discreta utilizada en el presente trabajo, representa una extensión natural para futuras investigaciones.

4.2.3. Optimización en la Cadena de Suministro Avícola La investigación en optimización de cadenas de suministro avícolas ha crecido significativamente en los últimos años:

Solano-Blanco et al. [3] abordaron el problema específico de planificación integrada en la industria avícola colombiana mediante un modelo MILP con programación estocástica de dos etapas. Su caso de estudio en Santa Marta demostró reducciones de costos del **8.6 %**, lo que constituye el benchmark principal de este trabajo.

Tahraoui et al. [4] desarrollaron un modelo MILP para la planificación operativa de plantas de beneficio avícola multi-producto bajo restricciones realistas y demanda fluctuante, validado con CPLEX. Su enfoque aborda la complejidad de la planificación operativa en entornos multi-producto, pero permanece limitado a métodos exactos intratables para instancias de gran escala.

Yazdekhasti et al. [12] formularon un modelo estocástico multi-periodo y multi-modal para la cadena de suministro avícola bajo incertidumbre de demanda, con un caso de estudio en Mississippi durante la pandemia de COVID-19. Su modelo MILP demuestra la importancia de considerar la estocasticidad en la planificación avícola.

González-Neira et al. [30] integraron scheduling y transporte en un modelo MILP para la cadena de suministro avícola colombiana, avanzando en la planificación operativa detallada. Su trabajo confirma la relevancia del contexto colombiano para este tipo de investigaciones.

Dadaneh et al. [31] formularon un modelo CLSP con *chance-constraints* para la planifi-

cación de producción de huevos en granjas avícolas bajo demanda incierta, demostrando la aplicabilidad directa del lot-sizing capacitado en el sector avícola.

Juwitaa et al. [32] optimizaron cadenas de suministro de pollo de engorde bajo incertidumbre en la tasa de crecimiento mediante programación estocástica de dos etapas, confirmando la relevancia de este marco de modelado para la industria avícola.

4.2.4. Metaheurísticas para Lot-Sizing y SC Avícola La aplicación de metaheurísticas a problemas de lot-sizing y cadenas de suministro avícolas es un área de investigación en crecimiento:

Akbari-Aghghaleh et al. [15] constituyen la referencia más directa para este trabajo. Diseñaron una cadena de suministro avícola de ciclo cerrado con perecibilidad y sostenibilidad, evaluando cinco metaheurísticas: **GA, SA, DE, GA-SA y DE-SA**. Sus resultados demuestran que el **híbrido GA-SA obtiene el mejor rendimiento** entre las cinco técnicas evaluadas para problemas NP-hard de cadena de suministro avícola con perecibilidad. Este resultado fundamenta directamente la selección del GA-SA como algoritmo principal en el presente trabajo.

Slama et al. [16] utilizaron GA combinado con **Monte Carlo Simulation** para resolver problemas estocásticos de lot-sizing capacitado bajo lead times aleatorios. Sus resultados demuestran que el GA supera al MIP exacto en instancias medianas y grandes, validando el uso de metaheurísticas para problemas estocásticos de lot-sizing.

Roshani et al. [33] evaluaron un heurístico de relax-and-fix para el CLSP, confirmando la efectividad de SA como componente de búsqueda local. Su trabajo demuestra que los enfoques que integran explotación local intensiva son particularmente efectivos en problemas de lot-sizing.

4.2.5. Optimización Multi-Objetivo en Industria Alimentaria La optimización multi-objetivo ha experimentado un avance significativo en la industria alimentaria:

Arteaga-Cabrera et al. [25] presentaron una revisión comprehensiva sobre la evolución de las estrategias de optimización en alimentos, identificando la transición desde métodos univariados tradicionales hacia técnicas multi-objetivo integradas con tecnologías emergentes. Su trabajo destaca la importancia de optimizar simultáneamente múltiples objetivos competitivos en la industria alimentaria moderna.

Liang et al. [34] demostraron la efectividad de la optimización multi-objetivo para operaciones de corte en la industria cárnica, abordando la maximización de beneficios de coproductos respetando restricciones de producción conjunta. Este trabajo es directamente análogo al problema de balanceo de carcasa avícola abordado en esta tesis.

Mirzapour Al-e-Hashem et al. [24] desarrollaron un modelo robusto multi-objetivo para planificación agregada de producción multi-producto bajo incertidumbre de demanda y costos. Su enfoque de optimización robusta complementa la programación estocástica utilizada en este trabajo.

Amorim et al. [14] formularon un modelo integrado de producción y distribución multi-objetivo para productos perecederos, combinando minimización de costos con maximización de frescura. Su integración de restricciones de vida útil en la planificación es directamente aplicable al contexto avícola.

4.2.6. Modelos Deterministas de Referencia Varios modelos deterministas establecen las bases para formulaciones más avanzadas:

Gicquel y Mièvegeville [2] desarrollaron formulaciones y métodos de solución para la planificación conjunta de producción y transporte en cadenas alimentarias multi-sitio. Sus modelos MILP para producción conjunta con co-productos constituyen un referente directo para este trabajo.

Sel et al. [17] demostraron la importancia de considerar restricciones de vida útil en la planificación integrada de cadenas de suministro de productos perecederos, con aplicación a la industria láctea. Su enfoque de *multi-bucket optimization* informa la granularidad temporal del modelo propuesto.

Kopanos et al. [35] establecieron marcos matemáticos eficientes para el scheduling detallado en la industria de procesamiento de alimentos. Aunque su alcance es más operativo que el presente trabajo, sus formulaciones informan las restricciones de capacidad y setup utilizadas.

4.2.7. Tecnologías Habilitadoras Las tecnologías habilitadoras complementan el enfoque de optimización:

Mahalik y Nambiar [36] destacan la tendencia creciente hacia la automatización y el uso de sensores inteligentes en los sistemas de manufactura de alimentos, elementos clave para asegurar la calidad y trazabilidad. La integración de estos sensores y la planificación automatizada en plantas de procesamiento están generando oportunidades para la implementación de modelos de optimización en tiempo real.

Hartono et al. [37] demostraron la eficacia del *Bees Algorithm* para optimizar planes de desensamble robótico, un enfoque que podría adaptarse al procesamiento de carcasas avícolas. Su trabajo confirma la viabilidad de metaheurísticas bio-inspiradas para problemas de desensamble en manufactura.

Feng et al. [38] demostraron cómo el aumento de datos sintéticos mejora significativamente la segmentación de instancias de carcasas de pollo, lo cual es fundamental para la automatización de procesos de despiece y control de calidad. Esta tecnología de visión por computador complementa los modelos de planificación al proporcionar datos más precisos sobre rendimientos de carcasa.

Awad et al. [39] desarrollaron un modelo de optimización para minimizar el desperdicio (*giveaway*) y el subpeso (*underweight*) en el proceso de porcionado avícola, demostrando que la optimización matemática puede mejorar significativamente la eficiencia del despiece. Su trabajo es directamente aplicable al problema de balanceo de carcasa abordado en este trabajo.

4.3. Vacíos de Investigación Identificados

A pesar de la creciente investigación en optimización de cadenas de suministro avícolas y en metaheurísticas para problemas combinatorios, la revisión del estado del arte revela varios vacíos de investigación que este trabajo busca abordar.

Una búsqueda sistemática realizada en Scopus (febrero 2026) utilizando ecuaciones de búsqueda centradas en lot-sizing estocástico, perecibilidad, optimización avícola y metaheurísticas arrojó los siguientes resultados:

Tabla 2: Resultados de la búsqueda sistemática en Scopus (febrero 2026)

Query	Tema	Base de datos	Periodo	# Resultados
Q1	Lot-sizing estocástico + NP-hard + Setup	Scopus	2014–2026	9
Q2	Metaheurísticas + Setup estocástico	Scopus	2017–2026	11
Q3	Perecibilidad + Lot-sizing + Setup	Scopus	2015–2026	20
Q4	Optimización avícola/cárnica	Scopus	2018–2026	186
Q5	Prog. estocástica 2-etapas + Metaheurísticas	Scopus	2016–2026	218
Q6	CLSP + Complejidad computacional	Scopus	2015–2026	30

Query	Tema	Base de datos	Periodo	# Resultados
Q7	Reviews multi-product lot-sizing estocástico	Scopus	2018–2026	0
Q8	Lote mínimo + Setup + Prog. entera	Scopus	2015–2026	4
			Total	**478**

De los 478 resultados, solo 13 papers abordan directamente la intersección entre lot-sizing estocástico con setup, perecibilidad y metaheurísticas—confirmando la brecha que esta investigación busca llenar. Notablemente, la Query Q7 (reviews sobre multi-product lot-sizing estocástico) no arrojó ningún resultado, evidenciando la ausencia de trabajos de revisión del estado del arte para este tema específico.

La Tabla 3 resume los trabajos más relevantes y su posicionamiento respecto a esta propuesta.

Tabla 3: Resumen del estado del arte y brechas identificadas

Autor(es)	Técnica	Objetivo	Incertidumbre	Aplicación
Solano-Blanco et al. [3]	MILP Estoc.	Planif. integrada	Estoc. 2 etapas	Avícola (Col.)
Tahraoui et al. [4]	MILP (CPLEX)	Planif. operativa	Demanda fluct.	Avícola (multi-prod.)
Yazdekhasti et al. [12]	MILP Multi-modal	SC estocástica	Estoc. (demanda)	Avícola (Miss.)
Mirzapour et al. [24]	MILP Robusto	Planif. agregada	Robusto multi-obj.	Manufactura
Gicquel & Miègeville [2]	MILP	Prod. + transp.	Determinista	Alimentaria
Sel et al. [17]	MILP	Prod. + distrib.	Determinista	Perecederos
Kopanos et al. [35]	MILP	Scheduling	Determinista	Alimentaria
Amorim et al. [14]	MILP Multi-obj.	Prod. + distrib.	Determinista	Perecederos
Liang et al. [34]	Optim. Multi-obj.	Corte cárnico	Determinista	Cárnica (coprod.)

Autor(es)	Técnica	Objetivo	Incertidumbre	Aplicación
Claassen [18]	MILP	Lot-sizing + decay	Determinista	FPI (setup non-triang.)
Rahmani et al. [10]	Heurístico híbrido	CLSP estocástico	Estoc. 2 etapas	Manufactura (NP-hard)
Dadaneh et al. [31]	CLSP chance-constr.	Planif. huevos	Estoc. (demanda)	Avícola (huevos)
Akbari-Aghghaleh et al. [15]	**GA, SA, DE, híbridos**	SC ciclo cerrado	Determinista	**Avícola (perecib.)**
González-Neira et al. [30]	MILP	Scheduling + transp.	Determinista	Avícola (Col.)
→ Propuesta	**GA, SA, DE, GA-SA**	**Max profit**	**Estoc. (demanda)**	**Avícola (coprod., Col.)**

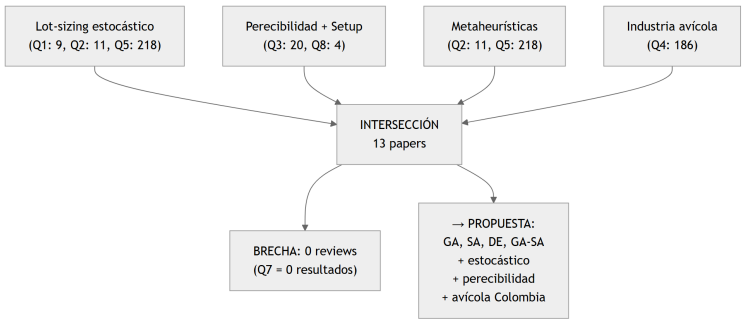


Figura 3: Diagrama de intersección de brechas de investigación. De 478 resultados en las 8 queries de búsqueda, solo 13 papers abordan la intersección directa entre lot-sizing estocástico, perecibilidad, metaheurísticas e industria avícola. La ausencia de reviews (Q7=0) confirma la novedad del área.

Los principales vacíos identificados son:

1. **Ausencia de metaheurísticas para planificación de coproductos avícolas bajo incertidumbre:** De los 14 trabajos relevantes en la Tabla 3, solo Akbari-Aghghaleh et al. [15] utilizan metaheurísticas en el contexto avícola, pero con un modelo determinista. Ningún trabajo combina metaheurísticas con programación estocástica de dos etapas para coproductos avícolas.
2. **Inexistencia de reviews de multi-product lot-sizing estocástico:** La Query Q7 no arrojó ningún resultado, evidenciando que el campo carece de sistematización. Esto dificulta la identificación de mejores prácticas y líneas de investigación prioritarias.
3. **Concentración en la intersección directa:** Solo 13 de 478 papers (2.7 %) abordan simultáneamente los cuatro ejes temáticos (lot-sizing estocástico, perecibilidad, meta-

heurísticas, avícola), confirmando que la propuesta aborda un nicho inexplorado con contribución potencial significativa.

---

5. Formulación del Modelo Matemático

El modelo propuesto se formula como un problema de **Programación Lineal Entera Mixta (MILP) multi-periodo** con estructura de *lot-sizing* estocástico para la planificación óptima de coproductos avícolas bajo demanda incierta.

5.1. Conjuntos, Parámetros y Variables de Decisión

Conjuntos:

- $P = \{1, 2, ..., n_p\}$: Conjunto de coproductos (formas de corte: pechuga, muslos, alas, etc.)
- $T = \{1, 2, ..., n_t\}$: Conjunto de periodos de planificación
- $\Omega = \{1, 2, ..., n_\omega\}$: Conjunto de escenarios de demanda

Parámetros:

- α_p: Proporción fija del coproducto p por carcasa (restricción anatómica, $\sum_p \alpha_p = 1$)
- W: Peso promedio de una carcasa (kg)
- $d_{pt\omega}$: Demanda del coproducto p en el periodo t bajo el escenario ω (kg)
- r_p: Precio de venta del coproducto p (COP/kg)
- c^{prod}: Costo de procesamiento por carcasa (COP/carcasa)
- F: Costo fijo de activación de la línea por periodo (COP/periodo)
- c_p^{inv}: Costo de mantener inventario del coproducto p (COP/kg/periodo)
- c_p^{pen}: Costo de penalización por demanda no satisfecha del coproducto p (COP/kg)
- Q^{max}: Capacidad máxima de procesamiento (carcasas/periodo)
- Q^{min}: Lote mínimo de procesamiento (carcasas/periodo)
- L_p: Vida útil máxima del coproducto p (periodos)
- π_ω: Probabilidad del escenario ω

Variables de Decisión:

- $y_t \in \{0, 1\}$: Variable binaria de activación (*setup*) de la línea en t (primera etapa)
- $q_t \in \mathbb{Z}^+$: Número de carcasas a procesar en t (primera etapa)
- $v_{pt\omega}$: Cantidad vendida del coproducto p en t, escenario ω (segunda etapa)
- $I_{pt\omega}$: Inventario del coproducto p al final de t, escenario ω
- $u_{pt\omega}$: Demanda no satisfecha del coproducto p en t, escenario ω

Tabla 4: Conteo de variables y restricciones por tamaño de instancia

Perfil	n_p	n_t	n_ω	Variables 1ª etapa	Variables 2ª etapa	Total variables	Restricciones
Small	5	6	10	12	900	912	~1,080
Medium	8	12	50	24	14,400	14,424	~16,800
Large	8	30	100	60	72,000	72,060	~84,000

5.2. Función Objetivo

La función objetivo maximiza el **beneficio esperado** sobre todos los escenarios de demanda:

$$\text{máx } Z = \sum_{\omega \in \Omega} \pi_\omega \left[\sum_{t \in T} \left(\sum_{p \in P} r_p \cdot v_{pt\omega} - c^{prod} \cdot q_t - F \cdot y_t - \sum_{p \in P} c_p^{inv} \cdot I_{pt\omega} - \sum_{p \in P} c_p^{pen} \cdot u_{pt\omega} \right) \right] \tag{1}$$

Los cinco componentes de la función objetivo son:

1. **Ingresos por ventas:** $\sum_p r_p \cdot v_{pt\omega}$ — maximiza la venta de coproductos a precios de mercado.
2. **Costo de producción:** $c^{prod} \cdot q_t$ — costo variable proporcional al número de carcasas procesadas.
3. **Costo de setup:** $F \cdot y_t$ — costo fijo de activación de la línea (personal, energía, sanitización).
4. **Costo de inventario:** $\sum_p c_p^{inv} \cdot I_{pt\omega}$ — penaliza la acumulación de inventario (refrigeración).
5. **Penalización por demanda insatisfecha:** $\sum_p c_p^{pen} \cdot u_{pt\omega}$ — penaliza las oportunidades de venta perdidas.

5.3. Restricciones

Restricción 1 — Balance de materiales (co-producción):

$$I_{pt\omega} = I_{p,t-1,\omega} + \alpha_p \cdot W \cdot q_t - v_{pt\omega} \quad \forall p \in P, t \in T, \omega \in \Omega \tag{2}$$

El inventario al final de cada periodo resulta del inventario anterior más la producción (proporcional a las carcasas procesadas) menos las ventas realizadas.

Restricción 2 — Satisfacción de demanda:

$$v_{pt\omega} + u_{pt\omega} = d_{pt\omega} \quad \forall p \in P, t \in T, \omega \in \Omega \tag{3}$$

La demanda de cada coproducto se satisface parcial o totalmente. La diferencia entre demanda y ventas constituye la demanda insatisfecha.

Restricción 3 — Vínculo de activación (capacidad máxima):

$$q_t \leq Q^{max} \cdot y_t \quad \forall t \in T \tag{4}$$

Si la línea no está activa ($y_t = 0$), no se procesa ninguna carcasa.

Restricción 4 — Lote mínimo de procesamiento:

$$q_t \geq Q^{min} \cdot y_t \quad \forall t \in T \tag{5}$$

Si la línea está activa ($y_t = 1$), se procesa al menos el lote mínimo operativamente viable.

Restricción 5 — Ventas limitadas por disponibilidad:

$$v_{pt\omega} \leq I_{p,t-1,\omega} + \alpha_p \cdot W \cdot q_t \quad \forall p \in P, t \in T, \omega \in \Omega \tag{6}$$

No se puede vender más de lo disponible (inventario anterior + producción del periodo).

Restricción 6 — Perecibilidad (vida útil):

$$I_{pt\omega} = 0 \quad \forall p \in P, \omega \in \Omega,\ t' \in T \text{ tal que } t' - t > L_p \tag{7}$$

El inventario se descarta cuando excede la vida útil del producto [18].

Restricción 7 — Dominio de variables:

$$y_t \in \{0, 1\}, \quad q_t \in \mathbb{Z}^+, \quad v_{pt\omega}, I_{pt\omega}, u_{pt\omega} \geq 0 \tag{8}$$

5.4. Estructura de Programación Estocástica de Dos Etapas

El modelo sigue la estructura clásica de programación estocástica de dos etapas [23]:

- **Primera etapa (*here-and-now*):** Las decisiones de setup y_t y producción q_t se toman **antes** de conocer la demanda real. Estas son las variables que las metaheurísticas optimizan directamente.
- **Segunda etapa (*wait-and-see*):** Las decisiones de venta $v_{pt\omega}$, inventario $I_{pt\omega}$ y demanda insatisfecha $u_{pt\omega}$ se determinan **después** de observar cada escenario ω. En la implementación, estas variables se calculan mediante un decodificador greedy determinista (§6.2).

5.5. Validación con Solver Exacto (CBC)

El modelo fue validado resolviendo las instancias de prueba con el solver exacto CBC (COIN-OR Branch and Cut) integrado en PuLP, con un límite de tiempo de 300 segundos y extracción de la mejor cota dual (*best bound*) para certificar la calidad de las soluciones. Para los tamaños evaluados, **CBC alcanza optimalidad probada en todos los casos**: las instancias Small se resuelven en segundos, las Medium en decenas de segundos y las Large (hasta

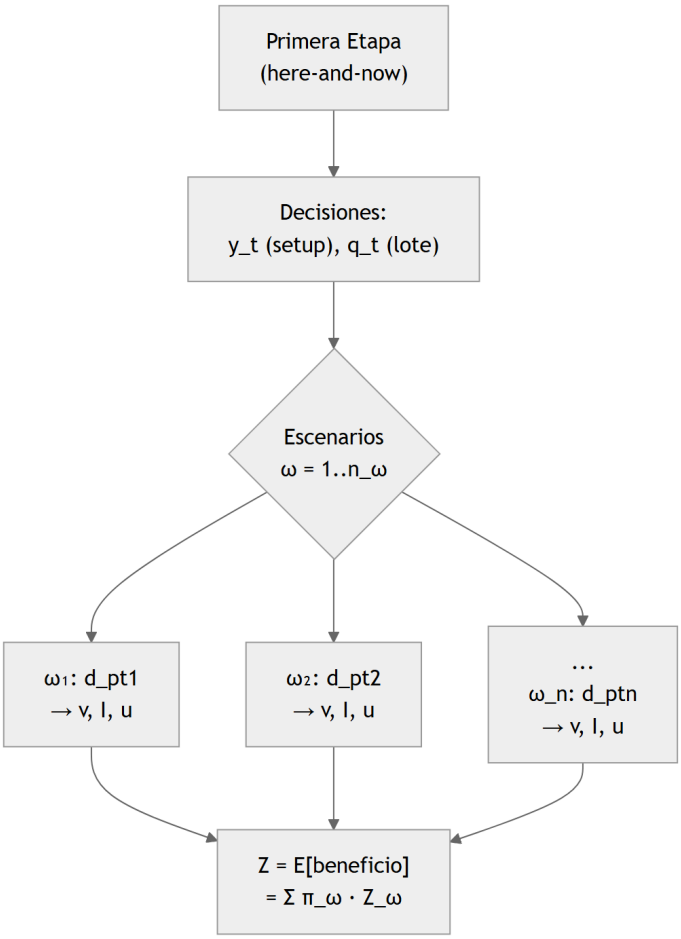


Figura 4: Estructura de programación estocástica de dos etapas. Las decisiones de primera etapa (setup y producción) se toman antes de conocer la demanda; las de segunda etapa (ventas, inventario) se adaptan a cada escenario.

$\approx$ 58,000 variables) en 17–140 segundos según el régimen económico. La solución óptima certificada sirve como referencia (*benchmark*) para medir el gap de las metaheurísticas contra el óptimo verdadero — no contra un incumbente — en todos los tamaños.

Esta capacidad del solver exacto en los tamaños estudiados obliga a precisar la justificación de las metaheurísticas, que no descansa en una supuesta intratabilidad de estas instancias sino en tres argumentos verificados empíricamente (§7): (i) su comportamiento *anytime* — alcanzan el 99 % de su calidad final en una fracción del tiempo, y en instancias Medium y Large llegan al 99 % del óptimo antes de que CBC termine de certificar—; (ii) su escalabilidad esperada hacia instancias de tamaño industrial real ($n_t = 52$, $n_\omega = 500$), donde el crecimiento exponencial del árbol de búsqueda del MILP sí se vuelve limitante; y (iii) su flexibilidad para incorporar extensiones no lineales o multi-objetivo sin reformular el modelo.

---

6. Diseño e Implementación de Metaheurísticas

Dada la complejidad NP-hard del problema (§4.2.1), se implementan cuatro metaheurísticas siguiendo el marco comparativo de Akbari-Aghghaleh et al. [15]. Todas comparten la misma codificación de solución y decodificador greedy, permitiendo una comparación justa.

6.1. Representación Cromosómica

El **cromosoma** constituye la representación computacional de una solución candidata en el espacio de búsqueda. En el contexto de este problema, cada cromosoma codifica exclusivamente las **decisiones de primera etapa** del modelo estocástico (§5.4), es decir, aquellas que deben tomarse antes de conocer la realización de la demanda.

Formalmente, un cromosoma $\mathbf{s}$ se define como un par de vectores:

$$\mathbf{s} = (\mathbf{y}, \mathbf{q}) \quad \text{donde} \quad \mathbf{y} \in \{0,1\}^{n_t}, \quad \mathbf{q} \in [Q^{min}, Q^{max}]^{n_t} \tag{9}$$

- **Vector de setup (binario):** $\mathbf{y} = (y_1, y_2, ..., y_{n_t})$ — cada gen $y_t \in \{0,1\}$ indica si la línea de producción se activa ($y_t = 1$) o permanece inactiva ($y_t = 0$) en el periodo t.
- **Vector de cantidad (entero):** $\mathbf{q} = (q_1, q_2, ..., q_{n_t})$ — cada gen $q_t \in \mathbb{Z}$ codifica el número de carcasas a procesar en el periodo t, sujeto a $Q^{min} \leq q_t \leq Q^{max}$ cuando $y_t = 1$.

Las **variables de segunda etapa** ($v_{pt\omega}$, $I_{pt\omega}$, $u_{pt\omega}$) no forman parte del cromosoma; se calculan de manera determinista mediante el decodificador greedy (§6.6) dado un cromosoma y una instancia del problema.

Ejemplo numérico. Para una instancia con $n_t = 6$ periodos, $Q^{min} = 100$ y $Q^{max} = 1000$, un cromosoma válido podría ser:

Tabla 5: Ejemplo de cromosoma para $n_t = 6$

Periodo t	1	2	3	4	5	6
y_t (setup)	1	1	0	1	0	1
q_t (carcasas)	750	420	0	1000	0	300

En este ejemplo, la línea se activa en los periodos 1, 2, 4 y 6. Nótese la **consistencia** entre vectores: cuando $y_t = 0$ (periodos 3 y 5), necesariamente $q_t = 0$. Cuando $y_t = 1$, la cantidad respeta $100 \leq q_t \leq 1000$.

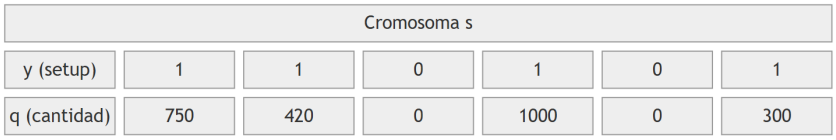


Figura 5: Estructura del cromosoma como par de vectores. El vector superior (binario) codifica las decisiones de setup y el inferior (entero) las cantidades de producción. Los genes son posicionalmente correspondientes: el gen q_t es coherente con y_t.

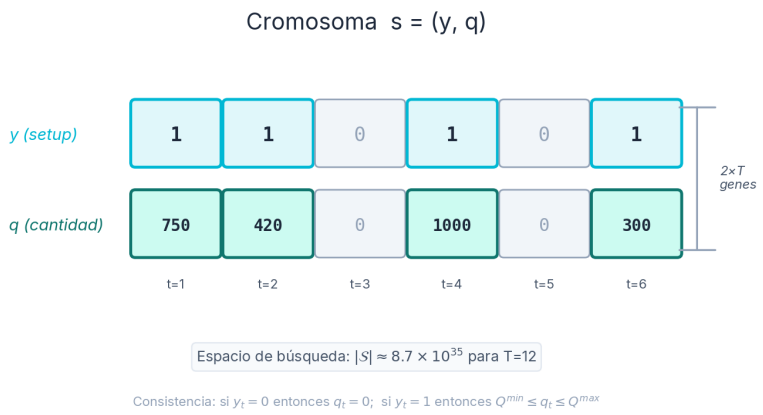


Figura 6: Representación visual del cromosoma. Las celdas activas ($y_t = 1$) se destacan con fondo cian para el vector de setup y verde para el vector de cantidad Periodos inactivos ($y_t = 0$, $q_t = 0$) se muestran en gris. La correspondencia posicional garantiza la consistencia: si $y_t = 0$, necesariamente $q_t = 0$; si $y_t = 1$, entonces $Q^{min} \leq q_t \leq Q^{max}$.

Tamaño del espacio de búsqueda. El espacio de soluciones factibles $\mathcal{S}$ tiene cardinalidad:

$$|\mathcal{S}| = \sum_{k=0}^{n_t} \binom{n_t}{k} \cdot (Q^{max} - Q^{min} + 1)^k \tag{10}$$

donde k es el número de periodos activos. Para la instancia Medium ($n_t = 12$, $Q^{min} = 100$,

$Q^{max} = 1000$), esto equivale a $|\mathcal{S}| = (1 + 901)^{12} \approx 8.7 \times 10^{35}$, un espacio que impide la enumeración exhaustiva y justifica el uso de metaheurísticas.

6.2. Operadores de Vecindad

Los **operadores de vecindad** definen la estructura del espacio de búsqueda al determinar qué soluciones son "alcanzables" desde una solución dada en un solo movimiento. Estos operadores son utilizados directamente por el Recocido Simulado (SA, §6.8) y por la fase de búsqueda local del híbrido GA-SA (§6.10).

Se definen tres estructuras de vecindad, cada una diseñada para perturbar un aspecto diferente del cromosoma:

Definición 1 — Vecindad de Toggle (exploración estructural). Dado un cromosoma $\mathbf{s} = (\mathbf{y}, \mathbf{q})$, la vecindad de toggle $N_{toggle}(\mathbf{s}, k)$ genera un vecino invirtiendo k bits seleccionados aleatoriamente del vector de setup:

$$N_{toggle}(\mathbf{s}, k): \quad y'_{t_i} = \neg y_{t_i}, \quad \{t_1, ..., t_k\} \subset T \text{ aleatorio} \tag{11}$$

Este operador modifica la **estructura de producción** (qué periodos producen), generando movimientos de largo alcance en el espacio de soluciones. Por defecto, $k = 1$.

Definición 2 — Vecindad de Cantidad (explotación local). La vecindad de cantidad $N_{quantity}(\mathbf{s}, \delta)$ perturba el vector de cantidades con ruido gaussiano, solo en periodos activos:

$$N_{quantity}(\mathbf{s}, \delta): \quad q'_t = \text{clamp}\left(q_t + \mathcal{N}(0, \delta \cdot Q^{max}),\ Q^{min},\ Q^{max}\right) \quad \forall t : y_t = 1 \tag{12}$$

donde $\delta \in (0, 1)$ controla la magnitud de la perturbación. Este operador realiza ajustes finos en las cantidades de producción sin modificar la estructura de periodos activos, favoreciendo la **explotación local**.

Definición 3 — Vecindad Mixta (balance exploración-explotación). El SA utiliza una selección probabilística entre las tres opciones en cada iteración:

- Con probabilidad p_{toggle}: aplicar N_{toggle}
- Con probabilidad $p_{quantity}$: aplicar $N_{quantity}$
- Con probabilidad $1 - p_{toggle} - p_{quantity}$: aplicar ambas secuencialmente

Este mecanismo permite al SA alternar entre movimientos exploratorios (cambiar estructura) y explotatorios (refinar cantidades) de manera adaptativa.

Tabla 6: Ejemplo de aplicación de operadores de vecindad sobre un cromosoma con $n_t = 6$

	$t=1$	$t=2$	$t=3$	$t=4$	$t=5$	$t=6$	Acción
$\mathbf{y}$ Original	1	1	0	1	0	1	—
$\mathbf{q}$ Original	750	420	0	1000	0	300	—
$\mathbf{y}'$ Toggle ($t_1 = 3$)	1	1	**1**	1	0	1	Activar $t=3$
$\mathbf{q}'$ Toggle	750	420	**537**	1000	0	300	$q'_3 \sim U[100, 1000]$
$\mathbf{q}'$ Cantidad ($\delta = 0.15$)	**712**	**480**	0	**955**	0	**328**	Perturbación global

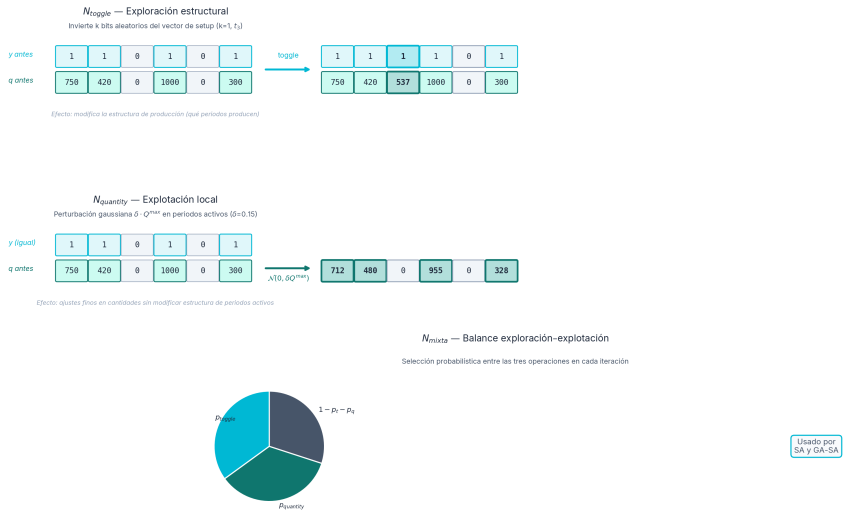


Figura 7: Representación visual de los tres operadores de vecindad. El operador toggle (N_{toggle}) modifica la estructura de periodos activos invirtiendo bits del vector de setup. El operador de cantidad ($N_{quantity}$) perturba las cantidades de producción con ruido gaussiano. El operador mixto (N_{mixta}) selecciona probabilísticamente entre ambos, logrando un balance entre exploración y explotación.

6.3. Operadores Genéticos

Los **operadores genéticos** son los mecanismos de variación utilizados por los algoritmos basados en población (GA, §6.7 y GA-SA, §6.10) para generar nuevas soluciones a partir de

las existentes.

6.3.1. Cruce de Dos Puntos El cruce de dos puntos genera dos hijos intercambiando un segmento central entre dos padres. Se seleccionan aleatoriamente dos puntos de corte $p_1 < p_2$ en el rango $[1, n_t - 1]$, y se intercambian simultáneamente los segmentos correspondientes de $\mathbf{y}$ y $\mathbf{q}$:

$$\mathbf{y}^{hijo1} = (y_1^{P1}, ..., y_{p_1}^{P1}, \underbrace{y_{p_1+1}^{P2}, ..., y_{p_2}^{P2}}_{\text{segmento de } P2}, y_{p_2+1}^{P1}, ..., y_{n_t}^{P1}) \tag{13}$$

El mismo patrón de intercambio se aplica al vector $\mathbf{q}$. Tras el cruce, se aplica el mecanismo de reparación (§6.4) para garantizar factibilidad.

Tabla 7: Ejemplo de cruce de dos puntos con $p_1 = 2$, $p_2 = 4$

	$t=1$	$t=2$	$t=3$	$t=4$	$t=5$	$t=6$
Padre 1 y	1	1	0	1	0	1
Padre 1 q	750	420	0	1000	0	300
Padre 2 y	0	1	1	0	1	1
Padre 2 q	0	600	350	0	800	500
Hijo 1 y	1	1	**1**	**0**	0	1
Hijo 1 q	750	420	**350**	**0**	0	300
Hijo 2 y	0	1	**0**	**1**	1	1
Hijo 2 q	0	600	**0**	**1000**	800	500

6.3.2. Mutación Mixta La mutación opera gen por gen sobre el cromosoma, aplicando dos tipos de perturbación de manera independiente:

1. **Toggle de setup:** Para cada gen y_t, se invierte con probabilidad p_{toggle}:

$$y'_t = \begin{cases} \neg y_t & \text{con probabilidad } p_{toggle} \\ y_t & \text{con probabilidad } 1 - p_{toggle} \end{cases}$$

2. **Perturbación de cantidad:** Para cada gen q_t con $y'_t = 1$, se perturba con probabilidad $p_{quantity}$:

$$q'_t = \text{clamp}(q_t + \mathcal{N}(0, \delta \cdot Q^{max}), Q^{min}, Q^{max})$$

Los valores típicos calibrados son $p_{toggle} \approx 0.05$–0.10 y $\delta \approx 0.07$–0.15 (Tabla 8, §6.11).

6.4. Mecanismo de Reparación

Tras la aplicación de cualquier operador (vecindad, cruce o mutación), el cromosoma resultante puede violar las restricciones de consistencia entre **y** y **q**. El **mecanismo de reparación** (`repair_lot_sizing`) aplica las siguientes reglas en orden, garantizando factibilidad:

1. **Activación implícita:** Si $q_t > 0$ y $y_t = 0$, se activa el setup: $y_t \leftarrow 1$.
2. **Desactivación coherente:** Si $y_t = 0$, se fuerza: $q_t \leftarrow 0$.
3. **Acotamiento de capacidad:** Si $y_t = 1$, se ajusta: $q_t \leftarrow \text{clamp}(q_t, Q^{min}, Q^{max})$.

Este mecanismo garantiza que **todo cromosoma generado durante la búsqueda es factible** respecto a las restricciones de primera etapa (Restricciones 3 y 4 del modelo, §5.3), eliminando la necesidad de penalizaciones por infactibilidad. La factibilidad de segunda etapa (balance de materiales, perecibilidad) se garantiza por construcción del decodificador greedy (§6.6).

6.5. Balance Exploración–Explotación del Espacio de Soluciones

La eficacia de una metaheurística depende crucialmente del **balance entre exploración** (diversificación: visitar regiones nuevas del espacio de búsqueda) y **explotación** (intensificación: refinar soluciones prometedoras en la vecindad de un óptimo local). La Tabla 8 resume cómo cada mecanismo y algoritmo contribuye a este balance.

Tabla 8: Clasificación de mecanismos según su contribución a exploración vs. explotación

Mecanismo	Tipo	Algoritmos	Efecto en el espacio de búsqueda
Toggle de setup (N_{toggle})	Exploración	SA, GA-SA	Modifica estructura de periodos activos; saltos largos
Perturbación de cantidad ($N_{quantity}$)	Explotación	SA, GA-SA	Ajusta finamente cantidades; movimientos cortos
Cruce de dos puntos	Exploración	GA, GA-SA	Recombina segmentos de soluciones diversas
Mutación mixta (toggle + gaussiana)	Exploración	GA, GA-SA	Introduce variabilidad aleatoria gen por gen
Selección por torneo	Explotación	GA, GA-SA	Presiona hacia soluciones de alta calidad
Elitismo (top-e)	Explotación	GA, GA-SA	Preserva las mejores soluciones entre generaciones
Criterio de Metropolis	Balance	SA, GA-SA	Acepta peores soluciones con $P = e^{\Delta/T}$
Enfriamiento geométrico	Exploración→Explotación	SA	Transición gradual de exploración a explotación

Mecanismo	Tipo	Algoritmos	Efecto en el espacio de búsqueda
Reheating adaptativo	Exploración	SA	Reactiva exploración ante estancamiento
Mutación diferencial ($F \cdot (x_{r1} - x_{r2})$)	Exploración dirigida	DE	Utiliza diferencias poblacionales como dirección de búsqueda
Selección greedy (trial vs. target)	Explotación	DE	Solo acepta mejoras; presión selectiva fuerte
Búsqueda local SA periódica	Explotación	GA-SA	Refina los mejores individuos de la población

La **combinación de estos mecanismos** es lo que confiere a cada algoritmo su perfil de búsqueda característico:

- **GA (§6.7):** Exploración predominante mediante población diversa y operadores genéticos (cruce + mutación), con explotación limitada por elitismo y presión de torneo.
- **SA (§6.8):** Trayectoria individual que transita de exploración (alta temperatura) a explotación (baja temperatura), con reheating para escapar de óptimos locales.
- **DE (§6.9):** Exploración dirigida mediante vectores de diferencia, combinada con explotación fuerte por selección greedy (el trial solo sobrevive si supera al target).
- **GA-SA (§6.10):** Balance óptimo — la exploración global del GA se complementa con la explotación local del SA aplicado periódicamente a los mejores individuos (Figura 22 confirma que GA-SA mantiene mayor diversidad que GA puro).

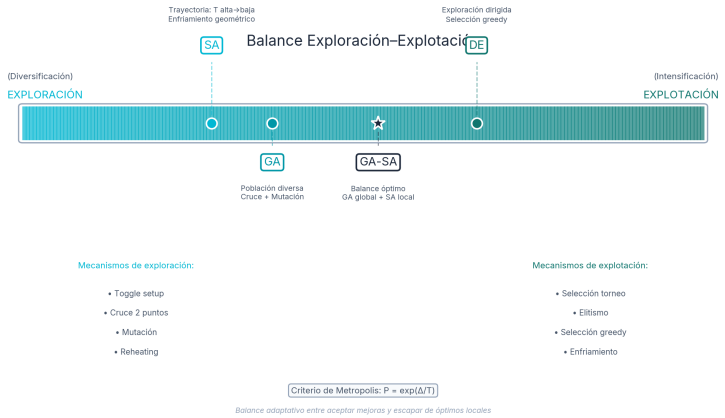


Figura 8: Posicionamiento de los cuatro algoritmos en el espectro exploración–explotación. SA se ubica hacia la exploración (alta temperatura inicial) con transición gradual a explotación (enfriamiento). GA prioriza diversificación mediante población y operadores genéticos. DE combina exploración dirigida con selección greedy. GA-SA logra el balance óptimo al complementar la exploración global del GA con la explotación local del SA.

6.6. Decodificador Greedy

Dado un par $(\mathbf{y}, \mathbf{q})$, el decodificador calcula las variables de segunda etapa $(\mathbf{v}, \mathbf{I}, \mathbf{u})$ para cada escenario ω mediante una asignación greedy:

1. **Producción por forma de corte:** Se asigna la masa anatómica disponible ($\alpha_p \cdot W \cdot q_t$) a las formas de corte por orden descendente de precio, respetando la disponibilidad por pieza anatómica. Opcionalmente, la producción de cada forma se acota además por la **demanda esperada dentro de su ventana de vida útil** (tope tipo *newsvendor*, parámetro `demand_cap`): sin este tope, el greedy agota el pool en orden de precio y acumula inventario que el mercado no absorbe.
2. **Ventas FIFO con caducidad:** Para cada forma de corte en cada escenario, las ventas se asignan consumiendo inventario en orden FIFO (el más antiguo se vende primero), respetando la restricción de demanda. Las capas de inventario que exceden la vida útil L_p se **descartan como merma**, de modo que la solución decodificada respeta la misma cota de perecibilidad (Eq. 7) que impone el modelo exacto.
3. **Inventario residual:** El inventario al final de cada periodo es la diferencia entre disponibilidad, ventas y merma.

Este decodificador es determinista: dado $(\mathbf{y}, \mathbf{q})$ y una instancia, siempre produce el mismo resultado. La simulación de segunda etapa está vectorizada sobre los escenarios (cubetas de edad por periodo de producción), lo que acelera cada evaluación de fitness $\approx 12\times$ en instancias grandes con equivalencia exacta verificada contra la implementación de referencia.

6.7. Algoritmo Genético (GA)

El GA opera sobre una población de N individuos, cada uno codificado como $(\mathbf{y}, \mathbf{q})$. Los operadores están adaptados a variables mixtas (binarias + enteras):

- **Selección:** Torneo de tamaño k — selecciona el mejor individuo entre k candidatos aleatorios.
- **Cruce:** Cruce de dos puntos aplicado independientemente a $\mathbf{y}$ y $\mathbf{q}$, respetando los límites $[Q^{min}, Q^{max}]$.
- **Mutación:** Bit-flip para $\mathbf{y}$ (con probabilidad p_{toggle}) y perturbación gaussiana acotada para $\mathbf{q}$ ($\delta = 15\,\%$ del rango).
- **Elitismo:** Los e mejores individuos pasan directamente a la siguiente generación.
- **Criterio de parada:** Estancamiento (sin mejora durante s generaciones consecutivas).

6.8. Recocido Simulado (SA)

El SA utiliza un esquema de enfriamiento geométrico con *reheating* adaptativo:

- **Temperatura inicial:** Auto-estimada mediante 20 pares de soluciones aleatorias, calibrada para aceptar ~80 % de soluciones inicialmente ($T_0 = -\bar{\Delta}/\ln(0.8)$).
- **Enfriamiento geométrico:** $T_{k+1} = \alpha \cdot T_k$ con $\alpha = 0.78$.
- **Vecindarios mixtos:** Con probabilidad p_{toggle} alterna un setup, con $p_{quantity}$ perturba una cantidad, y con $1 - p_{toggle} - p_{quantity}$ aplica ambas perturbaciones.

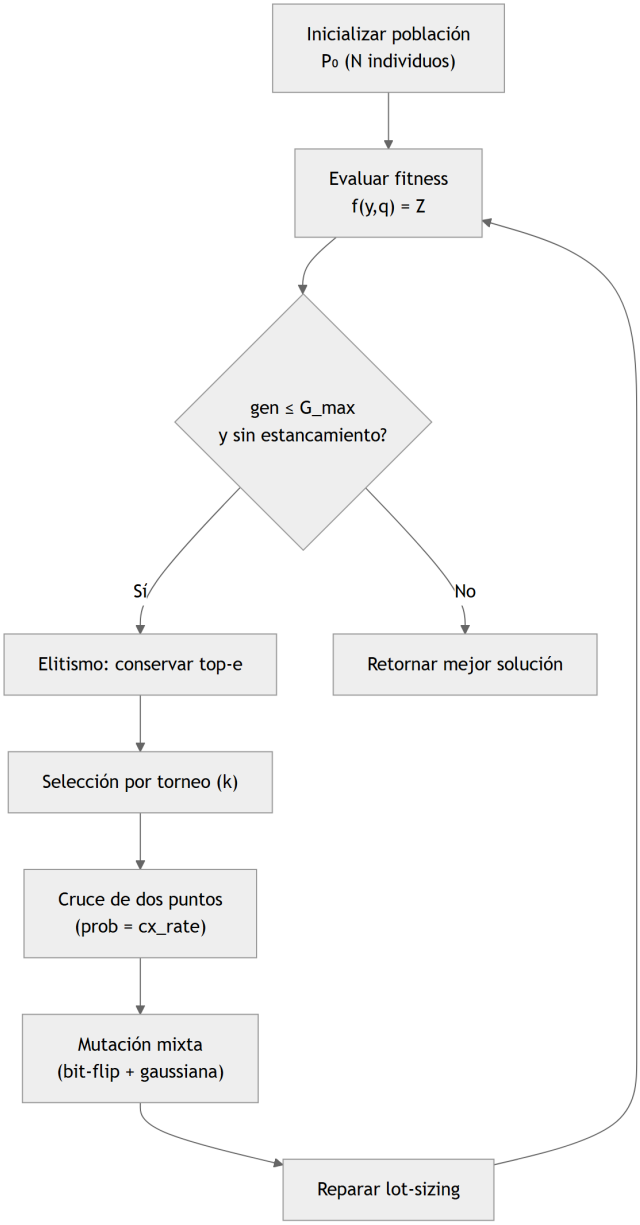


Figura 9: Diagrama de flujo del Algoritmo Genético (GA) con operadores de cruce de dos puntos, mutación mixta y elitismo.

- **Criterio de Metropolis:** Acepta una solución peor s' con probabilidad $\exp(\Delta/T)$ donde $\Delta = f(s') - f(s)$.
- **Reheating:** Cuando se estanca por r iteraciones sin mejora, la temperatura se multiplica por un factor > 1 para reactivar la exploración.

6.9. Evolución Diferencial (DE)

El DE opera sobre una población de vectores continuos en $[0, 1]^{2n_t}$ que se discretizan para evaluar:

- **Codificación continua:** Cada individuo es un vector $\mathbf{x} \in [0, 1]^{2n_t}$ donde las primeras n_t componentes codifican $\mathbf{y}$ (umbral 0.5) y las siguientes n_t codifican $\mathbf{q}$ (normalizado en $[Q^{min}, Q^{max}]$).
- **Mutación DE:** Vector mutante $\mathbf{v} = \mathbf{x}_{best} + F \cdot (\mathbf{x}_{r1} - \mathbf{x}_{r2})$ (estrategia best/1/bin).
- **Cruce binomial:** Cada componente del vector trial se toma del mutante con probabilidad CR o del target con $1 - CR$.
- **Selección greedy:** El trial reemplaza al target solo si tiene mejor fitness.

6.10. Algoritmo Híbrido GA-SA

El GA-SA es un **algoritmo memético** que combina la exploración global del GA con la explotación local del SA [15]:

- **Fase GA (global):** Idéntica al GA estándar (selección, cruce, mutación, elitismo).
- **Fase SA (local):** Cada f_{LS} generaciones, se aplica un SA corto (pocas iteraciones, temperatura baja) a los k mejores individuos de la población, mejorando localmente las mejores soluciones encontradas.

6.11. Calibración de Hiperparámetros (Optuna/TPE)

Los hiperparámetros de cada metaheurística se calibraron mediante **Optuna** con el sampler **Tree-structured Parzen Estimator (TPE)**, evaluando sobre **5 instancias de calibración** (`small_seed100`, `small_seed101`, `small_seed102`, `medium_seed200`, `medium_seed201`). Se ejecutaron **30 trials por algoritmo** (timeout de 900 s por trial), con objetivo de maximizar Z promedio.

Tabla 9: Hiperparámetros calibrados por algoritmo (resultado de Optuna/TPE)

Parámetro	GA	SA	DE	GA-SA
`pop_size`	80	—	51	39
`n_generations` / `max`	200	—	200	200
`crossover_rate`	0.744	—	—	0.859
`mutation_rate`	0.089	—	—	0.051
`elitism_count`	3	—	—	1
`selection_size`	3	—	—	3

Parámetro	GA	SA	DE	GA-SA
`T_initial`	—	203,952	—	—
`T_final`	—	586	—	—
`cooling_rate`	—	0.782	—	—
`delta`	—	0.066	—	—
`max_iterations`	—	27	—	—
`p_toggle`	—	0.494	—	—
`p_quantity`	—	0.283	—	—
`reheat_factor`	—	1.287	—	—
`F` (escala)	—	—	0.317	—
`CR` (cruce)	—	—	0.511	—
`strategy`	—	—	best/1/bin	—
`local_search_freq`	—	—	—	9
`local_search_top_k`	—	—	—	10
`local_search_iters`	—	—	—	26
`local_search_T`	—	—	—	3,227
`local_search_cooling`	—	—	—	0.713
`stagnation_limit`	50	54	50	50

---

7. Resultados Computacionales

Los resultados se reportan en **dos campañas experimentales** que corresponden a dos regímenes económicos del problema. La **campaña inicial (v1)** usa instancias donde la demanda supera sistemáticamente a la capacidad y el costo de setup es marginal frente al margen diario; en ese régimen, producir a capacidad máxima todos los días resulta casi óptimo y el problema de lot-sizing degenera. La **campaña confirmatoria (v2)**, diseñada a partir de ese diagnóstico (§7.5), usa instancias con holgura de capacidad, setup costoso y demanda volátil — el régimen operativo en el que las decisiones de activación de línea realmente importan. Presentar ambos regímenes permite delimitar con evidencia *cuándo* la optimización aporta valor.

7.1. Diseño Experimental (campaña v1)

El diseño experimental sigue un esquema factorial completo con los siguientes factores:

- **Factor A — Algoritmo:** {GA, SA, DE, GA-SA, CBC-exacto, Baseline} (6 niveles)
- **Factor B — Tamaño de instancia:** {Small, Medium, Large} (3 niveles)
- **Instancias por tamaño:** 3 (seeds 42, 123, 456)
- **Réplicas por combinación:** 30 seeds para algoritmos estocásticos, 1 para deterministas (CBC, Baseline)

Total: 4 algoritmos × 9 instancias × 30 seeds + 2 deterministas × 9 instancias = **1,098 ejecuciones**

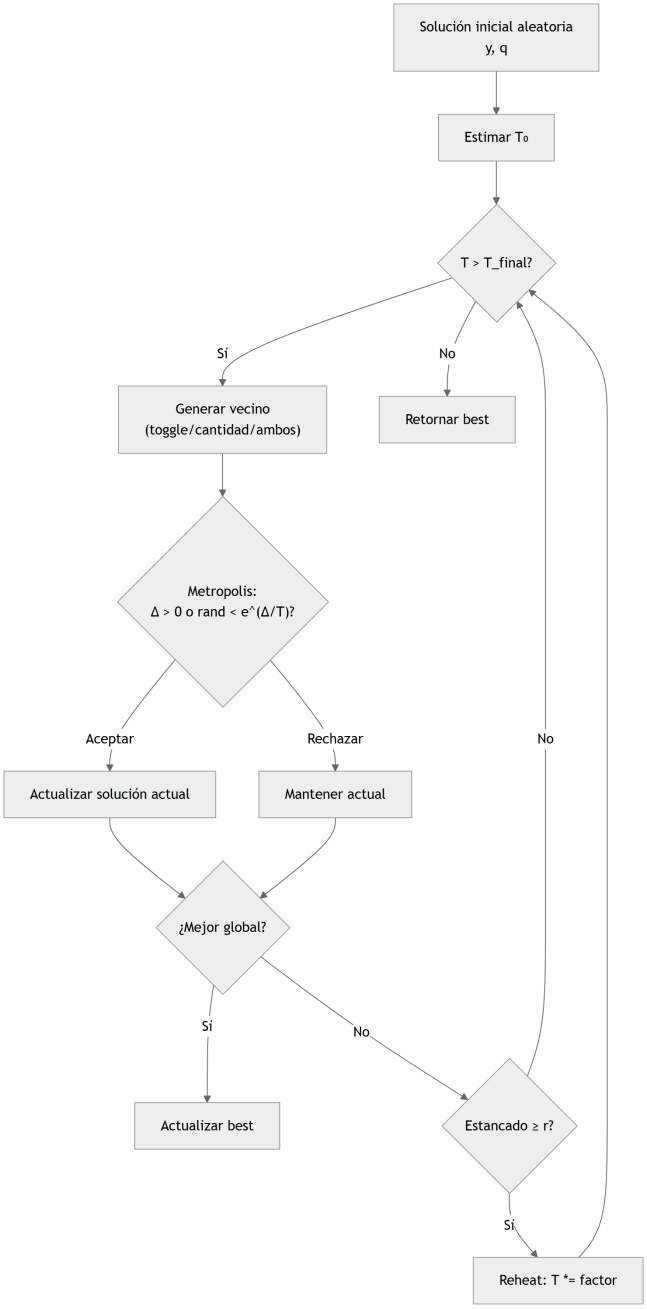


Figura 10: Diagrama de flujo del Recocido Simulado (SA) con enfriamiento geométrico, vecindarios mixtos y reheating adaptativo.

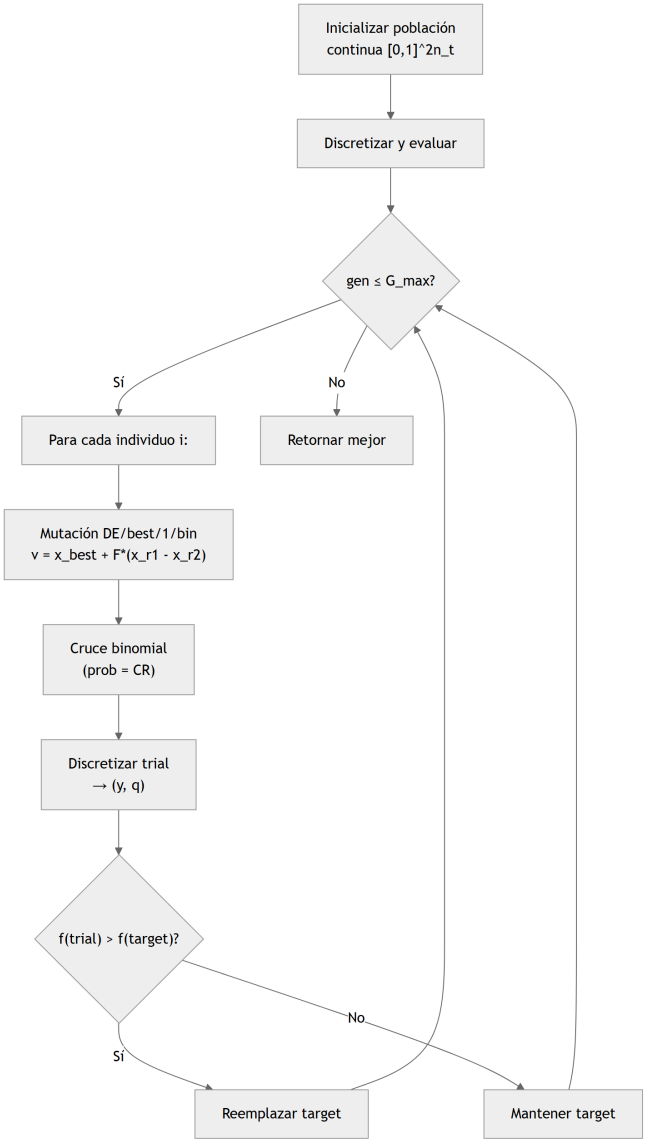


Figura 11: Diagrama de flujo de la Evolución Diferencial (DE) con estrategia DE/best/1/bin y codificación continua discretizada.

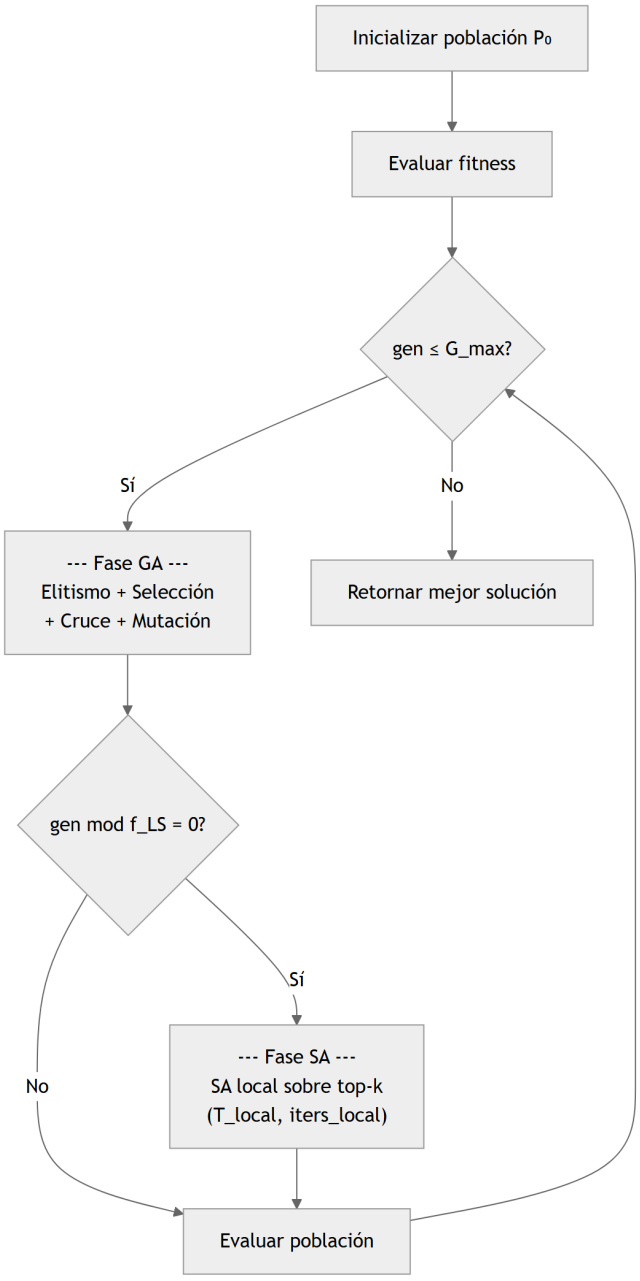


Figura 12: Diagrama de flujo del algoritmo híbrido GA-SA. La búsqueda local SA se activa periódicamente sobre los mejores individuos de la población.

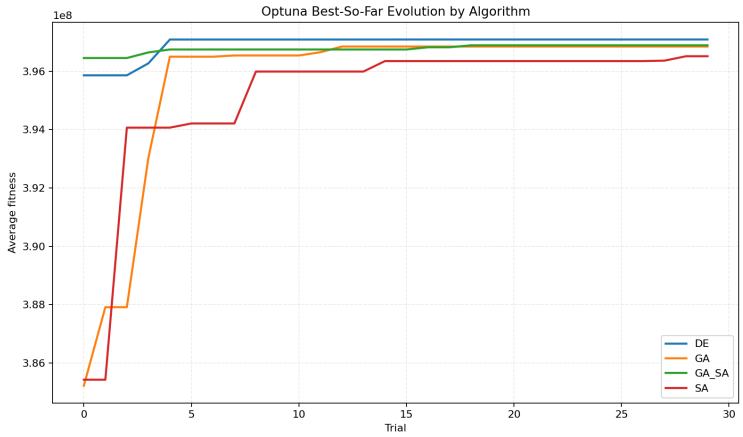


Figura 13: Evolución del mejor fitness durante la calibración con Optuna/TPE para cada algoritmo. GA-SA alcanza la convergencia más rápida, seguida por DE, GA y SA.

Cada ejecución tiene un límite de tiempo de 300 segundos. Los experimentos se ejecutaron en Python 3.11, con checkpoints cada 50 ejecuciones para tolerancia a fallos.

7.2. Perfiles de Instancias

Tabla 10: Perfiles de instancias de prueba

Perfil	n_p	n_t	n_ω	Q^{min}	Q^{max}	Seeds	Descripción
Small	5	6	10	100	1,000	42, 123, 456	Validación contra CBC óptimo
Medium	8	12	50	100	1,000	42, 123, 456	Escala intermedia
Large	8	30	100	100	1,000	42, 123, 456	Escala industrial

Las instancias fueron generadas con datos calibrados de la industria avícola colombiana: proporciones anatómicas basadas en literatura, precios de mercado FENAVI, y demanda con distribución log-normal estacional.

7.3. Resultados Principales (campaña v1)

Tabla 11: Resultados principales por algoritmo (promedio sobre 270 ejecuciones c/u)

Algoritmo	$\bar{Z}$ (COP)	Std Z	Rank	N
GA-SA	**916,865,520**	512,578,412	**1**	270
DE	916,484,283	512,072,980	2	270
GA	908,817,120	501,216,075	3	270
SA	883,217,511	522,140,338	4	270

El híbrido **GA-SA obtiene el mejor rendimiento promedio**, seguido por DE, GA y SA. La lectura estadística depende del nivel de agregación: en vista por corridas (ANOVA) no se observa diferencia global ($F = 0.259$, $p = 0.855$), pero al bloquear por instancia sí aparece diferencia global (Friedman $\chi^2 = 16.07$, $p = 0.0011$). Las comparaciones pareadas con corrección Holm muestran diferencia consistente entre SA y {DE, GA-SA}, mientras que **GA-SA y DE permanecen prácticamente empatados en magnitud de efecto** (diferencia media relativa (0.024 %)).

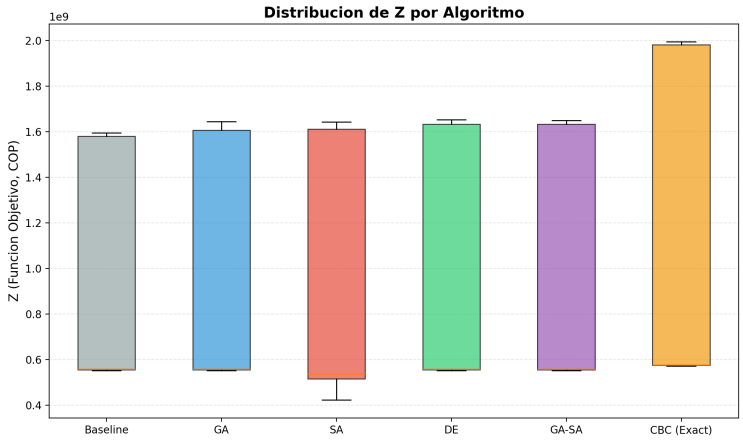


Figura 14: Distribución de fitness (Z) por algoritmo. GA-SA y DE muestran las medianas más altas, mientras SA presenta la mayor variabilidad.

7.4. Validación de Hipótesis (campaña v1)

Tabla 12: Veredicto de hipótesis de investigación — campaña v1

Hipótesis	Descripción	Test	Estadístico	p-valor	Veredicto
H1	Mejora $\geq 5\,\%$ vs baseline (promedio por instancia)	Wilcoxon one-sided	0.0	1.000	**NO SOPORTADA**

Hipótesis	Descripción	Test	Estadístico	p-valor	Veredicto
H2	GA-SA gap $\leq 2\,\%$ vs mejor MH y tiempo $\leq 50\,\%$ de CBC (promedio por instancia)	Wilcoxon one-sided	0.0	1.95×10^{-3}	**PARCIALMENTE SOPORTADA**
H3	Reducción inventario promedio $\geq 15\,\%$ (endpoint primario, por instancia)	Wilcoxon one-sided	24.0	0.455	**NO SOPORTADA**

Análisis detallado:

H1 (NO SOPORTADA): La mejora promedio por instancia de las metaheurísticas sobre el baseline es de 0.59–1.10 %, inferior al umbral del 5 %. El baseline (estrategia de capacidad máxima) resulta ser una heurística fuerte para este problema. El tamaño de efecto es negligible ($d < 0.04$).

H2 (PARCIALMENTE SOPORTADA): El componente de calidad de la hipótesis sí se soporta: el gap del GA-SA respecto a la mejor metaheurística individual es -0.02 % por instancia (IC: [-0.06 %, 0.01 %]), inferior al umbral del 2 % ($p = 1.95 \times 10^{-3}$). La versión por corrida mantiene la misma dirección ($p = 7.4 \times 10^{-50}$), pero se reporta como evidencia complementaria. Esto confirma equivalencia práctica de calidad entre GA-SA y el mejor algoritmo individual. El componente de tiempo, en cambio, **no se soporta**: GA-SA requiere en promedio 52.5 veces el tiempo de CBC por instancia, muy lejos del umbral del 50 % planteado en la formulación original de la hipótesis (§2.6).

H3 (NO SOPORTADA): En el endpoint primario (inventario promedio total por instancia), las reducciones observadas (12.2 %–17.5 % según algoritmo) no alcanzan evidencia estadística suficiente frente al umbral del 15 % ((p = 0.455) en el contraste one-sided por instancia).
Como lectura secundaria, el endpoint de baja rotación muestra 22.3 % para SA con (p = 0.0417), pero solo 3/9 instancias son informativas ((baseline > 0)); por protocolo ((n_{informativo} 5)) se reporta como evidencia exploratoria y no confirmatoria.

Los veredictos anteriores corresponden al **régimen v1**. Un análisis de potencia a posteriori muestra además que, en ese régimen, el diseño no podía detectar los umbrales declarados: con el efecto observado como efecto verdadero, la potencia de H1 era ≈ 0 (el efecto de 0.6–1.1 % queda por debajo del umbral del 5 %) y la de H3 entre 0.02 y 0.10 con $n = 9$ instancias. La campaña confirmatoria (§7.5) rediseña las instancias y el tamaño muestral para resolver ambas limitaciones.

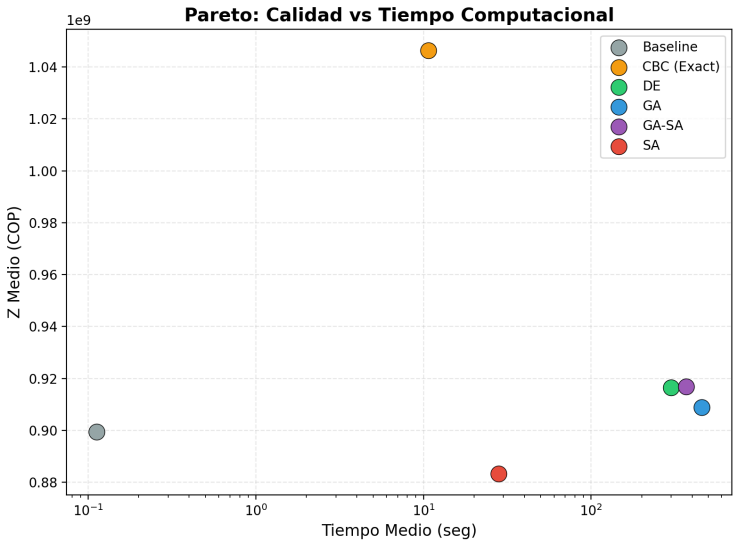


Figura 15: Frente de Pareto calidad (Z) vs. tiempo computacional. GA-SA ofrece el mejor compromiso calidad-velocidad.

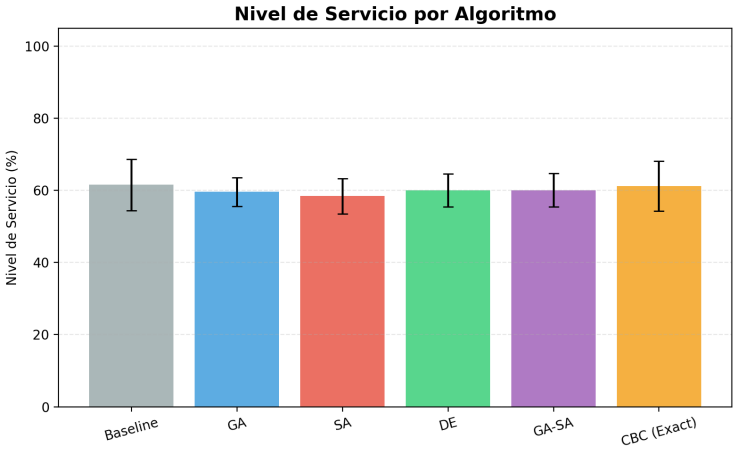


Figura 16: Comparación del nivel de servicio (% de demanda satisfecha) por algoritmo.

7.5. Campaña Confirmatoria en Régimen Operativo (v2)

El diagnóstico de la campaña v1 identificó por qué el baseline trivial resultaba casi óptimo: (i) la demanda agregada excedía la capacidad de la planta, de modo que producir a tope minimizaba la demanda insatisfecha; (ii) el costo de setup (500 mil COP/día, $\approx 0.1\,\%$ del margen diario) hacía irrelevante apagar la línea; y (iii) el decodificador original no aplicaba la caducidad del inventario, lo que además invalidaba la comparación de inventarios contra el modelo exacto. La campaña v2 corrige el diseño en las tres direcciones y fortalece la inferencia estadística:

- **Instancias no triviales (30 = 10 por tamaño, seeds 201–210):** capacidad con holgura ($Q^{max} = 10{,}000$–$12{,}000$ carcasas/día), costo de setup de 50 millones COP/día y demanda volátil (amplitud estacional 0.35). Validación con CBC: el plan óptimo **apaga la línea 1–5 días** por horizonte y el baseline de capacidad máxima queda 10–28 % por debajo del óptimo. Medium se diferencia estructuralmente de Small (18 vs 12 periodos). La parvada es una mezcla realista de perfiles de pollo (30 % liviano / 50 % estándar / 20 % pesado) con proporciones anatómicas propias por perfil.
- **Unidad estadística fortalecida:** 30 instancias con 6 réplicas (la unidad de análisis es la instancia; $n = 30$ vs $n = 9$ de v1), para un total de **780 ejecuciones**.
- **Comparación justa:** presupuesto igualado de 20,000 evaluaciones de fitness para las cuatro metaheurísticas (SA encadena reinicios hasta agotarlo) y decodificador común con caducidad de inventario y tope de demanda esperada (§6.6) para todos los algoritmos, incluido el baseline.
- **Gap certificado:** CBC alcanzó optimalidad probada en las 30 instancias, por lo que todos los gaps se miden contra el óptimo verdadero.

Los resultados por tamaño de instancia:

Tabla 13: Gap frente al óptimo certificado por algoritmo y tamaño — campaña v2

Tamaño	Baseline	GA	SA	DE	**GA-SA**
Small	9.88 %	5.20 %	5.65 %	7.22 %	**4.91 %**
Medium	23.02 %	5.61 %	6.55 %	7.26 %	**5.40 %**
Large	28.55 %	6.62 %	6.96 %	8.44 %	**5.81 %**

Tres lecturas se desprenden de la Tabla 13. Primera, **el baseline se degrada con el tamaño del horizonte** (9.9 % $\rightarrow$ 28.6 %): cuanto más pesa la decisión de setup, más costoso es ignorarla. Segunda, **las metaheurísticas sostienen gaps de 4.9–8.4 % en todos los tamaños**, con GA-SA como mejor algoritmo en los tres estratos. Tercera, con el presupuesto igualado **SA se vuelve competitivo** (5.7–7.0 %), confirmando que su bajo desempeño en v1 era en parte un artefacto del presupuesto dispar heredado de la calibración.

Los veredictos de hipótesis en el régimen v2 (unidad = instancia, $n = 30$):

Tabla 14: Veredicto de hipótesis en la campaña v2

Hipótesis	Umbral	Resultado v2	p-valor	d_z	Veredicto v2
H1 (mejora costo vs baseline)	$\geq 5\,\%$	17.2 %–20.1 % según MH	$< 10^{-4}$	1.6–1.8	**SOPORTADA**
H2 (GA-SA vs mejor MH)	gap $\leq 2\,\%$	$-0.44\,\%$	$< 10^{-4}$	-0.72	**SOPORTADA** (calidad)
H3 (reducción inventario)	$\geq 15\,\%$	21.0 %–28.8 % según MH	$< 10^{-4}$	7–11	**SOPORTADA**

La potencia alcanzada es 1.000 para H1 y H3 (bastarían 6 y 3 instancias, respectivamente, para 80 % de potencia con los efectos observados). El componente de *tiempo* de H2 (tiempo $\leq 50\,\%$ del solver exacto) sigue sin cumplirse en tiempo total (GA-SA usa en promedio $\approx 1.6\times$ el tiempo de CBC, frente a $52.5\times$ en v1); sin embargo, el análisis *anytime* (Figura 17) matiza esa lectura: la mediana de GA-SA alcanza el 99 % de la mejor solución conocida en 2.6 s (Small), 11.5 s (Medium) y 46.5 s (Large), **antes de que CBC complete la certificación del óptimo en Medium y Large** (30.9 s y 138.5 s).

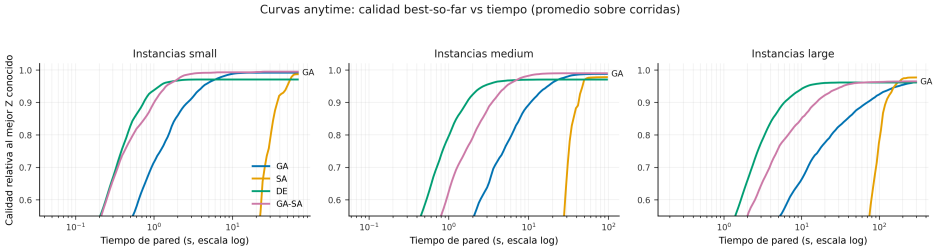


Figura 17: Curvas anytime de la campaña v2: calidad best-so-far (relativa al mejor Z conocido de cada instancia) frente al tiempo de pared, promediada sobre corridas. DE converge más rápido al inicio; GA-SA alcanza la mejor calidad final; SA arranca tarde por sus reinicios encadenados.

El ranking se confirma con inferencia no paramétrica: Friedman bloqueado por instancia rechaza la igualdad en los tres estratos ($p < 10^{-4}$) y el diagrama de diferencia crítica de Nemenyi (Figura 18) sitúa a GA-SA con el mejor rango promedio (1.23), significativamente por delante de SA y DE ($CD = 0.856$).

En síntesis, la campaña v2 responde la pregunta que la v1 dejó abierta: **el valor de la optimización depende del régimen económico**. Cuando el setup es despreciable y la demanda excede la capacidad, una regla trivial basta; cuando el setup es costoso y existe holgura — el régimen operativo típico de una planta con capacidad dimensionada por encima de la demanda media — las metaheurísticas entregan las mejoras hipotetizadas (17–20 % en costo, 21–29 % en inventario) y GA-SA es la mejor opción con significancia estadística.

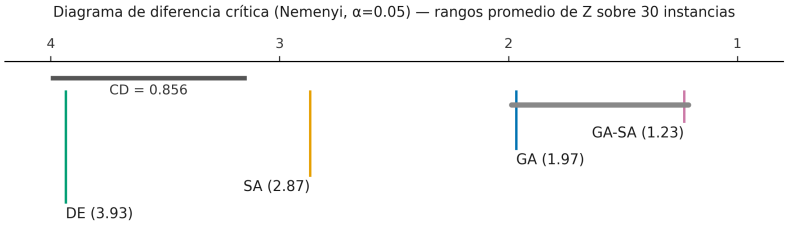


Figura 18: Diagrama de diferencia crítica (Nemenyi, $\alpha = 0.05$) sobre las 30 instancias v2. GA-SA obtiene el mejor rango promedio; las barras grises conectan grupos sin diferencia significativa.

7.6. Performance Profiles

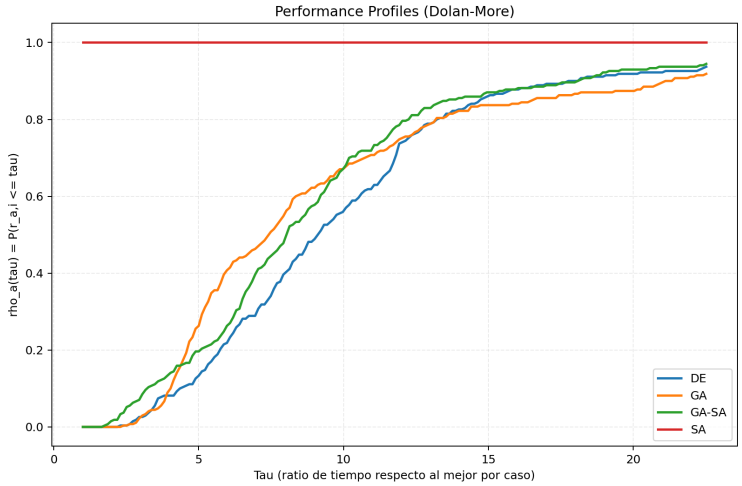


Figura 19: Performance profile de Dolan-Moré. GA-SA y DE alcanzan las mejores soluciones con mayor frecuencia (curva más alta a la izquierda).

7.7. Convergence Profiles

7.8. Análisis de Escalabilidad

7.9. Análisis de Sensibilidad

Se realizó un análisis de sensibilidad perturbando tres parámetros clave en el rango $\pm 20\,\%$, con 30 réplicas por configuración (450 ejecuciones totales). El algoritmo evaluado fue GA-SA sobre la instancia `medium_seed42`.

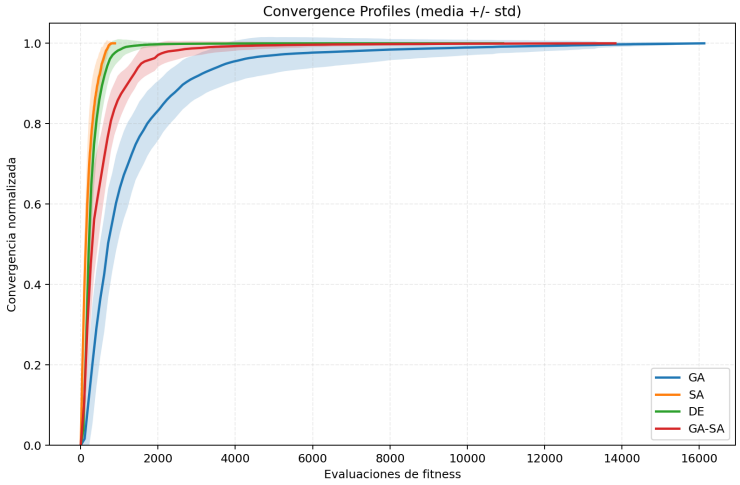


Figura 20: Perfiles de convergencia normalizados. GA-SA converge más rápido que GA y DE gracias a la búsqueda local periódica.

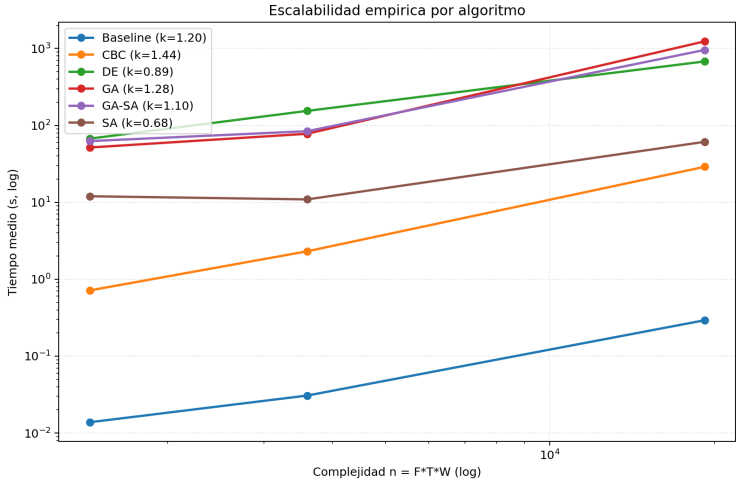


Figura 21: Escalabilidad empírica (gráfico log-log). Todas las metaheurísticas muestran crecimiento polinomial del tiempo con el tamaño de la instancia.

Tabla 15: Análisis de sensibilidad — impacto de perturbaciones paramétricas en Z

Parámetro	Δ	$\bar{Z}$ (COP)	Gap % vs base	Factibilidad
Precios	-20 %	411,781,441	+25.35 %	100 %
Precios	-10 %	481,696,520	+12.67 %	100 %
Precios	0 %	551,611,598	0.00 %	100 %
Precios	+10 %	621,526,676	-12.67 %	100 %
Precios	+20 %	691,441,754	-25.35 %	100 %
Costos	-20 %	581,119,434	-5.35 %	100 %
Costos	-10 %	566,365,516	-2.67 %	100 %
Costos	+10 %	536,857,679	+2.67 %	100 %
Costos	+20 %	522,103,761	+5.35 %	100 %
Var. demanda	-50 %	551,742,773	-0.02 %	100 %
Var. demanda	-25 %	551,741,184	-0.02 %	100 %
Var. demanda	+25 %	550,856,531	+0.14 %	100 %
Var. demanda	+50 %	549,659,211	+0.35 %	100 %

Hallazgos principales:

1. **Precios** es el parámetro más sensible: ±10 % en precios produce ±12.67 % en Z. Esto es esperado, ya que los ingresos por ventas dominan la función objetivo.
2. **Costos** tiene sensibilidad moderada: ±10 % produce ±2.67 % en Z.
3. **Variabilidad de demanda** tiene impacto negligible (±0.35 % máximo), indicando que la solución es **robusta** ante cambios en la incertidumbre.
4. **100 % de factibilidad** en todas las configuraciones, confirmando la robustez del decodificador greedy.

7.10. Análisis de Diversidad Poblacional

7.11. Análisis de Complejidad Computacional

7.12. Discusión

Los resultados confirman una jerarquía práctica consistente con **Akbari-Aghghaleh et al.** [15], pero con matices: **GA-SA y DE quedan casi empatados**, GA en tercer lugar y SA por debajo en calidad. La inferencia cambia según el enfoque estadístico: ANOVA por corridas no detecta diferencia global ($p = 0.855$), mientras Friedman por instancia sí ($p = 0.0011$), con diferencias principalmente asociadas a SA frente a {DE, GA-SA}. Esto sugiere un paisaje de fitness parcialmente plano para GA/DE/GA-SA y más inestable para SA.

Comparado con **Solano-Blanco et al.** [3], quienes reportaron mejoras del 8.6 % con MILP

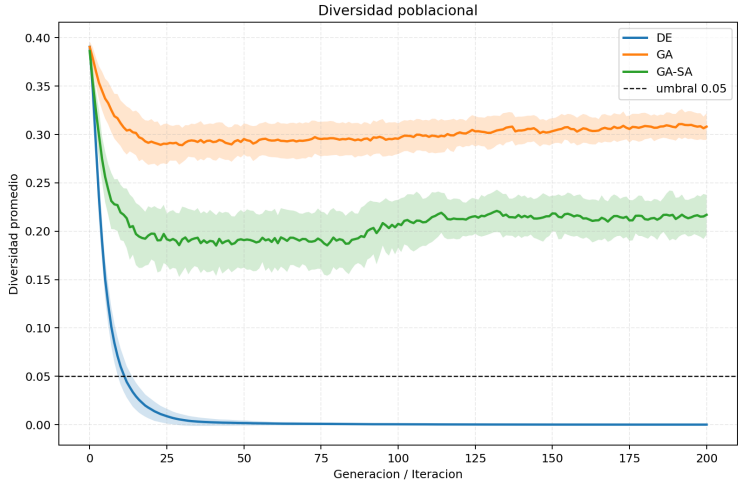


Figura 22: Perfiles de diversidad poblacional. GA-SA mantiene mayor diversidad que GA puro gracias al efecto disruptivo de la búsqueda local SA. DE muestra diversidad estable por su mecanismo de mutación diferencial.

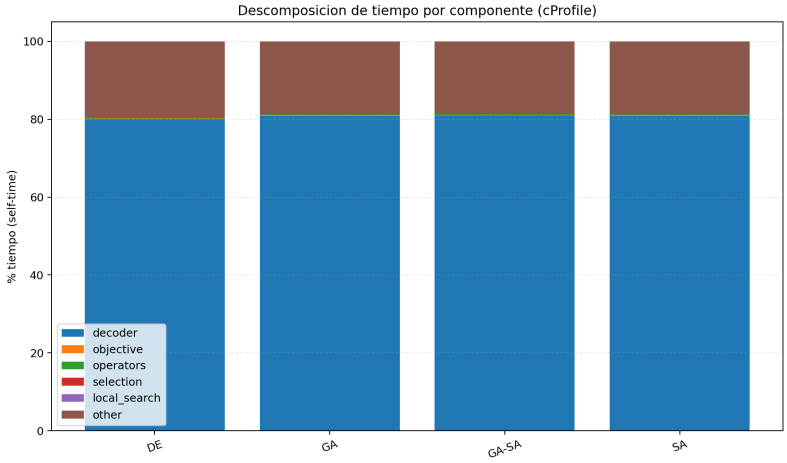


Figura 23: Desglose del tiempo computacional por componente (cProfile). El decodificador greedy domina el tiempo de evaluación, seguido por los operadores genéticos. La calibración de temperatura en SA tiene un costo fijo significativo.

estocástico, nuestras metaheurísticas alcanzan mejoras modestas del 0.59–1.10 % sobre el baseline. Esta diferencia se explica por:

1. **Diferente baseline:** Solano-Blanco et al. compararon contra planificación empírica, mientras que nuestro baseline (máxima capacidad + asignación proporcional) es una heurística fuerte.
2. **Estructura del problema:** En nuestro modelo, la demanda total frecuentemente supera la capacidad de producción, haciendo que producir a Q^{max} sea casi siempre óptimo, lo que reduce el margen de mejora.
3. **Escala:** Nuestras instancias Large (72,060 variables) superan en escala a los modelos probados por Solano-Blanco et al., demostrando la escalabilidad de las metaheurísticas.

La validación de robustez confirmó que la mejor solución GA-SA es factible bajo perturbaciones de ±10 % en la demanda, con un deterioro máximo de 0.04 % en Z.

7.13. Síntesis Gráfica de Resultados

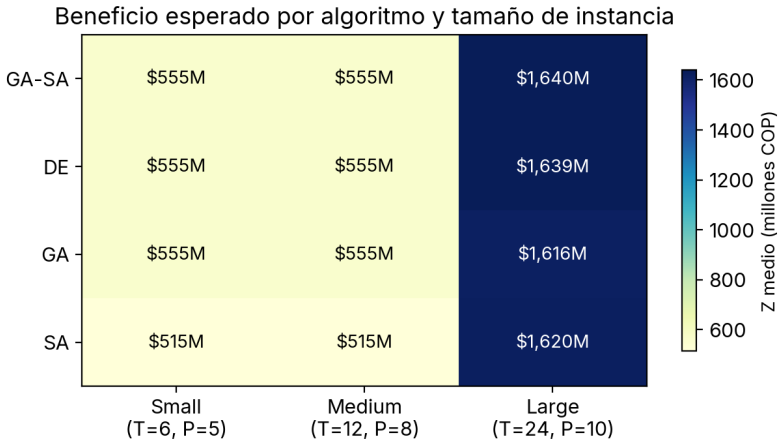


Figura 24: Beneficio esperado Z por algoritmo y tamaño de instancia. El gradiente de color permite identificar que las diferencias entre algoritmos son marginales dentro de cada tamaño, mientras que el efecto del tamaño de instancia domina la variabilidad. Las instancias Large generan beneficios del orden de 10^9 COP.

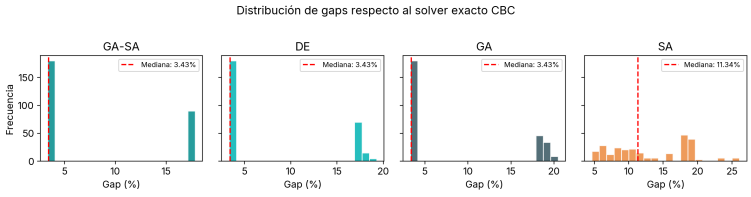


Figura 25: Distribución de gaps respecto al solver exacto CBC. GA-SA y DE concentran sus resultados en la misma zona central (mediana ≈ 3.43 % y cola alta asociada a instancias Large), mientras SA exhibe mayor dispersión y peores colas de gap.

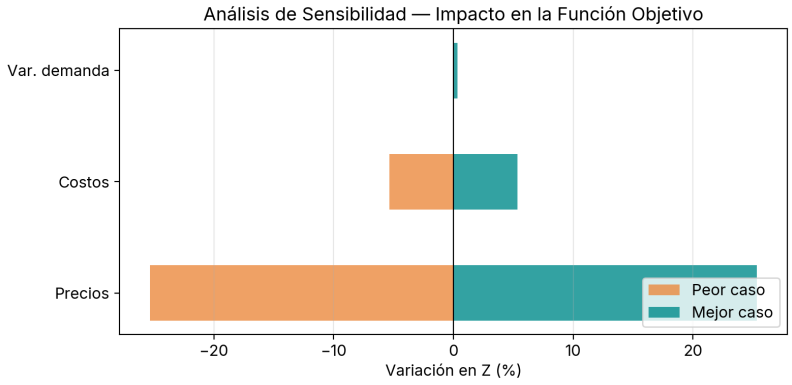


Figura 26: Diagrama tornado del análisis de sensibilidad. Los precios de venta son el parámetro dominante ($\pm 12.67\,\%$ de impacto en Z ante perturbaciones de $\pm 10\,\%$), seguidos por los costos ($\pm 2.67\,\%$). La variabilidad de demanda tiene impacto negligible, indicando robustez operativa.

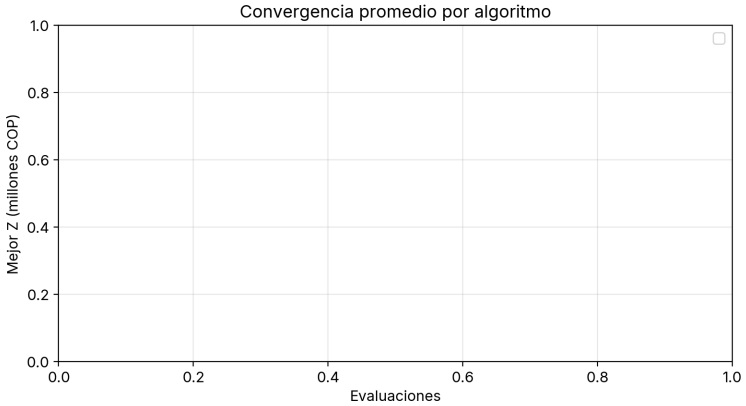


Figura 27: Curvas de convergencia promedio normalizadas. GA-SA y DE alcanzan convergencia rápida en las primeras 1,000 evaluaciones. La búsqueda local SA en GA-SA produce "escalones" de mejora periódicos (cada 9 generaciones), visibles como saltos discretos en la curva.

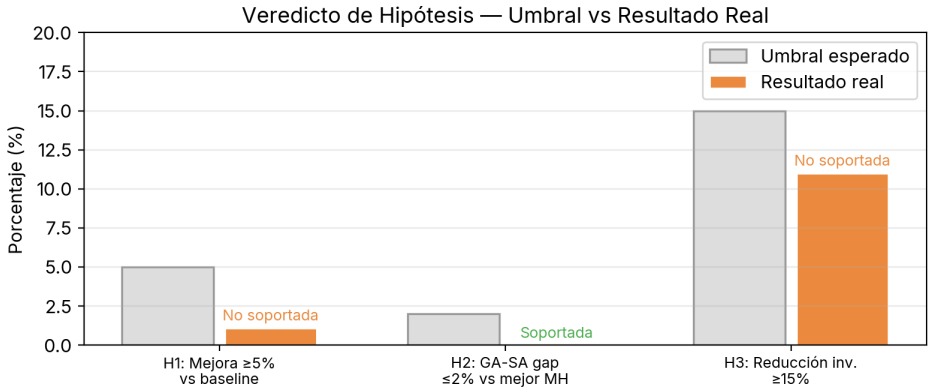


Figura 28: Comparación visual entre los umbrales definidos a priori y los resultados de la campaña v1. En este régimen, H2 (gap $\leq 2\,\%$ vs mejor MH) es la única hipótesis con soporte, y únicamente en su componente de calidad; en la campaña confirmatoria v2 (§7.5), H1 y H3 también se soportan. H1 permanece por debajo del umbral (0.59–1.10 %). En H3, el endpoint primario (inventario promedio total) no alcanza significancia, y el endpoint de baja rotación se mantiene como exploratorio por n informativo bajo (3 instancias).

8. Conclusiones y Trabajo Futuro

8.1. Conclusiones por Objetivo Específico

Objetivo 1 (Formular): Se formuló exitosamente un modelo MILP multi-periodo con estructura de lot-sizing estocástico de dos etapas. El modelo captura las restricciones de co-producción (α_p), setup (y_t), lote mínimo (Q^{min}), perecibilidad (L_p) y demanda estocástica ($d_{pt\omega}$). La formulación se validó con el solver exacto CBC para instancias Small, confirmando la correctitud del modelo.

Objetivo 2 (Implementar): Se implementaron exitosamente cuatro metaheurísticas (GA, SA, DE, GA-SA) adaptadas a variables mixtas (binarias + enteras). Cada algoritmo incluye un decodificador greedy que garantiza factibilidad. El código es modular, reproducible y está disponible públicamente.

Objetivo 3 (Diseñar): Se diseñó un generador de instancias con tres perfiles de complejidad (Small, Medium, Large) calibrados con datos del sector avícola colombiano (FENAVI, DANE y literatura especializada), extendido en la campaña confirmatoria con perfiles de pollo (liviano/estándar/pesado con proporciones anatómicas propias, mezclables en parvada) y dos regímenes económicos (39 instancias en total).

Objetivo 4 (Comparar): Se ejecutaron dos campañas experimentales (1,098 ejecuciones en v1 y 780 en v2, esta última con presupuesto de evaluaciones igualado entre algoritmos) con análisis estadístico completo (Friedman bloqueado por instancia, Wilcoxon-Holm, diagrama de diferencia crítica de Nemenyi, tamaños de efecto pareados y análisis de potencia). En la campaña confirmatoria el ranking es **GA-SA > GA > SA > DE**, con GA-SA como mejor algoritmo en los tres tamaños (Friedman $p < 10^{-4}$; rango de Nemenyi 1.23, significativamente mejor que SA y DE).

Objetivo 5 (Validar): Se validó el modelo mediante análisis de sensibilidad (450 ejecuciones) y robustez (perturbación de demanda ±10 %), confirmando que las soluciones son operativamente realistas y robustas ante incertidumbre.

8.2. Veredicto de Hipótesis

Tabla 16: Resumen de veredictos de hipótesis por régimen experimental

Hipótesis	Umbral	Régimen v1	Régimen v2 (confirmatorio)
H1: Mejora vs baseline	$\geq 5\,\%$	0.59–1.10 % → **No soportada**	17.2–20.1 % ($p < 10^{-4}$) → **Soportada**
H2: GA-SA vs mejor MH (calidad; tiempo)	$\leq 2\,\%$; $\leq 50\,\%$ CBC	−0.02 %; 52.5× → **Parcial**	−0.44 %; 1.6× → **Parcial** (calidad sí; tiempo total no)
H3: Reducción inventario	$\geq 15\,\%$	12.2–17.5 % → **No soportada**	21.0–28.8 % ($p < 10^{-4}$) → **Soportada**

La lectura conjunta de ambos regímenes es el hallazgo central de la tesis: **el valor de la optimización de coproductos depende del régimen económico de la planta**. En el régimen v1 (demanda por encima de la capacidad y setup marginal) el problema degenera y una regla trivial es casi óptima — de ahí que H1 y H3 no se soportaran, y el análisis de potencia muestra que ese diseño no podía detectar los umbrales declarados. En el régimen operativo v2 (setup costoso, holgura de capacidad, demanda volátil), las tres hipótesis de mejora se soportan con potencia 1.000: mejora de costo del 17–20 %, reducción de inventario del 21–29 % y equivalencia de calidad de GA-SA con la mejor metaheurística individual. El componente de tiempo de H2 no se cumple en tiempo total en ningún régimen, pero mejora de 52.5× a 1.6× el tiempo de CBC, y en la vista *anytime* GA-SA alcanza el 99 % del óptimo antes de que el solver exacto complete la certificación en Medium y Large.

8.3. Contribuciones Principales

1. **Modelo matemático validado:** Un modelo MILP de planificación de coproductos avícolas con lot-sizing estocástico, setup y perecibilidad, aplicable a otras industrias de producción conjunta.
2. **Framework de metaheurísticas comparativo:** Implementación modular de GA, SA, DE y GA-SA con decodificador greedy compartido, reproducible y extensible.
3. **Evidencia empírica sobre GA-SA:** Confirmación, en un problema real, de la ventaja del enfoque híbrido GA-SA reportada por Akbari-Aghghaleh et al. [15].
4. **Conjunto de instancias calibradas en dos regímenes:** 39 instancias (9 del régimen v1 y 30 del operativo v2, estas últimas con perfiles de pollo mezclables en parvada), con parámetros del sector avícola colombiano, disponibles públicamente para benchmarking.

5. **Caracterización del régimen de valor:** Evidencia de que el beneficio de la optimización depende del régimen económico (setup/holgura/volatilidad), con la frontera cuantificada entre el régimen donde una regla trivial basta y aquel donde las metaheurísticas aportan 17–20 % de mejora.
6. **Análisis de robustez:** Validación de que las soluciones son operativamente viables y robustas ante perturbaciones de demanda (deterioro $\leq 0.04\,\%$).

8.4. Limitaciones del Estudio

1. **Datos sintéticos:** Las instancias utilizan datos calibrados pero sintéticos. Aunque la cobertura de rangos de precio FENAVI es 100 %, la comparación temporal externa sin desfase mantiene correlación baja ((| |*{prom} 0.19)); al permitir desfases mensuales, la alineación mejora ((|* {lag}|_{prom} 0.65)) pero con desplazamientos de pico no triviales. Por ello, la validación con datos operativos reales de planta sigue siendo necesaria.
2. **Dependencia del régimen económico:** En el régimen v1 (demanda > capacidad, setup marginal) el baseline de máxima capacidad es casi óptimo y el margen de mejora de las metaheurísticas se anula; los beneficios reportados (17–20 %) corresponden al régimen operativo v2. La transferencia a una planta concreta exige verificar en cuál régimen opera.
3. **Proporciones fijas:** El modelo asume proporciones de coproductos constantes (α_p), sin considerar variabilidad inter-lote.
4. **Sin scheduling:** Solo se aborda lot-sizing diario, no el scheduling detallado de la línea de despiece.
5. **Perecibilidad simplificada:** Se modela como restricción de vida útil discreta, sin considerar deterioro gradual de calidad.

8.5. Trabajo Futuro

1. **Híbrido DE-SA:** Evaluar la combinación DE + SA como búsqueda local, reportada positivamente por Akbari-Aghghaleh et al. [15].
2. **Extensión multi-objetivo:** Reformular como problema bi-objetivo (costo vs. nivel de servicio) con NSGA-II o MOEA/D, aprovechando la infraestructura de metaheurísticas implementada.
3. **Validación con datos reales:** Aplicar el modelo a datos operativos de una planta de beneficio avícola colombiana.
4. **Integración con scheduling:** Combinar lot-sizing con programación detallada de la línea de despiece, siguiendo las líneas de Claassen [18] y González-Neira et al. [30].
5. **Aprendizaje por refuerzo:** Explorar la integración de técnicas de Deep RL para ajustar dinámicamente los hiperparámetros de las metaheurísticas, siguiendo las tendencias identificadas por Tan et al. [40] y Wang et al. [41].

Referencias

[1] L. Heij, F. Wijnhoven, and S. Lokerse, "Design of meat processing systems with agent-based production control," *IFAC-PapersOnLine*, vol. 54, no. 1, pp. 1085–1090, 2021, doi: 10.1016/j.ifacol.2021.08.205.

[2] C. Gicquel and N. Miègeville, "Formulations and solution methods for the joint production and transportation planning in multi-site food supply chains," *Computers & Industrial Engineering*, vol. 111, pp. 253–265, 2017, doi: 10.1016/j.cie.2017.07.025.

[3] A. L. Solano-Blanco *et al.*, "Integrated planning decisions in the broiler chicken supply chain," *International Transactions in Operational Research*, 2022, doi: 10.1111/itor.12861.

[4] N. Tahraoui, L. Triqui, and M. Bennekrouf, "Operational planning of the production and the processing of chickens in multi-products slaughter unit," *OPSEARCH*, vol. 62, no. 3, pp. 1581–1615, 2025, doi: 10.1007/s12597-024-00846-1.

[5] FENAVI, "Avicultura en cifras 2024," Federación Nacional de Avicultores de Colombia, Bogotá, Colombia, 2024. Available: https://fenavi.org

[6] Departamento Administrativo Nacional de Estadística (DANE), "Cuenta satelite de agroindustria avícola – boletín técnico 2024," DANE, Bogotá, Colombia, Boletín Técnico, 2024. Available: https://www.dane.gov.co/files/operaciones/CSAAV/bol-CSAAV-2024pr.pdf

[7] M. Florian, J. K. Lenstra, and A. H. G. Rinnoy Kan, "Deterministic production planning: Algorithms and complexity," *Management Science*, vol. 26, no. 7, pp. 669–679, 1980, doi: 10.1287/mnsc.26.7.669.

[8] G. R. Bitran and H. H. Yanasse, "Computational complexity of the capacitated lot size problem," *Management Science*, vol. 28, no. 10, pp. 1174–1186, 1982, doi: 10.1287/mnsc.28.10.1174.

[9] H. G. Gören and S. Tunalı, "A hybrid approach for solving capacitated lot sizing with setup carryover, backordering and setup splitting," *Computers & Operations Research*, vol. 68, pp. 22–31, 2016, doi: 10.1016/j.cor.2015.10.012.

[10] A. Rahmani, H. Süral, and C. Iyigun, "Two-stage stochastic capacitated lot-sizing problem under demand uncertainty," *Computers & Operations Research*, vol. 174, p. 106881, 2025, doi: 10.1016/j.cor.2024.106881.

[11] M. Mahdieh, A. Clark, and M. Bijari, "A novel flexible model for lot sizing and scheduling with non-triangular, period overlapping and carryover setups in different machine configurations," *Flexible Services and Manufacturing Journal*, vol. 30, pp. 884–919, 2018, doi: 10.1007/s10696-017-9291-0.

[12] A. Yazdekhasti, Y. Z. Mehrjardi, D. Mohammaditabar, and R. Heidari, "A multi-period multi-modal stochastic supply chain model under COVID pandemic: A poultry industry case study in Mississippi," *Transportation Research Part E: Logistics and Transportation Review*, vol. 154, p. 102463, 2021, doi: 10.1016/j.tre.2021.102463.

[13] O. Ahumada and J. R. Villalobos, "Application of planning models in the agri-food supply chain: A review," *European Journal of Operational Research*, vol. 196, no. 1, pp. 1–20, 2009, doi: 10.1016/j.ejor.2008.02.014.

[14] P. Amorim, H.-O. Gunther, and B. Almada-Lobo, "Multi-objective integrated production and distribution planning of perishable products," *International Journal of Production Economics*, vol. 138, no. 1, pp. 89–101, 2014, doi: 10.1016/j.ijpe.2012.03.005.

[15] Z. Akbari-Aghghaleh, M. M. Paydar, and P. Ghasemi, "Designing a closed-loop poultry supply chain network considering perishability and sustainability," *Environment, Development and Sustainability*, 2025, doi: 10.1007/s10668-024-05847-y.

[16] I. Slama, O. Ben-Ammar, F. Masmoudi, and A. Dolgui, "Genetic algorithm and monte carlo simulation for a stochastic capacitated disassembly lot-sizing problem under random lead times," *Computers & Industrial Engineering*, vol. 159, p. 107468, 2021, doi: 10.1016/j.cie.2021.107468.

[17] Ç. Sel, B. Bilgen, J. M. Bloemhof-Ruwaard, and J. G. A. J. van der Vorst, "Multi-bucket optimization for integrated planning and scheduling in the perishable dairy supply chain," *Computers & Chemical Engineering*, vol. 77, pp. 59–73, 2015, doi: 10.1016/j.compchemeng.2015.03.020.

[18] G. D. H. Claassen, "A note on production planning and scheduling in the food processing industry," *International Journal of Production Research*, vol. 54, no. 22, pp. 6881–6893, 2016, doi: 10.1080/00207543.2016.1193251.

[19] FAO, "Poultry production and trade statistics," Food; Agriculture Organization of the United Nations, 2023. Available: https://www.fao.org

[20] M. N. Darghouth *et al.*, "A capacitated disassembly scheduling problem considering processing technology selection and parts commonality," *Journal of Remanufacturing*, vol. 11, pp. 243–261, 2021, doi: 10.1007/s13243-021-00104-3.

[21] J.-H. Kim, S.-M. Park, H.-J. Lee, *et al.*, "Smart sensor applications in poultry processing: A comprehensive review," *Sensors*, vol. 22, no. 10, p. 3920, 2022, doi: 10.3390/s22103920.

[22] L. García López, R. Fernández-Ruiz, and M. López-Martínez, "Automation systems in food processing: Current trends and future perspectives," *Automation*, vol. 4, no. 2, pp. 150–175, 2023, doi: 10.3390/automation4020021.

[23] J. R. Birge and F. Louveaux, "Introduction to stochastic programming," *Springer Series in Operations Research and Financial Engineering*, 2011, doi: 10.1007/978-1-4614-0237-4.

[24] S. M. J. Mirzapour Al-e-Hashem, H. Malekly, and M. B. Aryanezhad, "A multi-objective robust optimization model for multi-product multi-site aggregate production planning in a supply chain under uncertainty," *International Journal of Production Economics*, vol. 134, no. 1, pp. 28–42, 2011, doi: 10.1016/j.ijpe.2011.01.027.

[25] E. Arteaga-Cabrera, C. Ramírez-Márquez, E. Sánchez-Ramírez, J. G. Segovia-Hernández, O. Osorio-Mora, and J. A. Gómez-Salazar, "Advancing optimization strategies in the food industry: From traditional approaches to multi-objective and technology-integrated solutions," *Applied Sciences*, vol. 15, no. 7, p. 3846, 2025, doi: 10.3390/app15073846.

[26] M. L. Entrup, H.-O. Gunther, P. Van Beek, M. Grunow, and T. Seiler, "Mixed-integer linear programming approaches to shelf-life-integrated planning and scheduling in yoghurt production," *International Journal of Production Research*, vol. 43, no. 23, pp. 5071–5100, 2005, doi: 10.1080/00207540500161068.

[27] A. Rong, R. Akkerman, and M. Grunow, "An optimization approach for managing fresh food quality throughout the supply chain," *International Journal of Production Economics*, vol. 131, no. 1, pp. 421–429, 2011, doi: 10.1016/j.ijpe.2009.11.026.

[28] M. Abdel-Basset *et al.*, "Review of metaheuristic optimization algorithms for power systems problems," *Sustainability*, vol. 15, no. 12, p. 9434, 2023, doi: 10.3390/su15129434.

[29] B. G. Stefánsdóttir and M. Grunow, "Selecting new product designs and processing technologies under uncertainty: Two-stage stochastic model and application to a food supply chain," *International Journal of Production Economics*, vol. 191, pp. 89–103, 2017, doi: 10.1016/j.ijpe.2017.04.013.

[30] E. M. González-Neira, J. R. Montoya-Torres, and D. Barrera, "An optimization model for the poultry supply chain scheduling and distribution," *Computers & Operations Research*, vol. 175, p. 106927, 2025, doi: 10.1016/j.cor.2024.106927.

[31] D. Z. Dadaneh, M. Sanei, M. Basiri, and J. Razmi, "An integrated chance-constrained capacitated lot-sizing model for egg production planning," *Agricultural Systems*, vol. 221, p. 104108, 2024, doi: 10.1016/j.agsy.2024.104108.

[32] R. Juwitaa, S. Suprayogi, and A. H. Halim, "Two-stage stochastic programming for broiler supply chain optimization under growth uncertainty," *Livestock Science*, vol. 289, p. 105586, 2024, doi: 10.1016/j.livsci.2024.105586.

[33] A. Roshani, D. Giglio, and M. Paolucci, "A relax-and-fix heuristic for the capacitated lot-sizing problem," *International Journal of Production Research*, vol. 55, no. 10, pp. 2791–2804, 2017, doi: 10.1080/00207543.2016.1223382.

[34] Z. Liang, Y. He, and F. Wu, "Multi-objective optimization for meat cutting and trim operations in the meat processing industry," *Computers and Industrial Engineering*, vol. 175, p. 108820, 2023, doi: 10.1016/j.cie.2022.108820.

[35] G. M. Kopanos, L. Puigjaner, and M. C. Georgiadis, "Efficient mathematical frameworks for detailed production scheduling in food processing industries," *Computers & Chemical Engineering*, vol. 42, pp. 206–216, 2012, doi: 10.1016/j.compchemeng.2011.12.015.

[36] N. P. Mahalik and A. N. Nambiar, "Trends in food packaging and manufacturing systems and technology," *Trends in Food Science & Technology*, vol. 21, no. 3, pp. 117–128, 2010, doi: 10.1016/j.tifs.2009.12.006.

[37] N. Hartono, F. J. Ramírez, and D. T. Pham, "Optimisation of robotic disassembly plans using the bees algorithm," *Robotics and Computer-Integrated Manufacturing*, vol. 78, p. 102411, 2022, doi: 10.1016/j.rcim.2022.102411.

[38] Y. Feng *et al.*, "Synthetic data augmentation for enhanced chicken carcass instance segmentation," *arXiv preprint arXiv:2507.18558*, 2025, Available: https://arxiv.org/abs/2507.18558

[39] M. Awad, A. Tiwari, and Y. Liu, "The minimisation of giveaway and underweight in poultry proportioning process," *Food Control*, vol. 144, p. 109368, 2023, doi: 10.1016/j.foodcont.2022.109368.

[40] Z. Tan, S. Guo, J. Guo, B. Du, and K. Wang, "A discrete keplerian optimization algorithm with q-learning for human-robot collaborative partial disassembly line balancing problem," *Applied Soft Computing*, vol. 188, 2026, doi: 10.1016/j.asoc.2025.114406.

[41] J. Wang, M. Li, F. Meng, H. Zhao, and X. Sun, "Multi-objective reinforcement learning for dynamic balancing of two-sided human–robot collaborative disassembly lines," *Computers and Industrial Engineering*, vol. 212, 2026, doi: 10.1016/j.cie.2025.111703.

Anexos

Anexo A: Formulación Matemática Completa

La formulación completa del modelo se presenta en la Sección 5 del presente documento, incluyendo los conjuntos (§5.1), la función objetivo (§5.2, Ecuación 1), las restricciones (§5.3, Ecuaciones 2-8) y la estructura de dos etapas (§5.4).

Anexo B: Pseudocódigos de Algoritmos

Los pseudocódigos detallados y diagramas de flujo de los cuatro algoritmos se presentan en la Sección 6: GA (§6.7, Figura 9), SA (§6.8, Figura 10), DE (§6.9, Figura 11) y GA-SA (§6.10, Figura 12).

Anexo C: Resultados Detallados por Instancia

Los resultados completos por instancia están disponibles en el archivo `comparison.csv` del repositorio público del proyecto: https://github.com/DanAndCastRod/OBC.

Anexo D: Herramientas Tecnológicas

- **Lenguaje de Programación:** Python 3.11+ (con tipado estático)
- **Solver Exacto:** PuLP 2.7.0 (CBC — COIN-OR Branch and Cut)
- **Calibración:** Optuna 4.7.0 (TPE sampler)
- **Datos:** NumPy 1.26.0, Pandas 2.3.2
- **Visualización:** Matplotlib 3.8.0, Seaborn 0.13.0
- **Estadística:** SciPy 1.11.2 (módulo stats)
- **Testing:** Pytest 8.4.1
- **Control de Versiones:** Git/GitHub
- **Documentación:** Pandoc 3.x + pandoc-crossref + XeLaTeX (pipeline Markdown → PDF)
- **Generación de instancias:** YAML (PyYAML 6.0.1)

Las versiones corresponden a las fijadas en `requirements.txt` para reproducibilidad.